



**SISTEM DETEKSI POSISI TUBUH BELAKANG SAAT
MENGANGKAT BEBAN BERBASIS *INTERNET OF
THINGS* MENGGUNAKAN *RANDOM FOREST***

SKRIPSI

**Disusun Sebagai Syarat Memperoleh Gelar Sarjana Komputer
Prodi Teknik Informatika Fakultas Teknik
Universitas Malikussaleh**

DISUSUN OLEH :

**NAMA : MUHAMMAD FATHURRAHMAN
NIM : 220170212
PRODI : TEKNIK INFORMATIKA**

**JURUSAN INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS MALIKUSSALEH
LHOKSEUMAWE
2026**

KATA PENGANTAR

Segala puji dan syukur hanya bagi Allah Yang Maha Esa, oleh karena anugerah-Nya yang melimpah akhirnya penulis dapat menyelesaikan skripsi ini dengan judul “Sistem Deteksi Posisi Tubuh Belakang saat Mengangkat Beban Berbasis *Internet of Things* Menggunakan *Random Forest*”. Alhamdulillah, penulis dapat menyelesaikannya dengan baik. Skripsi ini disusun sebagai salah satu syarat dalam menyelesaikan dan memperoleh gelar Sarjana Komputer pada Program Studi Teknik Informatika Universitas Malikussaleh.

Penulis menghadapi sejumlah tantangan dan kesulitan dalam menyusun skripsi ini, namun dapat menyelesaikannya berkat nasihat, dukungan, dorongan, dan bimbingan dari berbagai pihak. Semoga Allah Yang Maha Esa membalas kebaikan tersebut. Oleh karena itu, penulis ingin menggunakan kesempatan ini untuk menyampaikan rasa terima kasih yang tulus kepada:

1. Bapak Prof. Dr. Ir. H. Herman Fithra, S.T., M.T., IPM., ASEAN.Eng., selaku Rektor Universitas Malikussaleh.
2. Bapak Dr. Muhammad Daud, M.T., selaku Dekan Fakultas Teknik Universitas Malikussaleh.
3. Bapak Dr. Eng. Ir. Muhammad Fikry, S.Kom., M.Kom., selaku Ketua Jurusan Informatika Universitas Malikussaleh dan Dosen Pembimbing Utama yang banyak membantu dalam memberikan arahan dan nasihat yang berguna dalam penyusunan skripsi ini.
4. Bapak Hafizh Al Kautsar Aidilof, S.T., M.Kom., selaku Sekretaris Jurusan Informatika Universitas Malikussaleh dan dosen penguji yang telah memberikan kritik dan saran untuk kesempurnaan skripsi ini.
5. Bapak Said Fadlan Anshari, S.Kom., M.Kom., selaku Ketua Program Studi Teknik Informatika Universitas Malikussaleh.
6. Bapak Rizki Suwanda, S.T., M.Kom., selaku Dosen Pembimbing Kedua yang banyak membantu dalam memberikan arahan dan nasihat yang berguna dalam penyusunan skripsi ini.
7. Ibu Zara Yunizar, S.Kom., M.Kom., selaku dosen penguji yang telah memberikan kritik dan saran untuk kesempurnaan skripsi ini.

8. Bapak dan Ibu Dosen serta seluruh Staf Jurusan Informatika, Fakultas Teknik Universitas Malikussaleh yang telah memberikan ilmu pengetahuan dan membantu penulis dalam segala hal selama di bangku perkuliahan.
9. Kedua orang tua penulis, Bapak Jamaludin dan Ibu Yusra Defawati, yang selalu mendukung dan berdoa tiada henti agar anaknya dapat menyelesaikan masa studinya hingga sarjana, serta menjadi segalanya dalam hidup penulis karena tanpa mereka penulis bukanlah siapa-siapa.
10. Abang tersayang, Ahmad Syauqi Jafari; kedua kakak tersayang, Muthia Tsabita Jafari dan Raisa Hanifa Jafari; serta adik tersayang, Naura Qonita Jafari, yang telah memberikan dorongan, doa, dan dukungan kepada penulis.

Penulis menyadari masih banyak kekurangan dan kelemahan dalam penyusunan laporan ini, maka penulis dengan tulus menerima saran dan kritik yang membangun. Akhir kata, penulis mengucapkan terima kasih dan berharap semoga karya ini bermanfaat bagi semua pihak.

Lhokseumawe, 17 Juni 2026
Penulis,

Muhammad Fathurrahman
NIM. 220170212

ABSTRAK

Work-related Musculoskeletal Disorders (WMSDs) masih menjadi masalah kesehatan kerja yang disebabkan oleh posisi tubuh yang kurang tepat saat mengangkat beban. Penelitian ini bertujuan merancang dan menguji Sistem Deteksi Posisi Angkat Beban berbasis *Internet of Things* (IoT) yang mampu memantau posisi tubuh secara *real-time* serta mengidentifikasi gerakan benar dan salah menggunakan metode *Random Forest*. Penelitian menggunakan pendekatan eksperimen dengan pengumpulan data dari 20 responden yang melakukan aktivitas mengangkat beban pada dua kondisi, yaitu teknik benar dan teknik salah. Sistem dibangun menggunakan dua sensor MPU6050, satu sensor BMP280, mikrokontroler ESP8266, *website* berbasis Flask, serta *buzzer* sebagai umpan balik. Data yang terkumpul kemudian melalui tahap pembersihan data, pelabelan, ekstraksi fitur, normalisasi, pemodelan, dan evaluasi klasifikasi. Hasil penelitian menunjukkan bahwa sistem berhasil bekerja secara terintegrasi dan model *Random Forest* memperoleh akurasi sebesar 83,32% dengan rata-rata akurasi per subjek 84,80%. Pada pengujian sistem, 38 dari 40 data uji menghasilkan prediksi yang sesuai dengan label aktual, sedangkan respons *buzzer* juga berjalan sesuai rancangan. Hasil ini menunjukkan bahwa sistem dapat digunakan sebagai media deteksi awal untuk membantu pengguna memperbaiki teknik angkat beban dan mengurangi risiko cedera punggung.

Kata Kunci: *Internet of Things, Random Forest, WMSDs, Klasifikasi Postur*

ABSTRACT

Work-related Musculoskeletal Disorders (WMSDs) remain a significant occupational health issue caused by improper body posture during lifting. This study aims to design and test an Internet of Things (IoT)-based Lifting Posture Detection System capable of monitoring body posture in real-time and identifying correct and incorrect movements using the Random Forest method. The study employed an experimental approach, collecting data from 20 participants performing load-lifting activities under two conditions: correct technique and incorrect technique. The system was built using two MPU6050 sensors, one BMP280 sensor, an ESP8266 microcontroller, a Flask-based web application, and a buzzer for feedback. The collected data then underwent data cleaning, labeling, feature extraction, normalization, modeling, and classification evaluation. The results showed that the system functioned effectively as an integrated system, and the Random Forest model achieved an accuracy of 83.32% with an average accuracy per subject of 84.80%. During system testing, 38 out of 40 test data points produced predictions that matched the actual labels, while the buzzer response also functioned as designed. These results indicate that the system can be used as an early detection tool to help users improve their lifting techniques and reduce the risk of back injuries.

Keywords: *Internet of Things, Random Forest, WMSDs, Posture Classification*

DAFTAR ISI

KATA PENGANTAR	i
ABSTRAK	iii
ABSTRACT	iv
DAFTAR ISI	v
DAFTAR TABEL	viii
DAFTAR GAMBAR	ix
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	5
1.3 Tujuan Penelitian.....	5
1.4 Manfaat Penelitian	5
1.5 Ruang Lingkup Dan Batasan Penelitian	7
BAB II TINJAUAN PUSTAKA	9
2.1 Posisi Angkat Beban	9
2.2 <i>Internet of Things</i>	10
2.3 <i>Random Forest</i>	11
2.4 Mikrokontroler	12
2.5 <i>Node MCU (ESP8266)</i>	13
2.6 MPU6050	14
2.7 BMP280	15
2.8 <i>Piezo Buzzer</i>	16
2.9 Baterai Lithium-ion	17
2.10 Ekstraksi Fitur	18
2.10.1 Magnitudo Akselerometer	18
2.10.2 Magnitudo Girooskop	19
2.10.3 Sudut Kemiringan	19
2.10.4 Selisih Antar Sensor	20
2.10.5 <i>Rolling Feature</i>	21
2.11 <i>Robust Scaler</i>	22
2.12 Python	22

2.13	Scikit-learn	23
2.14	Visual Studio Code.....	23
2.15	Arduino IDE.....	24
2.16	Fritzing	24
2.17	<i>Flowchart</i>	24
2.18	Unified Modeling Language	25
2.18.1	Use Case Diagram.....	26
2.18.2	Sequence Diagram.....	27
2.19	Penelitian Terdahulu.....	28
BAB III	METODE PENELITIAN.....	34
3.1	Tempat dan Waktu Pelaksanaan Penelitian	34
3.2	Langkah Penelitian.....	34
3.2.1	Perancangan Alat Deteksi Posisi Angkat Beban	35
3.2.2	Pengumpulan Data.....	35
3.2.3	<i>Preprocessing</i>	36
3.2.4	Pemodelan <i>Random Forest</i>	37
3.2.5	Evaluasi Sistem Deteksi Posisi Angkat Beban.....	39
3.3	Metode Penelitian.....	40
3.4	Analisis Kebutuhan	41
3.4.1	Kebutuhan Perangkat Keras	41
3.4.2	Kebutuhan Perangkat Lunak.....	42
3.5	Skema Sistem Deteksi Posisi Angkat Beban	42
3.6	Rancangan Sistem Deteksi Posisi Angkat Beban.....	49
3.6.1	Rancangan Alat Deteksi Posisi Angkat Beban.....	49
3.6.2	Rancangan <i>Website</i> Deteksi Posisi Angkat Beban	50
3.6.3	Rancangan <i>Random Forest</i>	52
BAB IV	HASIL DAN PEMBAHASAN.....	55
4.1	Pengumpulan Data	55
4.1.1	Instrumen Penelitian	55
4.1.2	Skenario Pengambilan Data.....	57
4.1.3	Responden Penelitian.....	60
4.1.4	Hasil Pengumpulan Data	65

4.2	<i>Preprocessing</i> Data	66
4.2.1	Pembersihan Data	67
4.2.2	Pelabelan Data	69
4.2.3	Ekstraksi Fitur	71
4.2.4	Normalisasi Data	75
4.3	Pemodelan <i>Random Forest</i>	77
4.3.1	Pembagian Data	78
4.3.2	Model <i>Random Forest</i>	79
4.4	Evaluasi Sistem Deteksi Posisi Angkat Beban.....	84
4.4.1	Hasil Evaluasi Model.....	84
4.4.2	Pengujian Sistem Deteksi Posisi Angkat Beban.....	87
4.4.3	Analisis Hasil Penelitian.....	93
BAB V	KESIMPULAN DAN SARAN.....	96
5.1	Kesimpulan	96
5.2	Saran.....	97
	DAFTAR PUSTAKA	98

DAFTAR TABEL

Tabel 2.1 Simbol-simbol <i>Flowchart</i>	25
Tabel 2.2 Simbol-simbol <i>Use Case Diagram</i>	26
Tabel 2.3 Simbol-simbol <i>Sequence Diagram</i>	27
Tabel 2.4 Penelitian Terdahulu	28
Tabel 3.1 Konfigurasi <i>Hyperparameter</i> Model	53
Tabel 3.2 Metrik Evaluasi Model <i>Random Forest</i>	54
Tabel 4.1 Karakteristik Demografi Responden.....	61
Tabel 4.2 Riwayat dan Kebiasaan Responden	62
Tabel 4.3 Sampel Hasil Data Sensor MPU6050	65
Tabel 4.4 Sampel Hasil Data Sensor BMP280	66
Tabel 4.5 Deskripsi Fitur <i>Dataset</i>	67
Tabel 4.6 Data <i>Subject</i> 01 Setelah Dibersihkan	69
Tabel 4.7 Sampel Hasil Pelabelan Data <i>Subject</i> 01	70
Tabel 4.8 Ekstraksi Fitur Data	74
Tabel 4.9 Sampel Data Sebelum <i>Scaling</i>	76
Tabel 4.10 Sampel Data Setelah <i>Scaling</i>	77
Tabel 4.11 Parameter Model <i>Random Forest</i>	79
Tabel 4.12 Data Sampel untuk Pembentukan <i>Node</i>	80
Tabel 4.13 Hasil Pemisalah <i>Node</i> Kiri.....	81
Tabel 4.14 Hasil Pemisalah <i>Node</i> Kanan.....	82
Tabel 4.15 Nilai Akurasi Per- <i>Subject</i>	84
Tabel 4.16 <i>Classification Report</i>	85
Tabel 4.17 Tabel Pengujian Data.	89

DAFTAR GAMBAR

Gambar 2.1 Contoh Posisi Angkat Beban	9
Gambar 2.2 <i>Pinout Node</i> MCU (ESP8266)	13
Gambar 2.3 Sumbu Sensor MPU6050	14
Gambar 2.4 BMP280	15
Gambar 2.5 <i>Piezo buzzer</i>	16
Gambar 2.6 Baterai <i>Lithium-ion</i>	17
Gambar 3.1 Langkah Penelitian Sistem Deteksi Posisi Angkat Beban	34
Gambar 3.2 Skema Alur Pengembangan Sistem	40
Gambar 3.3 Alur Sistem Deteksi Posisi Angkat Beban	43
Gambar 3.4 <i>Sequence Diagram</i> Sistem Deteksi Posisi Angkat Beban.....	46
Gambar 3.5 Diagram Sirkuit Sistem Deteksi Posisi Angkat Beban	49
Gambar 3.6 Use Case Diagram Sistem Deteksi Posisi Angkat Beban	50
Gambar 4.1 Tampilan Alat Baca Sensor MPU6050 dan BMP280	55
Gambar 4.2 Foto Proses Pengambilan Data.....	60
Gambar 4.3 Pernyataan Persetujuan Responden (<i>Informed consent</i>).	64
Gambar 4.4 Perbandingan Distribusi Data.....	71
Gambar 4.5 <i>Confusion matrix</i>	86
Gambar 4.6 <i>Features Importance</i>	87
Gambar 4.7 Tampilan <i>Website</i> Ketika Memprediksi Benar	88
Gambar 4.8 Tampilan <i>Website</i> Ketika Memprediksi Salah	89
Gambar 4.9 Pengujian Sistem Terhadap <i>Subject</i>	93

BAB I

PENDAHULUAN

1.1 Latar Belakang

Work Musculoskeletal Disorders (WMSDs) merupakan salah satu masalah kesehatan global yang berdampak besar terhadap produktivitas dan kualitas hidup manusia. Berdasarkan analisis *Global Burden of Disease* (GBD) 2019, sekitar 1,71 miliar orang di seluruh dunia hidup dengan kondisi muskuloskeletal seperti nyeri punggung bawah, nyeri leher, patah tulang, osteoarthritis, amputasi, dan artritis reumatoid (*World Health Organization*, 2023). Kondisi muskuloskeletal menjadi penyebab utama *Years Lived with Disability* (YLDs) secara global dengan kontribusi sebesar 17% dari total YLDs, di mana nyeri punggung bawah merupakan kontributor terbesar dengan 570 juta kasus yang mewakili 7,4% dari beban YLDs dunia.

Analisis terbaru juga menunjukkan bahwa kasus gangguan muskuloskeletal lainnya meningkat tajam hingga 123,4% antara 1990 dan 2020, dan diproyeksikan akan meningkat lebih dari 115% hingga tahun 2050, menjadikan gangguan ini sebagai penyebab keenam tertinggi YLDs global (Gill dkk., 2023). Hubungan antara posisi mengangkat beban dengan keluhan *Work-related Musculoskeletal Disorders* (WMSDs) telah dibuktikan oleh berbagai penelitian di Indonesia. Kidi dkk. (2024) menemukan hubungan signifikan antara sikap kerja saat menurunkan dan menaikkan karung beras dengan keluhan muskuloskeletal pada buruh angkut PT X, dengan posisi memiringkan leher menjadi yang paling dominan (60-63%). Salcha dkk. (2021) juga melaporkan bahwa 81,4% petani padi memiliki postur kerja berisiko tinggi dan 72,1% mengalami keluhan muskuloskeletal berat, dengan hubungan yang signifikan. Penelitian pada pekerja angkat-angkut di UD. Barokah oleh Irwan dkk. (2021) menunjukkan bahwa aktivitas manual handling berisiko dan postur kerja berhubungan dengan risiko penyakit muskuloskeletal, di mana 66,7% pekerja memiliki postur kerja sangat tinggi. Ananda dkk. (2025) pada pemanen sawit menemukan bahwa 56% pekerja memiliki postur kerja sangat berisiko dan 48% mengalami MSDs risiko sangat tinggi, dengan hubungan yang

sangat signifikan. Secara konsisten, posisi membungkuk, memiringkan leher, dan postur salah saat mengangkat beban menjadi faktor utama penyebab WMSDs, yang memperkuat urgensi pengembangan sistem deteksi posisi angkat beban secara *real-time*.

Seiring dengan meningkatnya prevalensi gangguan muskuloskeletal, kebutuhan akan pencegahan dini dan promosi kesehatan kerja semakin mendesak, terutama dalam rangka mencapai *Sustainable Development Goals* (SDG) 3, yaitu *Good Health and Well-Being*. Tujuan ini menekankan pentingnya meningkatkan kualitas hidup dan memprioritaskan pencegahan penyakit. Namun, strategi pencegahan WMSDs yang berlaku di berbagai sektor kerja masih bergantung pada metode konvensional. Metode tersebut masih kurang umpan balik secara *real-time*, sifat subjektif, dan ketidakmampuan untuk memberikan koreksi segera terhadap posisi yang buruk. Batasan-batasan ini sering menghambat pengenalan tepat waktu terhadap posisi yang salah saat mengangkat beban, sehingga mempertahankan risiko cedera yang tinggi. Kesenjangan yang signifikan dalam lanskap teknologi saat ini terlihat dalam ketidakhadiran perangkat yang mampu memberikan umpan balik instan tentang posisi. Kekurangan ini terutama menonjol dalam bidang teknologi muskuloskeletal, otomatis, dan berbasis sensor, yang krusial untuk mengatasi kesenjangan ini melalui solusi inovatif. Temuan ini sejalan dengan observasi yang dilaporkan oleh Irianto dkk. (2025), yang menunjukkan bahwa gangguan posisi, seperti posisi kepala yang condong ke depan dan ketidakseimbangan tubuh akibat kebiasaan duduk dan membawa barang yang salah, menyoroti pentingnya deteksi dini dan pendidikan posisi sejak usia dini, yang menjadi elemen dasar untuk pencegahan jangka panjang. Oleh karena itu, terdapat kebutuhan untuk mengembangkan Sistem Deteksi Posisi Angkat Beban berbasis *Internet of Things* (IoT) yang dapat mendeteksi posisi tubuh secara *real-time* (Kalua, dkk., 2024). Sistem semacam ini akan mendukung terciptanya lingkungan kerja yang sehat, aman, dan produktif sesuai dengan Tujuan Pembangunan Berkelanjutan (SDGs).

Penelitian tentang deteksi posisi telah berkembang pesat seiring dengan meningkatnya permintaan akan sistem pemantauan posisi mencegah cedera

muskuloskeletal. Salah satu pendekatan awal yang telah banyak diterapkan adalah estimasi posisi berbasis kamera. Hsu dkk. (2025) mengembangkan sistem untuk mendeteksi posisi mengangkat menggunakan model estimasi posisi dari kamera *smartphone* dan jaringan *Long Short Term Memory* (LSTM). Sistem ini mampu mengklasifikasikan posisi yang benar dan salah dengan akurasi 96,9%. Namun, efektivitas sistem ini bergantung pada faktor-faktor seperti kualitas video, kondisi pencahayaan, dan sudut kamera, yang membuatnya kurang cocok untuk lingkungan industri atau lingkungan kerja dinamis yang memerlukan penilaian yang cepat dan otonom. Pendekatan berbasis kamera juga memiliki keterbatasan terkait privasi dan tidak memungkinkan pengukuran data biomekanik langsung, seperti sudut sendi atau orientasi tubuh, yang krusial dalam penilaian ergonomis.

Penelitian yang berfokus pada pemanfaatan *Internet of Things* (IoT) dan teknologi multisensor untuk mendeteksi aktivitas tubuh. Kianoush dkk. (2023) mengusulkan sistem untuk mendeteksi gerakan tubuh. Sistem ini didasarkan pada penggabungan sensor inframerah dan ultrasonik dengan algoritma *Random Forest*. Sistem ini dioptimalkan untuk pemrosesan tepi pada perangkat IoT berdaya rendah. Meskipun sistem ini menunjukkan keefektifan dalam mendeteksi aktivitas seperti berjalan dan jatuh dengan akurasi 94%, perlu dicatat bahwa studi ini tidak dirancang untuk mendeteksi posisi angkat beban atau melakukan analisis biomekanik spesifik. Selain itu, penggunaan sensor jarak pasif tidak memadai dalam menangkap dinamika sudut tubuh yang diperlukan untuk mengevaluasi risiko cedera punggung bawah.

Pengembangan sistem *Internet of Things* (IoT) berbasis sensor inersia juga telah dilakukan oleh Han dkk. (2020) yang merancang sistem yang menggunakan sensor *Inertial Measurement Unit* (IMU) sembilan sumbu dan teknologi LoRa. Sistem ini mengidentifikasi aktivitas harian, seperti berjalan, berdiri, dan menaiki tangga, dengan akurasi 95,06% menggunakan algoritma *Random Forest*. Namun, sistem ini tidak fokus pada aktivitas mengangkat beban, dan tidak termasuk parameter ergonomis seperti sudut fleksi punggung atau posisi pinggul sesuai dengan standar penilaian risiko, seperti Persamaan Mengangkat *National Institute for Occupational Safety and Health* (NIOSH). Karena aktivitas yang diuji terbatas

pada gerakan umum, sistem ini belum dapat digunakan untuk pencegahan cedera di lingkungan kerja yang melibatkan tugas fisik berat.

Beberapa penelitian telah mengembangkan Sistem Deteksi Posisi Angkat Beban berbasis *Internet of Things* (IoT) untuk tujuan kebugaran. SmartPosisie, yang dikembangkan oleh Rane dkk. (2025), menggunakan sensor fleksibel, *Convolutional Neural Network* (CNN) berbasis gambar, dan modul ESP8266 untuk memberikan pemberitahuan *real-time* tentang posisi duduk atau berdiri. Meskipun inovatif, akurasi sistem ini hanya sekitar 75,52%, dan tidak dapat menangani gerakan kompleks, seperti mengangkat beban berat. Selain itu, sistem ini tidak mempertimbangkan standar biomekanik ergonomis, dan tidak dapat menilai risiko cedera berdasarkan sudut tubuh yang terlibat dalam tugas mengangkat beban.

Dalam bidang biomekanika, Alghifari dkk. (2024) mengembangkan sistem *wearable* dengan sensor MPU6050 untuk mendeteksi akurasi gerakan latihan beban, seperti *dumbbell curls* dan *triceps extensions*, menggunakan algoritma *Random Forest*. Model tersebut mencapai akurasi 96,3%. Namun, penelitian ini terbatas pada gerakan otot sederhana dan terisolasi, dan tidak mencakup gerakan kompleks seperti mengangkat beban dari lantai, yang memerlukan koordinasi antara pinggul, lutut, dan punggung. Selain itu, sistem ini tidak dirancang untuk aplikasi *Internet of Things* (IoT) penuh dan hanya memberikan umpan balik melalui *buzzer*, tanpa integrasi ke *platform* pemantauan ergonomi.

Berdasarkan tinjauan ini, dapat disimpulkan bahwa belum ada penelitian yang secara khusus menggabungkan sensor inersia berbasis IoT, analisis biomekanik pengangkatan beban, dan algoritma *Random Forest* untuk mendeteksi posisi pengangkatan beban yang berisiko dan memberikan peringatan *real-time*. Studi sebelumnya terbatas dalam hal konteks pengangkatan, parameter ergonomi spesifik, kemampuan IoT untuk pemantauan jarak jauh, dan ketergantungan pada gambar. Oleh karena itu, terdapat kesenjangan penelitian yang signifikan dalam pengembangan sistem berbasis IoT yang dapat mendeteksi posisi pengangkatan beban dan memberikan umpan balik yang segera, akurat, dan sesuai ergonomi untuk mencegah gangguan muskuloskeletal (WMSDs).

1.2 Rumusan Masalah

Berdasarkan uraian pada latar belakang tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang Sistem Deteksi Posisi Angkat Beban tubuh saat mengangkat beban berbasis *Internet of Things* (IoT)?
2. Bagaimana penerapan metode *Random Forest* dalam klasifikasi posisi tubuh berdasarkan data sensor?
3. Bagaimana sistem dapat mengidentifikasi posisi tubuh saat mengangkat beban yang benar dan yang salah?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dijabarkan, tujuan penelitian ini adalah sebagai berikut:

1. Merancang dan mengembangkan Sistem Deteksi Posisi Angkat Beban tubuh saat mengangkat beban berbasis *Internet of Things* (IoT) yang mampu mengukur dan memantau posisi tubuh secara *real-time* menggunakan sensor inersia.
2. Menerapkan metode *Random Forest* sebagai algoritma klasifikasi untuk mengolah dan mengklasifikasikan data sensor inersia dalam mendeteksi posisi tubuh saat mengangkat beban.
3. Mengidentifikasi dan membedakan posisi tubuh yang benar dan yang salah saat mengangkat beban berdasarkan hasil klasifikasi data sensor menggunakan metode *Random Forest*.

1.4 Manfaat Penelitian

Hasil penelitian ini diharapkan memberikan manfaat teoretis, akademis, dan praktis. Manfaat teoretis dari pendekatan ini adalah sebagai berikut:

1. Memberikan kontribusi konseptual dalam pengembangan Sistem Deteksi Posisi Angkat Beban tubuh saat mengangkat beban berbasis sensor inersia (IMU) dengan memanfaatkan pendekatan *Internet of Things* (IoT) dan algoritma *Random Forest* untuk klasifikasi posisi angkat beban.
2. Memperkaya kajian ilmiah mengenai pemodelan pola gerakan biomekanik

manusia, khususnya pada aktivitas mengangkat beban, melalui pemanfaatan data sensor yang dianalisis menggunakan metode *machine learning*.

3. Menjadi referensi teoretis bagi penelitian selanjutnya yang berfokus pada integrasi *wearable sensor* dan algoritma klasifikasi dalam konteks kesehatan kerja dan ergonomi.

Adapun manfaat secara akademis adalah sebagai berikut:

1. Menyediakan bahan referensi akademik bagi mahasiswa dan dosen, khususnya pada bidang Teknik Informatika, yang berkaitan dengan pengembangan sistem IoT, *wearable*, dan pengenalan aktivitas manusia (*human activity recognition*).
2. Menjadi contoh penerapan metodologi penelitian berbasis data sensor, mulai dari proses pengambilan data, *preprocessing*, ekstraksi fitur, hingga evaluasi model klasifikasi menggunakan algoritma *Random Forest*.
3. Mendukung pengembangan materi pembelajaran dan praktikum pada mata kuliah terkait, seperti *Embedded System*, *Internet of Things* (IoT), dan *Machine learning*, melalui studi kasus nyata pada deteksi posisi angkat beban.
4. Menambah literatur ilmiah nasional dalam bidang penerapan teknologi cerdas untuk pencegahan gangguan muskuloskeletal akibat kerja (WMSDs), yang saat ini masih relatif terbatas, khususnya pada konteks posisi angkat beban.

Terakhir, Adapun manfaat secara praktis adalah sebagai berikut:

1. Menghasilkan Sistem Deteksi Posisi Angkat Beban angkat beban secara *real-time* yang mampu mengidentifikasi posisi tubuh yang benar dan yang salah, sehingga dapat membantu pengguna dalam mencegah cedera punggung bawah akibat kesalahan posisi.
2. Menyediakan alat bantu ergonomis berbasis IoT yang dapat diterapkan pada berbagai sektor, seperti manufaktur, logistik, pergudangan, serta aktivitas latihan fisik yang melibatkan pengangkatan beban.
3. Mendukung implementasi program Kesehatan dan Keselamatan Kerja (K3) melalui pemanfaatan teknologi pemantauan posisi tubuh secara

berkelanjutan, serta berkontribusi terhadap pencapaian *Sustainable Development Goals* (SDGs) poin 3: *Good Health and Well-Being* melalui upaya pencegahan dini gangguan muskuloskeletal terkait pekerjaan.

1.5 Ruang Lingkup Dan Batasan Penelitian

Untuk memastikan bahwa penelitian ini terfokus, terarah, dan sesuai dengan waktu dan sumber daya yang tersedia, ruang lingkup dan batasan penelitian ini ditetapkan sebagai berikut:

1. Sistem dirancang untuk mendeteksi dua kategori saat mengangkat beban, yaitu posisi baik dan posisi buruk saat melakukan aktivitas mengangkat beban dari posisi jongkok ke posisi berdiri. Selain itu, sistem dilengkapi dengan mekanisme *feedback* berupa suara yang dikeluarkan oleh alat ketika terdeteksi posisi yang salah.
2. Penelitian hanya memfokuskan analisis pada aktivitas mengangkat beban dari lantai menuju posisi berdiri. Aktivitas lain seperti mendorong, menarik, memutar tubuh, membungkuk statis, atau mengangkat beban di atas kepala tidak termasuk dalam cakupan penelitian.
3. Sistem hanya menggunakan dua sensor MPU6050 dan satu sensor BMP280, yang mana MPU6050 dipasang pada punggung bagian atas (*thoracic*), punggung bagian bawah (*lumbar*) dan pada beban ditempelkan BMP280. Pemilihan titik pemasangan ini ditujukan untuk menangkap sudut fleksi dan ekstensi punggung yang relevan dalam penilaian risiko ergonomis.
4. Algoritma yang digunakan untuk klasifikasi posisi dibatasi pada model *Random Forest*. Penelitian tidak melakukan perbandingan dengan algoritma lain untuk menjaga fokus analisis dan kedalaman pembahasan.
5. Pengujian sistem hanya dilakukan di lingkungan Universitas Malikussaleh. Lokasi di luar Universitas Malikussaleh tidak termasuk dalam cakupan penelitian guna memastikan kondisi lingkungan pengujian lebih terkendali, seragam, dan konsisten, sehingga meminimalkan pengaruh variabel eksternal terhadap hasil pengujian sistem.
6. Subjek penelitian dibatasi sebanyak 20 orang dengan kondisi fisik normal

serta tidak memiliki riwayat gangguan muskuloskeletal. Pembatasan ini bertujuan untuk mengurangi variabilitas data akibat perbedaan kondisi medis yang dapat memengaruhi pola gerakan dan hasil klasifikasi posisi.

7. Jenis beban yang digunakan dalam pengujian adalah galon air berkapasitas 15 liter dengan bentuk dan karakteristik beban yang seragam. Pembatasan jenis dan berat beban ini diterapkan untuk menjaga konsistensi pola pengangkatan dan memastikan keamanan subjek selama proses penelitian.
8. Evaluasi performa model dilakukan menggunakan tiga metrik utama, yaitu akurasi, *recall*, dan *F1-score*. Penggunaan metrik tersebut dipilih untuk memberikan gambaran yang memadai mengenai kinerja klasifikasi.

BAB II

TINJAUAN PUSTAKA

2.1 Posisi Angkat Beban

Posisi Angkat Beban adalah cara atau sikap tubuh yang dilakukan saat mengangkat benda atau barang dengan teknik yang tepat sesuai prinsip ergonomi untuk menghindari cedera dan memaksimalkan efisiensi kerja.



Gambar 2.1 Contoh Posisi Angkat Beban

Sumber : Susanti & Septi (2021)

Menurut Alfiyan (2023), posisi yang digunakan saat mengangkat benda harus sesuai dengan prosedur yang telah ditetapkan, mengutamakan ergonomi, dan mematuhi aturan pengangkatan yang telah ditentukan. Protokol yang benar untuk mengangkat benda adalah sebagai berikut (Susanti & Septi, 2021):

1. Awalnya, seseorang harus mengambil posisi jongkok, memastikan kaki ditempatkan pada jarak yang setara dengan lebar bahu. Kemudian, ia harus mendekati benda tersebut, menjaga jarak yang dekat dengannya. Selama fase mengangkat, sangat penting bagi seseorang untuk menjaga posisi tegak, dengan dagu terangkat, sehingga mencegah kepala atau tubuh condong ke depan atau ke belakang.
2. Saat melakukan latihan mengangkat, penting untuk memegang objek dengan pegangan yang kuat untuk memanfaatkan kekuatan tulang dan otot. Penting untuk menjaga kaki tetap lurus agar objek terangkat.
3. Terakhir, tubuh bagian atas harus diposisikan sedemikian rupa sehingga sejajar dengan kaki dan tegak lurus terhadap lantai sebanyak mungkin.

2.2 *Internet of Things*

Internet of Things (IoT) adalah istilah yang digunakan untuk menggambarkan jaringan perangkat yang saling terhubung, yang memanfaatkan teknologi internet untuk memfasilitasi pertukaran data. Tujuan utama sistem ini adalah untuk membangun infrastruktur komunikasi terintegrasi yang memfasilitasi konektivitas tanpa hambatan antar perangkat, sehingga mengoptimalkan pemanfaatan koneksi internet yang terus-menerus (Putri & Mahmudin, 2025). Konsep ini beroperasi melalui pemrograman berbasis argumen, di mana instruksi yang diberikan membentuk koneksi otomatis antarmesin tanpa intervensi manusia (Fikhri & Nurdin, 2024). Istilah “*Internet of Things*” pertama kali diperkenalkan oleh Kevin Ashton pada tahun 2002. IoT memfasilitasi konektivitas berbagai entitas, yang disebut “things,” ke internet, sehingga memungkinkan pengendalian jarak jauh (Turyadi, 2021) .

Cara kerja IoT yaitu dengan menggunakan alamat IP (*Internet Protocol*) yang berfungsi sebagai identitas jaringan yang dibutuhkan setiap perangkat agar dapat terhubung ke internet. Dengan adanya alamat IP, perangkat mampu saling berkomunikasi dalam suatu jaringan di mana masing-masing perangkat memperoleh alamat unik untuk mengakses layanan internet. Pada prinsipnya, IoT bekerja melalui instruksi pemrograman yang menghasilkan bahasa komunikasi yang dapat dipahami perangkat, sehingga memungkinkan koneksi otomatis antarperangkat bahkan pada jarak jauh. Konektivitas sistem dan perangkat dengan internet merupakan syarat utama agar ekosistem IoT dapat berjalan secara optimal. Dalam proses ini, peran manusia lebih difokuskan pada pengawasan, pengaturan, dan pengendalian aktivitas yang dilakukan perangkat. IoT sendiri memiliki beragam penerapan dalam kehidupan sehari-hari yang memberikan kemudahan. Setelah suatu objek memperoleh alamat IP dan terkoneksi dengan internet, objek tersebut dapat dipasang sensor untuk mengumpulkan, mengolah, dan mengirimkan data atau berinteraksi dengan perangkat lain berdasarkan variabel yang diterimanya. Data yang dihasilkan kemudian dapat dimanfaatkan pengguna untuk mengendalikan objek yang terhubung. Hal tersebut yang menjadikan salah satu keunggulan utama dari IoT (Ayu Syahfitri, 2025).

2.3 *Random Forest*

Random Forest adalah metode yang dapat meningkatkan akurasi dalam menghasilkan atribut untuk setiap *node* yang dilakukan secara acak. Algoritma *Random Forest* terdiri dari kumpulan pohon keputusan, di mana kumpulan pohon keputusan ini digunakan untuk mengklasifikasikan data ke dalam kelas tertentu. Pohon keputusan dibangun dengan terlebih dahulu mengidentifikasi *node* akar dan kemudian berakhir dengan beberapa *node* daun untuk menghasilkan hasil yang diinginkan (Fikry dkk., 2025; Fathurrahman dkk., 2025).

Seperti yang dinyatakan oleh Amaliah dkk. (2022), *Random Forest* mampu membangun pohon keputusan yang serupa dengan yang dibentuk oleh *Classification and Regression Tree*. Berbeda dengan model CART, model *Random Forest* tidak menjalani proses pemangkasan. Indeks Gini adalah ukuran statistik yang digunakan untuk menilai ketidaksetaraan ekonomi, dan digunakan dalam proses seleksi. Setiap *node* internal pada pohon keputusan memiliki kumpulan fitur tertentu. Indeks Gini dapat dihitung sebagai berikut:

$$\text{Gini}(S_i) = 1 - \sum_{i=0}^{c-1} p_i^2 \dots\dots\dots(2.1)$$

Dengan P_i adalah frekuensi relative kelas C_i di dalam set. C_i adalah kelas untuk $i = 1, \dots, c-1$, dan c adalah jumlah kelas yang ditentukan.

Kualitas fitur k dibagi menjadi subset S_i , yang didefinisikan sebagai jumlah sampel yang termasuk dalam kelas C_i . Perhitungan ini diperoleh dengan menjumlahkan pertimbangan indeks Gini dari subset yang dihasilkan. Perhitungan data dapat dilakukan menggunakan rumus berikut:

$$\text{Gini}_{split} = 1 - \sum_{i=0}^{k-1} \left(\frac{n_i}{n}\right) \text{Gini}(S_i) \dots\dots\dots(2.2)$$

Dimana n_i merupakan jumlah sampel dalam subset S_i setelah di split dan n merupakan jumlah sampel di *node* yang diberikan.

Misalkan $\{h(x, \Theta_k), k = 1, \dots\}$ dimana $\{\Theta_k\}$ adalah vector random yang *independent identically distributed* (iid) dan setiap pohon memilih kelas yang lebih dari rata rata (*majority vote*).


2.4 Mikrokontroler

Mikrokontroler adalah sebuah chip yang memiliki CPU (*Central Processing Unit*), RAM (*Random Access Memory*), ROM (*Read Only Memory*), *Input dan output*, *counter timer*, dan serial. Komunikasi *port* yang mendukung pengembangan aplikasi kendali serta aplikasi umum atau serbaguna. Komputer kecil yang dirangkai dalam bentuk IC (*Integrated Chip*) disebut mikrokontroler. IC memiliki kemampuan untuk melakukan tugas atau operasi tertentu (Junaedi dkk., 2021). Selain disebut sebagai memori program, ROM mempertahankan isinya meskipun IC kehilangan catu daya, sementara RAM adalah kebalikannya. Isi RAM akan hilang ketika IC kehilangan catu daya. Mikrokontroler biasanya memiliki beberapa komunikasi serial, seperti:

1. UART (*Universal Asynchronous Receiver Transmitter*) sebagai *port* komunikasi data secara asinkron.
2. USART (*Universal Synchronous Asynchronous Receiver Transmitter*) merupakan *port* komunikasi yang mendukung mode sinkron maupun asinkron, serta mampu bekerja dengan kecepatan hingga 16 kali lebih tinggi dibandingkan UART.
3. SPI (*Serial Port Interface*) adalah protokol komunikasi serial yang umum digunakan untuk pertukaran data berkecepatan tinggi.
4. SCI (*Serial Communication Interface*) merupakan antarmuka yang digunakan dalam komunikasi data secara serial.
5. I2C (*Inter-Integrated Circuit*) Bus adalah sistem komunikasi dua jalur yang umum dipakai untuk pengiriman data 8-bit, terdiri dari jalur SDA (*Serial Data Line*) sebagai jalur data dan SCL (*Serial Clock Line*) sebagai jalur sinkronisasi/clock.
6. CAN (*Control Area Network*) adalah standar jaringan komunikasi yang dikembangkan oleh SAE (*Society of Automotive Engineers*) (Zulfa dkk., 2021).

2.5 Node MCU (ESP8266)

Node MCU atau ESP8266 merupakan sebuah *board* elektronika berbasis chip ESP8266 yang memiliki kemampuan menjalankan fungsi mikrokontroler sekaligus menyediakan konektivitas internet melalui modul WiFi. *Board* ini dilengkapi dengan sejumlah pin *Input/Output* (I/O) yang memungkinkan pengembang untuk merancang berbagai aplikasi monitoring maupun *controlling* pada proyek *Internet of Things* (IoT).




Gambar 2.2 Pinout Node MCU (ESP8266)
Sumber: Satria (2022)

Node MCU ESP8266 sendiri merupakan pengembangan dari modul ESP8266 tipe ESP-12 yang banyak digunakan pada *platform* IoT (Satria, 2022). Selain itu, *Node MCU* dapat diprogram menggunakan *compiler* Arduino melalui perangkat lunak Arduino IDE, sehingga memudahkan proses pengembangan dan implementasi sistem (Ibrahim & Setiyadi, 2021).

Fitur-fitur yang dimiliki *Node MCU* umumnya serupa dengan modul ESP-12, di antaranya: 10 *port* GPIO (D0–D10), dukungan PWM, antarmuka I2C dan SPI, antarmuka 1-Wire, serta ADC. *Board* ini juga mampu mengendalikan berbagai jenis display seperti LCD, OLED, hingga VGA, dan telah tersedia lebih dari 40 modul fungsional yang dapat dimanfaatkan sesuai kebutuhan pengembang. *Node MCU* ESP8266 bekerja pada tegangan 3.3V serta mendukung tiga mode WiFi, yaitu *Station*, *Access Point*, dan keduanya sekaligus. Dengan kelengkapan fitur tersebut, *Node MCU* dapat berfungsi sebagai perangkat mandiri tanpa memerlukan mikrokontroler tambahan, karena telah memiliki seluruh kemampuan dasar layaknya sebuah mikrokontroler (Suryana, 2021).

2.6 MPU6050

Sensor MPU6050 merupakan Sensor yang mampu mengukur kemiringan sudut dengan memanfaatkan data yang dikumpulkan dari sensor akselerometer dan giroskop.



Gambar 2.3 Sumbu Sensor MPU6050


Sumber: <https://github.com/ElectronicCats/mpu6050/wiki>

Sensor ini juga dilengkapi dengan sensor suhu yang mampu memantau suhu lingkungan sekitar. Jalur data yang digunakan oleh sensor ini adalah jalur data I2C. Sensor MPU-6050 dilengkapi dengan akselerometer *Micro-Electro-Mechanical Systems* (MEMS) dan giroskop MEMS yang terintegrasi satu sama lain. Ketepatan sensor yang ditingkatkan disebabkan oleh penggunaan konverter analog-ke-digital (ADC) 16-bit untuk setiap kanal. Sensor ini mampu menangkap nilai sumbu X, Y, dan Z secara bersamaan (Kaladewa & Santoso 2022; Maulana dkk., 2025).

MPU6050 dilengkapi dengan tiga sensor yang berbeda, yaitu *gyroscope*, *accelerometer*, dan *thermometer*. Sensor-sensor ini memiliki berbagai aplikasi yang luas, sehingga menjadikan MPU6050 multifungsi. Di bidang industri, *accelerometer* dan *gyroscope* digunakan dalam pesawat terbang dan kendaraan bermotor, di mana keduanya sangat penting untuk menjaga keseimbangan. *Accelerometer* dan *gyroscope* terintegrasi dalam satu chipset MPU6050, sehingga memungkinkan penggabungan data dari kedua sensor untuk mendapatkan nilai gerak linier dan rotasi yang lebih akurat dan konsisten pada suatu objek. Selain digunakan sebagai pengukuran sudut untuk keseimbangan, sensor ini juga dapat diterapkan dalam pembuatan model tiga dimensi (Rahman dkk. 2022).

2.7 BMP280

Sensor BMP280 merupakan sensor tekanan atmosfer digital yang dikembangkan oleh Bosch Sensortec dan banyak digunakan untuk pengukuran tekanan serta suhu pada berbagai sistem tertanam dan aplikasi IoT.



Gambar 2.4 BMP280

Sumber: <https://forum.arduino.cc/t/multiple-bmp280-sensors-with-uno-via-spi>

Sensor ini bekerja pada rentang tekanan sekitar 300 hingga 1100 hPa dan menggunakan teknologi piezoresistif, di mana perubahan tekanan akan menyebabkan perubahan resistansi pada elemen sensor. Perubahan tersebut kemudian diproses oleh rangkaian application-specific integrated circuit (ASIC) internal untuk dikonversi dari sinyal analog menjadi data digital yang dapat dibaca oleh mikrokontroler melalui antarmuka I2C atau SPI. Ukurannya yang kecil, konsumsi daya rendah, serta kestabilan pembacaan menjadikan BMP280 sesuai untuk sistem yang membutuhkan pemantauan tekanan secara kontinu (Kusuma dkk., 2023).

Dalam implementasinya, BMP280 banyak digunakan pada sistem stasiun cuaca, altimeter, serta sistem otomasi berbasis mikrokontroler dan komputer mini. Sensor ini mampu memberikan data tekanan yang cukup akurat, meskipun pada kondisi tertentu masih dapat dipengaruhi oleh *noise* sehingga diperlukan proses kalibrasi atau pengolahan lanjutan untuk meningkatkan akurasi pembacaan. Penggunaan BMP280 pada sistem cuaca berbasis Raspberry Pi maupun mikrokontroler menunjukkan bahwa sensor ini efektif dalam mendukung pemantauan kondisi atmosfer secara *real-time* dan terintegrasi dengan platform berbasis web atau *dashboard* digital (Nekwek dkk., 2024).

2.8 Piezo Buzzer

Buzzer adalah komponen elektroakustik yang berfungsi sebagai transduser, sehingga mengubah energi listrik menjadi energi suara melalui prinsip induksi elektromagnetik.



Gambar 2.5 Piezo buzzer

Sumber: <https://www.eitkw.com/product/piezo-buzzer/>

Mekanisme operasional dasar *buzzer* mirip dengan speaker konvensional, di mana komponen tersebut terdiri dari kumparan kawat yang terpasang pada membran diafragma. Ketika arus listrik diterapkan pada kumparan, kumparan berfungsi sebagai elektromagnet, berinteraksi dengan medan magnet permanen, dan menghasilkan gaya Lorentz. Gaya ini menyebabkan gerakan translasi pada kumparan. Gerakan translasi kumparan kemudian diteruskan ke diafragma, menyebabkan diafragma bergetar secara periodik pada frekuensi tertentu. Getaran mekanis diafragma berfungsi sebagai katalisator untuk pembentukan gelombang tekanan, yang kemudian manifestasi sebagai gelombang suara yang dapat didengar (Kiswantono & Irwan, 2024). Menurut penelitian terbaru, komponen yang dimaksud disebut sebagai *piezo buzzer* atau *piezo speaker*. Komponen ini memiliki karakteristik fisik berdiameter sekitar 1 sentimeter dan mampu menghasilkan tingkat tekanan suara sekitar 9 dB (Sinuhaji, 2023). Prinsip kerja ini didasarkan pada fenomena piezoelektrik, di mana bahan piezokeramik mengalami deformasi mekanis saat tegangan listrik diterapkan, sehingga menghasilkan gelombang suara melalui getaran molekul udara.

2.9 Baterai Lithium-ion

Baterai *lithium-ion* merupakan salah satu jenis baterai yang paling banyak digunakan pada kendaraan listrik maupun berbagai perangkat elektronik modern karena densitas energinya yang tinggi dan efisiensinya yang baik.



Gambar 2.6 Baterai *Lithium-ion*

Sumber: <https://motoma.com/id/cylindrical-lithium-battery>

Pada baterai *lithium-ion*, material elektrode aktif yang digunakan terdiri atas *lithium metal oxide* sebagai elektrode positif dan karbon sebagai elektrode negatif. Kedua material tersebut dikombinasikan dengan arus kolektor berbahan logam dan bahan pengikat seperti *polyvinylidene fluoride* (PVDF) atau kopolimer *polyvinylidene fluoride-hexafluoropropylene* (PVDF-HFP), serta ditambahkan pengencer konduktif untuk meningkatkan performa elektrokimia (Hilal dkk., 2023). Salah satu tipe baterai *lithium-ion* yang populer adalah baterai 18650, yang penamaannya merujuk pada ukuran fisiknya berbentuk silinder: angka “18” menunjukkan diameter 18 mm, sedangkan angka “650” menunjukkan tinggi 65,0 mm, dengan angka “0” sebagai toleransi ukuran sesuai standar produksi. Baterai 18650 memiliki tegangan kerja nominal sebesar 3,7 volt, dapat diisi hingga 4,2 volt, dan dianggap kosong pada tegangan sekitar 3,0 volt. Kapasitas penyimpanan arus listriknya bervariasi tergantung pabrikan, namun secara umum tipe ini memiliki kapasitas maksimum mencapai 3.600 mAh (Saputra & Yulianti, 2021).

2.10 Ekstraksi Fitur

Ekstraksi fitur merupakan tahap penting dalam pengolahan data sensor karena data mentah perlu diubah menjadi representasi yang lebih informatif agar pola gerakan dapat dikenali oleh model klasifikasi. Proses tersebut sejalan dengan pendekatan *feature engineering* yang menekankan pentingnya penyesuaian data, penghilangan nilai tidak valid, serta pembentukan fitur turunan untuk meningkatkan konsistensi data dan stabilitas model *machine learning* (Alfarezy dkk., 2026). Berdasarkan hal tersebut, fitur yang digunakan pada penelitian ini mencakup magnitudo akselerometer, magnitudo giroskop, sudut kemiringan, selisih antar sensor, serta *Rolling Feature* yang masing-masing berperan dalam merepresentasikan intensitas gerakan, orientasi tubuh, perbedaan antarsegmen tubuh, dan variasi sinyal dalam jendela waktu tertentu.

2.10.1 Magnitudo Akselerometer

Magnitudo akselerometer merupakan fitur yang digunakan untuk merepresentasikan besar percepatan total dari sensor tanpa mempertimbangkan arah pada masing-masing sumbu. Fitur ini diperoleh dengan menggabungkan komponen percepatan pada sumbu X, Y, dan Z menjadi satu nilai skalar sehingga intensitas gerakan tubuh dapat ditangkap secara lebih ringkas. Pada penelitian berbasis sensor inersia, penggunaan magnitudo banyak dimanfaatkan untuk memperkuat representasi gerakan dan memudahkan proses klasifikasi karena informasi tiga sumbu telah dirangkum menjadi satu parameter utama (Guo et al., 2024; Rafiq et al., 2025).

Magnitudo akselerometer dihitung menggunakan Persamaan.

$$acc_mag_i = \sqrt{axi^2 + ayi^2 + azi^2} \dots\dots\dots (2.3)$$

Dimana: acc_mag_i = Magnitudo total percepatan pada sensor ke-i.

axi = Nilai percepatan pada sumbu X sensor ke-i.

ayi = Nilai percepatan pada sumbu Y sensor ke-i.

azi = Nilai percepatan pada sumbu Z sensor ke-i.

i = Nomor sensor yang digunakan, yaitu sensor 1 atau sensor 2.

2.10.2 Magnitudo Girooskop

Magnitudo girooskop digunakan untuk merepresentasikan besar kecepatan sudut total yang dihasilkan oleh sensor girooskop. Fitur ini menggabungkan komponen kecepatan sudut pada sumbu X, Y, dan Z sehingga informasi mengenai rotasi tubuh dapat dirangkum dalam satu nilai. Penggunaan magnitudo girooskop umum diterapkan pada analisis gerakan berbasis *wearable* sensor karena mampu menangkap karakteristik rotasi tubuh secara lebih stabil dan informatif (Guo et al., 2024; Rafiq et al., 2025).

Magnitudo girooskop dihitung menggunakan Persamaan.

$$gyro_mag_i = \sqrt{gxi^2 + gyi^2 + gzi^2} \dots\dots\dots (2.4)$$

Dimana: $gyro_mag_i$ = Magnitudo total percepatan pada sensor ke-i.

gxi = Nilai percepatan pada sumbu X sensor ke-i.

gyi = Nilai percepatan pada sumbu Y sensor ke-i.

gzi = Nilai percepatan pada sumbu Z sensor ke-i.

i = Nomor sensor yang digunakan, yaitu sensor 1 atau sensor 2.

2.10.3 Sudut Kemiringan

Sudut kemiringan atau orientasi tubuh digunakan untuk menggambarkan posisi sensor terhadap gravitasi. Pada penelitian ini, orientasi tubuh direpresentasikan melalui sudut *roll* dan *pitch* yang dihitung dari data akselerometer tiga sumbu. Fitur ini penting karena perubahan postur tubuh selama aktivitas pengangkatan beban umumnya ditunjukkan oleh perubahan sudut kemiringan pada punggung. Estimasi orientasi berbasis sensor inersia juga telah digunakan untuk menggambarkan perubahan posisi tubuh dan sudut relatif antarsegmen tubuh selama aktivitas gerakan (Song et al., 2022).

Sudut *roll* dihitung menggunakan Persamaan.

$$roll_i = \arctan 2 \left(ayi, \sqrt{axi^2 + azi^2} + 10^{-9} \right) \dots\dots\dots (2.5)$$

Sedangkan sudut *pitch* dihitung menggunakan Persamaan.

$$pitch_i = \arctan 2 \left(-axi, \sqrt{ayi^2 + azi^2} + 10^{-9} \right) \dots\dots\dots (2.6)$$

Dimana: $roll_i$ = Sudut *roll* sensor ke-i yang menggambarkan kemiringan lateral

sensor.

$pitch_i$ = Sudut *pitch* sensor ke-(i) yang menggambarkan kemiringan longitudinal sensor.

ax_i = Nilai percepatan sumbu X sensor ke-i

ay_i = Nilai percepatan sumbu Y sensor ke-i

az_i = Nilai percepatan sumbu Z sensor ke-i

10^{-9} = Konstanta kecil untuk menghindari pembagian dengan nol.

i = Nomor sensor (1 atau 2).

2.10.4 Selisih Antar Sensor

Selisih antar sensor digunakan untuk menggambarkan perbedaan gerakan dan orientasi antara sensor yang ditempatkan pada bagian *thoracic* dan lumbar. Fitur ini penting karena teknik pengangkatan beban yang tidak ergonomis sering menghasilkan perbedaan sudut dan gerakan yang lebih besar antara punggung bagian atas dan bawah. Dalam studi berbasis dua IMU, sudut relatif antar sensor dapat diperoleh melalui selisih orientasi masing-masing sensor sehingga hubungan gerakan antarsegmen tubuh dapat diketahui (Song et al., 2022).

Selisih akselerometer dihitung menggunakan Persamaan.

$$diff_ax = ax1 - ax2, \dots\dots\dots (2.7)$$

$$diff_ay = ay1 - ay2, \dots\dots\dots (2.8)$$

$$diff_az = az1 - az2 \dots\dots\dots (2.9)$$

Dimana: $diff_ax$ = Selisih percepatan sumbu X antara kedua sensor.

$diff_ay$ = Selisih percepatan sumbu Y antara kedua sensor.

$diff_az$ = Selisih percepatan sumbu Z antara kedua sensor.

ax_1, ay_1, az_1 = Data akselerometer sensor 1.

ax_2, ay_2, az_2 = Data akselerometer sensor 2.

Selisih giroskop dihitung menggunakan Persamaan.

$$diff_gx = gx1 - gx2, \dots\dots\dots (2.10)$$

$$diff_gy = gy1 - gy2, \dots\dots\dots (2.11)$$

$$diff_gz = gz1 - gz2 \dots\dots\dots (2.12)$$

Dimana: $diff_gx$ = Selisih kecepatan sudut sumbu X antara kedua sensor.
 $diff_gy$ = Selisih kecepatan sudut sumbu Y antara kedua sensor.
 $diff_gz$ = Selisih kecepatan sudut sumbu Z antara kedua sensor.
 gx_1, gy_1, gz_1 = Data giroskop sensor 1.
 gx_2, gy_2, gz_2 = Data giroskop sensor 2.

Selisih sudut antar sensor dihitung menggunakan Persamaan.

$$diff_roll = roll1 - roll2 \dots\dots\dots(2.13)$$

$$diff_pitch = pitch1 - pitch2 \dots\dots\dots(2.14)$$

Dimana: $diff_roll$ = Selisih sudut *roll* antara sensor *thoracic* dan lumbar.
 $diff_pitch$ = Selisih sudut *pitch* antara sensor *thoracic* dan lumbar.
 $roll1, roll2$ = Sudut *roll* pada sensor 1 dan sensor 2.
 $pitch1, pitch2$ = Sudut *pitch* pada sensor 1 dan sensor 2.

2.10.5 Rolling Feature

Rolling Feature merupakan fitur statistik berbasis deret waktu yang digunakan untuk menangkap pola lokal dari sinyal sensor. Fitur ini mampu menggambarkan kecenderungan dan variasi data dalam jendela waktu tertentu sehingga perubahan gerakan yang terjadi secara berkelanjutan dapat direpresentasikan dengan lebih baik. Pendekatan jendela geser (*rolling window*) juga umum digunakan dalam analisis deret waktu untuk memperoleh informasi statistik lokal yang mendukung proses klasifikasi (Dimoudis et al., 2023).

Rolling mean dihitung menggunakan Persamaan.

$$x_t^{rm3} = \frac{x_t + x_{t-1} + x_{t-2}}{3} \dots\dots\dots(2.15)$$

Dimana: x_t^{rm3} = Nilai rata-rata bergerak (*rolling mean*) pada window 3 data.
 x_t = Nilai data pada waktu ke-t.
 x_{t-1} = Nilai data satu langkah sebelumnya.
 x_{t-2} = Nilai data dua langkah sebelumnya.
3 = Ukuran jendela pengamatan (*window size*).

Rolling Standar Deviasi dihitung menggunakan Persamaan.

$$x_t^{rs3} = \sqrt{\frac{\sum_{i=1}^3 (x_i - \bar{x})^2}{3-1}} \dots\dots\dots (2.16)$$

Dimana: x_t^{rs3} = Nilai standar deviasi bergerak dalam *window* 3 data.

x_i = Nilai data ke-i dalam *window* pengamatan.

$\bar{x}$ = Nilai rata-rata dari data pada *window*.

3 = Jumlah data dalam *window*.

3 – 1 = Derajat bebas dalam perhitungan standar deviasi sampel.x

2.11 Robust Scaler

Robust Scaler merupakan metode penskalaan data yang menggunakan median dan rentang antarkuartil (*interquartile range*). Metode ini dipilih karena lebih tahan terhadap nilai ekstrem atau pencilan dibandingkan metode penskalaan lainnya. Dalam beberapa studi, *robust scaler* terbukti membantu menjaga kestabilan distribusi data sebelum proses klasifikasi dilakukan (Ahsan et al., 2021; Amorim et al., 2022).

$$X_{scaled} = \frac{X - Q_2}{Q_3 - Q_1} \dots\dots\dots (2.17)$$

Dimana: X_{scaled} = Nilai data setelah diskala.

X = Nilai data asli.

Q_2 = Median dari data

Q_1 = Kuartil pertama

Q_3 = Kuartil ketiga

$Q_3 - Q_1$ = Selisih antara Kuartil ketiga dan kuartil pertama.

2.12 Python

Python adalah bahasa pemrograman tingkat tinggi yang menekankan keterbacaan kode, sehingga memudahkan proses pembelajaran. Python adalah bahasa pemrograman yang dapat dijalankan pada berbagai sistem operasi, termasuk yang dikembangkan oleh Microsoft (Windows), Linux, Google (Android), dan Apple (Mac OS), di antara lainnya. Python diakui sebagai bahasa pemrograman yang secara mulus mengintegrasikan kemampuan dan fungsionalitas dengan sintaks kode yang jelas, serta dilengkapi dengan

fungsionalitas perpustakaan standar yang luas. Oleh sebab itu, jika sebuah program dirancang dalam bahasa ini, program tersebut harus melalui proses sebelum dieksekusi di komputer, yang memakan waktu lebih lama dibandingkan dengan bahasa pemrograman tingkat rendah. Implementasi pemrograman Python difasilitasi oleh interpreter interaktif yang dikenal sebagai Jupyter Notebook, yang diinstal melalui tumpukan perangkat lunak bernama *Anaconda Data Science Platform*. Metode implementasi alternatif juga telah dijelaskan dalam literatur penggunaan PyCharm (Fahmi, 2023).

2.13 Scikit-learn

Scikit-Learn adalah perpustakaan Python yang dikembangkan untuk memudahkan pemrograman *machine learning* dalam Python melalui *Application Programming Interface* (API) yang dikembangkan oleh sejumlah kontributor dari berbagai negara. Perpustakaan ini sering digunakan baik di industri maupun di lingkungan akademis. Dapat dikatakan bahwa perpustakaan scikit-learn memiliki kinerja yang dioptimalkan berkat desainnya yang dibangun di atas modul NumPy (*Numerical Python*) dan SciPy (*Scientific Python*), yang memudahkan perhitungan yang lebih efisien. Namun, keterbatasan yang menonjol dari perpustakaan ini adalah ketidakcocokannya dengan desain big data. Akibatnya, scikit-learn tidak direkomendasikan untuk kasus-kasus semacam itu (Fahmi, 2023).

2.14 Visual Studio Code

Visual Studio Code adalah *editor* kode yang dikembangkan oleh Microsoft dan dapat digunakan pada berbagai sistem operasi, seperti Windows, Linux, dan macOS. Aplikasi ini dirancang untuk memudahkan proses penulisan kode program karena mendukung berbagai bahasa pemrograman serta menyediakan fitur yang membantu pengguna dalam memahami struktur dan fungsi setiap baris kode. Selain itu, Visual Studio Code memiliki kemampuan untuk menambahkan ekstensi, sehingga pengembang dapat memperluas fungsionalitas aplikasi sesuai dengan kebutuhan pengembangan perangkat lunak. Visual Studio Code juga bersifat *open source*, yang memungkinkan pengembang lain dapat berkontribusi dalam penyempurnaan aplikasi tersebut (Juniawan dkk., 2023).

2.15 Arduino IDE

Sebuah *Integrated Development Environment* (IDE) adalah paket perangkat lunak yang menyediakan lingkungan pengembangan yang komprehensif. Arduino menggunakan bahasa pemrograman C/C++. Bahasa pemrograman Arduino, yang menggunakan sketsa, dapat dimodifikasi untuk memudahkan pemrograman dengan cara yang melampaui kompleksitas bahasa C/C++ asli. IDE Arduino dikembangkan menggunakan bahasa pemrograman Java dan dilengkapi dengan perpustakaan C/C++, yang juga dikenal sebagai *wiring*. Implementasi konfigurasi *wiring* yang efektif telah terbukti memudahkan proses *Input* dan *output*. Arduino IDE sendiri dikembangkan dari perangkat lunak *processing* yang telah dimodifikasi menjadi Arduino IDE secara khusus untuk pemrograman Arduino (Ali dkk., 2022).

2.16 Fritzing



Fritzing adalah perangkat lunak yang dapat digunakan untuk belajar elektronika. Fritzing telah terbukti menjadi alat yang sangat efektif pada sistem operasi seperti Linux, Mac, dan Windows (Susanto dkk., 2022). Fritzing juga bersifat *open-source*, artinya pengguna dapat mengakses, memodifikasi, dan mendistribusikannya secara bebas kepada siapa pun. Perangkat lunak ini dikembangkan di Universitas Ilmu Terapan Potsdam. Fritzing membantu penggunaannya dalam bidang *prototyping*, merancang sirkuit berbasis mikrokontroler Arduino, serta merancang atau merakit tata letak PCB (*Printed Circuit Board*) kustom (Mentaruk dkk., 2020).

2.17 Flowchart

Flowchart adalah representasi diagramatis konvensional yang digunakan untuk menggambarkan logika prosedural suatu proses. *Flowchart* menggunakan kombinasi simbol-simbol standar, termasuk kotak proses dan panah, untuk menunjukkan arah alur. Meskipun *flowchart* belum secara resmi dimasukkan ke dalam standar UML, *flowchart* tetap relevan pada tahap awal analisis sistem, berkat kesederhanaan dan kemudahan pemahamannya. *Flowchart* merupakan metode yang sangat efektif untuk memetakan proses operasional, terutama ketika

pemangku kepentingan non-teknis terlibat dalam perencanaan sistem (Pecoraro & Luzi, 2022). Diagram ini sering digunakan untuk menjelaskan proses bisnis atau prosedur administratif yang memerlukan visualisasi yang cepat dan efektif.

Tabel 2.1 Simbol-simbol *Flowchart*

Simbol	Keterangan
	<i>Terminator</i> : permulaan / akhir program.
	Garis alir (<i>flow line</i>): arah aliran program.
	<i>Preparation</i> : proses inisialisasi / pemberian harga awal.
	Proses: proses perhitungan / proses pengolahan data.
	<i>Input/Output data</i> : proses <i>input</i> / <i>output</i> data, parameter, atau informasi.
	<i>Predefined process</i> (sub program): permulaan sub program / proses menjalankan sub program.
	<i>Decision</i> : pertandingan pernyataan, penyelesaian data yang memberikan pilihan untuk langkah selanjutnya.
	<i>On page connector</i> : penghubung bagian-bagian <i>flowchart</i> yang berada pada satu halaman.
	<i>Off page connector</i> : penghubung bagian-bagian <i>flowchart</i> yang berada pada halaman berbeda

2.18 Unified Modeling Language




Unified Modeling Language (UML) adalah kerangka kerja pemodelan visual yang digunakan untuk merancang, merepresentasikan, mengembangkan, dan mendokumentasikan sistem perangkat lunak serta proses bisnis secara sistematis (Koç dkk., 2021). UML terdiri dari berbagai representasi diagram yang menggambarkan struktur, perilaku, dan interaksi dalam suatu sistem (Suwanda, 2024). Dalam konteks analisis dan perancangan sistem, ada beberapa diagram

utama sering digunakan yaitu *use case diagrams* dan *activity diagrams*.

2.18.1 Use Case Diagram

Use case diagram berfungsi untuk menggambarkan hubungan timbal balik antara berbagai aktor yang terlibat dalam sistem yang sedang dikembangkan, yang dapat mencakup pengguna atau sistem eksternal. Diagram ini merupakan alat bantu visual yang berharga dalam memahami fungsi-fungsi utama yang dibutuhkan oleh pengguna, serta batasan-batasan yang melekat pada sistem. Diagram kasus penggunaan telah terbukti menjadi sarana yang sangat efektif untuk membedakan persyaratan fungsional yang mencakup elemen interaktif dan non-interaktif (Iqbal et al., 2020). Dalam bidang pengembangan sistem, diagram ini berfungsi sebagai titik acuan dasar untuk merumuskan skenario dan melakukan pengujian sistem.

Tabel 2.2 Simbol-simbol *Use Case Diagram*

Simbol	Keterangan
	Aktor: mewakili peran orang, sistem yang lain, atau alat ketika berkomunikasi dengan <i>use case</i> .
	<i>Use case</i> : abstraksi dan interaksi antara sistem dan aktor.
	<i>Association</i> : abstraksi dari penghubung antara aktor dengan <i>use case</i> .
	Generalisasi: menunjukkan spesialisasi aktor untuk dapat berpartisipasi dengan <i>use case</i> .
	<<include>>: menunjukkan bahwa suatu <i>use case</i> seluruhnya merupakan fungsionalitas dari <i>use case</i> lainnya.
	<<extend>>: menunjukkan bahwa suatu <i>use case</i> merupakan tambahan fungsional dari <i>use case</i> lainnya jika suatu kondisi terpenuhi.

2.18.2 Sequence Diagram

Sequence diagram adalah alat yang digunakan untuk menggambarkan urutan kronologis interaksi antar objek dalam suatu sistem. Diagram ini menggambarkan mekanisme komunikasi pesan antar objek selama pelaksanaan skenario tertentu, sebagaimana diuraikan dalam *use case diagram*. *Sequence diagram* dianggap sebagai salah satu diagram UML yang paling umum digunakan dalam bidang penelitian perangkat lunak, terutama karena kegunaannya dalam menggambarkan dinamika sistem (Koç dkk., 2021). *Sequence diagram* adalah alat yang berguna untuk memvisualisasikan urutan interaksi antar objek dalam suatu sistem. Selain perannya dalam menggambarkan interaksi ini, diagram urutan juga dapat berfungsi sebagai dasar untuk membuat kasus uji penerimaan dan menilai sejauh mana fungsionalitas sistem telah tercakup secara otomatis. Metode yang digunakan dalam penelitian ini melibatkan konversi diagram urutan menjadi grafik urutan peristiwa, yang memfasilitasi analisis grafik untuk menilai cakupan rangkaian pengujian terhadap alur kasus penggunaan sambil secara otomatis menghasilkan kasus uji baru (Ekici & Tuglular, 2023).

Tabel 2.3 Simbol- simbol *Sequence Diagram*

Simbol	Keterangan
	<i>Actor</i> : orang, proses, atau sistem lain yang berinteraksi dengan sistem informasi yang akan dibuat di luar sistem informasi yang akan dibuat.
	<i>Object</i> : berfungsi sebagai simbol grafis yang merepresentasikan entitas yang terlibat dalam interaksi.
	<i>Entity class</i> : gambaran sistem sebagai landasan dalam menyusun basis data.
	<i>Boundary class</i> : menangani komunikasi antar lingkungan sistem.
	<i>Control class</i> : bertanggung jawab terhadap kelas-kelas terhadap objek yang berisi logika.

Tabel 2.3 Simbol- simbol *Sequence Diagram*

Simbol	Keterangan
	<i>Recursive</i> : pesan untuk dirinya.
	<i>Activation</i> : komponen yang digambarkan garis putus-putus terhubung dengan objek.
	<i>Life line</i> : komponen yang digambarkan garis putus-putus terhubung dengan objek.

2.19 Penelitian Terdahulu

Penelitian terdahulu memberikan dasar penting dalam memahami Sistem Deteksi Posisi Angkat Beban tubuh saat mengangkat beban berbasis *Internet of Things* menggunakan *Random Forest*. Untuk mendukung perancangan Sistem Deteksi Posisi Angkat Beban tubuh saat mengangkat beban berbasis IoT menggunakan *Random Forest*, dibutuhkan pemahaman mengenai penelitian-penelitian yang telah dilakukan sebelumnya. Oleh karena itu, tinjauan ini akan membahas beberapa studi terkait sebagai pijakan pengembangan metode yang digunakan.

Tabel 2.4 Penelitian Terdahulu

No	Nama Peneliti	Judul Penelitian
1	Gee-Sern Jison Hsu, Jie Syuan Wu, Yin-Kai Dean Huang, Chun-Chieh Chiu, Jiunn-Horng Kang (2025)	<i>Automatic Detect Incorrect Lifting Posisie with the Pose Estimation Model</i>

Tabel 2.4 Penelitian Terdahulu (Lanjutan)

No	Nama Peneliti	Judul Penelitian
	Hasil Penelitian: Tujuan penelitian ini adalah mengembangkan Sistem Deteksi Posisi Angkat Beban angkat beban menggunakan model estimasi pose berbasis kamera <i>smartphone</i> dan <i>Long Short-Term Memory</i> (LSTM). Fokus penelitiannya terletak pada klasifikasi posisi angkat yang benar dan salah berdasarkan fitur kinematik dari titik-titik tubuh yang diekstraksi. Meskipun mencapai akurasi tinggi (sekitar 96,9%), penelitian ini memiliki ketergantungan pada kualitas rekaman video dan sudut pandang kamera, serta belum memanfaatkan sensor fisik atau pendekatan berbasis IoT yang dapat memberikan data biomekanik secara langsung dan <i>real-time</i>.	
2	Nama Peneliti	Judul Penelitian
	Sanaz Kianoush, Stefano Savazzi, Vittorio Rampa, Leonardo Costa, Denis Tolochenko (2023)	<i>A Random Forest Approach to Body Motion Detection: Multisensory Fusion and Edge processing</i>
	Hasil Penelitian: Tujuan penelitian ini adalah mengembangkan sistem deteksi gerakan tubuh berbasis IoT dengan menggunakan algoritma <i>Random Forest</i> untuk klasifikasi aktivitas seperti berjalan dan jatuh. Fokus penelitiannya terletak pada fusi multisensor (inframerah dan ultrasonik), ekstraksi fitur menggunakan metode <i>Cumulative Sum Control Chart</i> (CUSUM), serta penerapan model <i>Random Forest</i> untuk perangkat IoT. Meskipun mencapai akurasi sekitar 94% dan efisiensi komputasi tinggi, penelitian ini tidak dirancang untuk mendeteksi posisi mengangkat beban dan tidak menggunakan sensor inersia seperti IMU. Selain itu, skenario eksperimennya terbatas pada deteksi jatuh di ruang tertutup, bukan pada konteks ergonomi kerja atau pengangkatan beban sesuai standar NIOSH.	

Tabel 2.4 Penelitian Terdahulu (Lanjutan)

3	Nama Peneliti	Judul Penelitian
	Jinkun Han, Wei Song, Amanda Gozho, Yunsick Sung, Sumi Ji, Liangliang Song, Long Wen, Qi Zhang (2020)	<i>A Random Forest Approach to Body Motion Detection: Multisensory Fusion and Edge processing</i>
	Hasil Penelitian: Tujuan penelitian ini adalah mengembangkan Sistem Deteksi Posisi Angkat Beban tubuh berbasis IoT menggunakan sensor inersia sembilan sumbu dan teknologi <i>Long Range</i> (LoRa) untuk transmisi data jarak jauh. Fokus penelitiannya terletak pada ekstraksi dan seleksi fitur dari data sensor menggunakan algoritma <i>Random Forest</i> guna mengenali berbagai posisi harian seperti berdiri, berjalan, dan naik-turun tangga, dengan akurasi mencapai 95,06%. Meskipun sistem ini unggul dalam efisiensi energi dan kompatibilitas IoT, penelitian ini tidak secara khusus dirancang untuk mendeteksi posisi mengangkat beban sesuai standar ergonomi. Selain itu, cakupan gerakan yang dianalisis terbatas pada aktivitas umum dan belum mempertimbangkan parameter biomekanik spesifik seperti sudut sendi panggul atau posisi punggung saat mengangkat, yang sangat relevan untuk pencegahan cedera punggung bawah.	
No	Nama Peneliti	Judul Penelitian
4	Milind Rane, Shrihari Mohole, Yash Pahade, Gokul Kurandale, Aditya Munjale (2025)	<i>Automatic Detect Incorrect Lifting Posisie with the Pose Estimation Model</i>

Tabel 2.4 Penelitian Terdahulu (Lanjutan)

No	Nama Peneliti	Judul Penelitian
4	Hasil Penelitian: Penelitian ini mengembangkan sistem pemantauan posisi tubuh berbasis IoT yang memberikan umpan balik untuk membedakan posisi “baik” dan “buruk”. Fokus penelitiannya terletak pada pemanfaatan <i>Convolutional Neural Network</i> (CNN) yang dilatih menggunakan <i>dataset</i> Yoga Poses sebanyak 2.000 data citra, serta integrasi dengan sensor fleksibel, modul Wi-Fi ESP8266, motor getar, dan tampilan LCD untuk memberikan notifikasi <i>real-time</i>. Namun, penelitian ini tidak dirancang khusus untuk mendeteksi posisi saat mengangkat beban dan tidak mempertimbangkan parameter biomekanik ergonomis. Selain itu, akurasi yang relatif rendah (75,52%) serta ketergantungan pada data citra dua dimensi mengurangi keandalannya dalam skenario kerja fisik dinamis seperti pengangkatan beban berat.	
No	Nama Peneliti	Judul Penelitian
5	Muhammad Ghaly Alghifari, Dahnial Syauqy, Rekyan Regasari Mardi Putri (2024)	Sistem <i>Wearable</i> Deteksi Posisi Pada Pelatihan Otot <i>Biceps</i> Dan <i>Triceps</i> Berbasis Angkat Beban Dengan Algoritma <i>Random Forest</i>
	Hasil Penelitian: Tujuan penelitian ini adalah mengembangkan sistem <i>wearable</i> untuk mendeteksi kebenaran gerakan pada latihan angkat beban menggunakan <i>dumbbell</i>. Fokus penelitiannya terletak pada pemanfaatan data akselerometer dan giroskop dari sensor MPU6050 yang dipasang di pergelangan tangan, lengan atas, dan dada, serta klasifikasi gerakan menggunakan algoritma <i>Random Forest</i> dengan akurasi mencapai 96,3% pada model dan 85–91% pada pengujian sistem. Meskipun sistem ini menunjukkan kinerja yang baik dalam latihan kebugaran terkontrol, penelitian ini tidak dirancang untuk mendeteksi posisi mengangkat beban secara ergonomis dan tidak mempertimbangkan parameter biomekanik seperti sudut punggung atau posisi panggul saat mengangkat objek berat.	

Tabel 2.4 Penelitian Terdahulu (Lanjutan)

No	Nama Peneliti	Judul Penelitian
6	Muhammad Fikry, Bustami, Ella Suzanna (2025)	<i>IOT-Based Environmental Monitoring and Its Implications For Student Mental Health</i>
	Hasil Penelitian: Penelitian ini bertujuan menginvestigasi dampak kondisi lingkungan kelas terhadap kesehatan mental siswa melalui sistem <i>Internet of Things</i> (IoT) yang terintegrasi. Fokus penelitiannya terletak pada pemantauan parameter lingkungan seperti suhu, kelembaban, dan kebisingan menggunakan sensor IoT, serta korelasinya dengan gejala kecemasan dan depresi yang diukur melalui <i>Hopkins Symptom Checklist</i> pada 267 siswa. Meskipun penelitian ini menggunakan algoritma <i>Random Forest</i> untuk analisis data dan menunjukkan akurasi tinggi dalam prediksi, sistem tersebut memiliki keterbatasan karena tidak dirancang khusus untuk mendeteksi posisi tubuh saat mengangkat beban dan tidak mempertimbangkan parameter biomekanik spesifik seperti sudut sendi atau posisi punggung yang relevan untuk pencegahan cedera kerja. Selain itu, penelitian ini tidak mengacu pada standar ergonomi seperti NIOSH dalam menganalisis posisi mengangkat beban.	
No	Nama Peneliti	Judul Penelitian
7	Munirul Ula, Suriah, Veri Ilhadi, Zailani Mohamed Sidek (2025)	<i>Comparing Long Short-Term Memory and Random Forest Accuracy for Bitcoin Price Forecasting</i>
	Hasil Penelitian: Penelitian ini bertujuan membandingkan akurasi metode <i>Long Short-Term Memory</i> (LSTM) dan <i>Random Forest</i> dalam melakukan prediksi berdasarkan data <i>time series</i>. Fokus penelitiannya terletak pada penerapan kedua algoritma <i>machine learning</i> tersebut untuk memprediksi pergerakan harga Bitcoin menggunakan <i>dataset</i> harian selama dua tahun	

Tabel 2.4 Penelitian Terdahulu (Lanjutan)

No	Nama Peneliti	Judul Penelitian
7		dengan evaluasi berdasarkan <i>Mean Absolute Percentage Error</i> (MAPE). Meskipun penelitian ini menunjukkan bahwa <i>Random Forest</i> memiliki keunggulan dalam hal kecepatan komputasi dan penggunaan sumber daya dibandingkan LSTM, metode ini memiliki keterbatasan dalam menangkap pola berurutan yang kompleks pada data time series sehingga menghasilkan akurasi yang lebih rendah. Keterbatasan ini menjadi relevan untuk diperhatikan dalam pengembangan Sistem Deteksi Posisi Angkat Beban tubuh belakang yang juga memanfaatkan data berurutan dari sensor IoT dan membutuhkan akurasi tinggi untuk mengidentifikasi posisi tubuh yang berisiko saat mengangkat beban.

BAB III


METODE PENELITIAN

3.1 Tempat dan Waktu Pelaksanaan Penelitian

Penelitian ini dilakukan di ruang lingkup Universitas Malikussaleh. Waktu pelaksanaan penelitian terhitung dari bulan November 2025 sampai dengan Maret 2026 yang meliputi berbagai macam aspek berupa studi kepustakaan, perancangan sistem, implementasi sistem, analisis dan evaluasi sistem, serta penyusunan proposal.

3.2 Langkah Penelitian

Langkah penelitian ini menjelaskan alur sistematis dalam pelaksanaan penelitian Sistem Deteksi Posisi Angkat Beban, yang terdiri atas enam tahapan utama sebagaimana ditunjukkan pada Gambar 31.



Gambar 3.1 Langkah Penelitian Sistem Deteksi Posisi Angkat Beban

Proses penelitian dimulai dari tahap perancangan sistem, dilanjutkan dengan pengumpulan data, *preprocessing*, pemodelan, pengujian, hingga integrasi sistem secara keseluruhan.

3.2.1 Perancangan Alat Deteksi Posisi Angkat Beban

Alat deteksi posisi Angkat Beban merupakan sistem berbasis *Internet of Things* yang dirancang untuk mengumpulkan data gerakan tubuh secara *real-time* guna mendeteksi postur pengguna saat mengangkat beban. Sistem ini terdiri atas tiga sensor utama, yaitu dua unit sensor MPU6050 yang dipasang pada punggung bagian atas (*thoracic*) dan punggung bagian bawah (*lumbar*), serta satu sensor tekanan BMP280 yang berfungsi sebagai pendukung estimasi ketinggian atau perubahan posisi vertikal tubuh. Data dari kedua sensor MPU6050 diproses oleh satu mikrokontroler *Node MCU ESP8266*, sedangkan data dari sensor BMP280 diproses oleh mikrokontroler *Node MCU ESP8266* lainnya. Selain itu, sistem dilengkapi dengan sebuah *Piezo buzzer* yang berfungsi sebagai aktuator suara untuk memberikan umpan balik langsung kepada pengguna apabila terdeteksi posisi angkat beban yang tidak benar.

Secara fungsional, sistem ini berperan sebagai sumber data biomekanik yang akurat dan andal untuk proses klasifikasi postur melalui algoritma *Random Forest*. *Output* dari sistem tidak hanya berupa data digital yang dikirim ke server untuk visualisasi dan analisis lebih lanjut, tetapi juga berupa peringatan audio instan melalui *buzzer*, sehingga memungkinkan pengguna melakukan koreksi postur secara langsung selama aktivitas pengangkatan beban berlangsung. Dengan demikian, sistem ini diharapkan mampu berkontribusi dalam pencegahan cedera muskuloskeletal akibat postur kerja yang tidak sesuai prinsip ergonomi.

3.2.2 Pengumpulan Data

Pengumpulan data dilakukan melalui serangkaian prosedur terstruktur untuk memastikan kualitas, konsistensi, dan keabsahan data yang diperoleh. Adapun tahapan pengumpulan data secara sistematis adalah sebagai berikut:

1. Persiapan lokasi: Menyiapkan area pengujian dengan kondisi lingkungan yang terkontrol.
2. Penyampaian tata cara: Memberikan instruksi kepada partisipan mengenai teknik pengangkatan beban yang benar sebagai dasar posisi ergonomis.
3. Persetujuan partisipan: Mengisi *informed consent* sebelum memulai

pemasangan perangkat.

4. Pemasangan alat: Memasang *Node* MCU dan sensor MPU6050 pada titik pengukuran pada pinggang menggunakan velcro.
5. Proses pengambilan data: Merekam data gerakan saat partisipan melakukan pengangkatan dengan posisi benar dan salah.
6. Pelepasan alat dan pembersihan area: Melepas perangkat dan merapikan area setelah sesi pengumpulan data selesai.
7. Pelabelan Data: Pelabelan dilakukan dengan cara melihat rekaman video lalu memberikan label sesuai dengan posisi benar dan salah saat partisipan melakukan gerakan.

3.2.3 *Preprocessing*

Data mentah yang diperoleh dari sensor MPU6050 tidak dapat langsung digunakan untuk pelatihan model karena masih mengandung *noise*, perbedaan skala, dan variasi sinyal yang tidak terstruktur. Oleh karena itu, data perlu melalui beberapa tahapan *preprocessing* agar lebih representatif dan siap untuk diklasifikasikan. Tahapan *preprocessing* yang dilakukan meliputi pembersihan data, penambahan fitur turunan, serta standarisasi data. Setiap tahap memiliki fungsi spesifik dan berperan penting dalam meningkatkan kualitas data masukan untuk algoritma *Random Forest*. Adapun penjelasan dari setiap tahapan adalah sebagai berikut:

1. Pembersihan Data

Pembersihan data adalah proses menghilangkan data yang tidak relevan dan menangani nilai yang hilang agar kumpulan data menjadi lebih konsisten dan siap digunakan pada tahap berikutnya. Data yang tidak berhubungan langsung dengan proses klasifikasi, seperti informasi identitas peserta dan cap waktu, dihilangkan karena tidak berkontribusi pada proses prediksi postur. Selanjutnya, semua data sensor dikonversi ke dalam format numerik untuk diproses oleh model *Random Forest*. Jika terdeteksi adanya nilai yang hilang, sistem akan menggunakan nilai median dari setiap kumpulan data sensor untuk memastikan stabilitas distribusi data. Selanjutnya, data yang

berisi nilai kosong akan dihilangkan untuk mencegah gangguan dalam proses pelatihan model. Pada tahap ini, pembersihan label data juga dilakukan untuk memastikan format yang seragam dan konsisten.

2. *Feature Engineering*

Feature Engineering adalah proses memperoleh informasi tambahan dari data sensor mentah, dengan tujuan meningkatkan akurasi model klasifikasi dalam mengenali pola gerakan tubuh. Fitur-fitur yang ditambahkan meliputi perhitungan besaran percepatan dan besaran giroskop guna memberikan gambaran komprehensif mengenai besaran gerakan tubuh. Selain itu, selisih nilai sensor dihitung untuk mengidentifikasi perbedaan gerakan antara punggung bagian atas dan bawah. Sistem ini juga mampu menghitung sudut kemiringan tubuh, termasuk *roll* dan *pitch*, untuk menggambarkan perubahan posisi tubuh selama angkat beban. Fitur-fitur ini membantu sistem dalam mengidentifikasi pola gerakan berkelanjutan, sehingga meningkatkan kemampuan model untuk membedakan antara posisi benar dan salah.

3. Standarisasi Data (*Scaling*)

Standarisasi adalah proses penyelarasan rentang nilai di seluruh fitur sehingga seluruh data berada pada skala yang dapat dibandingkan. Dalam penelitian ini, metode *RobustScaler* digunakan karena keunggulannya dalam menangani data *outlier*. Standarisasi dilakukan secara eksklusif pada data pelatihan, dengan hasil transformasi kemudian diterapkan pada data uji untuk mencegah kebocoran data. Standarisasi memfasilitasi kemampuan model untuk mengenali pola dalam data dengan lebih efektif, tanpa terganggu oleh variasi satuan atau rentang nilai yang melekat pada fitur sensor.

3.2.4 **Pemodelan *Random Forest***

Model klasifikasi *Random Forest* dikembangkan melalui beberapa tahapan untuk memastikan bahwa sistem mampu membedakan posisi benar dan salah secara akurat. Setiap tahapan memiliki fungsi yang saling berkaitan, mulai dari

persiapan *dataset* hingga pelatihan model. Adapun penjelasan dari masing-masing tahap adalah sebagai berikut:

1. Pembagian Data

Pembagian data merupakan proses memisahkan *dataset* menjadi dua bagian utama, yaitu data *training* dan data *testing*. Tujuan utamanya adalah untuk menyediakan data khusus yang hanya digunakan untuk evaluasi model, sehingga hasil pengujian lebih objektif dan tidak bias. Cara kerjanya dilakukan dengan memisahkan sebagian data sebagai data training yang digunakan untuk membangun model, sementara 30% sisanya digunakan sebagai data testing untuk menguji seberapa baik model menggeneralisasi pola posisi yang belum pernah dilihat sebelumnya. Proses ini penting untuk mencegah *overfitting* sekaligus menilai performa model terhadap data nyata.

2. *Hyperparameter tuning* (Penyetelan *Hyperparameter*)

Hyperparameter tuning adalah proses memilih nilai terbaik untuk parameter utama *Random Forest*, seperti jumlah pohon dan kedalaman maksimal pohon keputusan. *Hyperparameter* harus ditentukan sebelum pelatihan dilakukan. Cara kerjanya menggunakan teknik *cross-validation*, di mana beberapa kombinasi *Hyperparameter* diuji pada sejumlah subset data untuk mendapatkan performa rata-rata terbaik. Dengan cara ini, model dapat memperoleh konfigurasi yang mampu meningkatkan akurasi tanpa menyebabkan *overfitting*.

3. Pelatihan Model

Pelatihan model adalah tahap ketika algoritma *Random Forest* mempelajari pola dari data yang telah diproses melalui proses sebelumnya. Dalam tahap ini, model membangun kumpulan pohon keputusan berdasarkan fitur-fitur yang diekstraksi dari sensor MPU6050 dan BMP280. Cara kerjanya, *Random Forest* membuat banyak pohon secara acak, lalu setiap pohon menghasilkan prediksi sendiri. Prediksi akhir diperoleh dari voting mayoritas seluruh pohon. Melalui proses ini, model dapat mempelajari perbedaan karakteristik antara posisi benar dan salah sehingga siap digunakan untuk klasifikasi pada data baru.

3.2.5 Evaluasi Sistem Deteksi Posisi Angkat Beban

Evaluasi sistem dilakukan untuk memastikan bahwa model klasifikasi yang dikembangkan mampu bekerja secara optimal dalam membedakan posisi benar dan salah. Pada tahap ini, penilaian performa sepenuhnya berfokus pada evaluasi kuantitatif menggunakan metrik klasifikasi berbasis data testing. Proses evaluasi dilakukan dengan membandingkan hasil prediksi model dengan label aktual, sehingga diperoleh gambaran objektif mengenai ketepatan dan konsistensi model. Metrik yang digunakan meliputi akurasi, *recall*, dan *F1-score*, yang masing-masing memberikan perspektif berbeda mengenai kualitas prediksi model. Penjelasan lengkapnya sebagai berikut:

1. Akurasi

Akurasi adalah ukuran tingkat keseluruhan kebenaran prediksi model dibandingkan jumlah total data uji. Cara kerjanya adalah dengan menghitung jumlah prediksi yang sesuai dengan label sebenarnya, kemudian membaginya dengan seluruh jumlah data testing. Metrik ini memberikan gambaran umum tentang performa model, namun perlu diperhatikan bahwa akurasi dapat menjadi kurang representatif apabila terdapat ketidakseimbangan jumlah data antara kelas benar dan salah.


2. *Recall*

Recall mengukur kemampuan model dalam mengenali seluruh data yang benar-benar termasuk dalam kategori posisi salah. Cara kerjanya adalah dengan membandingkan jumlah prediksi benar pada kelas berisiko dengan jumlah keseluruhan data aktual di kelas tersebut. *Recall* sangat penting untuk penelitian ini karena kegagalan mendeteksi posisi berbahaya berpotensi meningkatkan risiko cedera pada pengguna.

3. *F1-score*

F1-score merupakan rata-rata harmonik antara *precision* dan *recall*, sehingga memberikan pandangan evaluatif yang lebih seimbang terutama ketika distribusi data antar kelas tidak merata. Cara kerjanya adalah dengan mengombinasikan *precision* dan *recall* ke dalam satu nilai terpadu. Metrik ini sangat berguna untuk menilai apakah model mampu menjaga

keseimbangan antara menghindari kesalahan prediksi dan mendeteksi posisi berisiko secara konsisten.



Gambar 3.2 Skema Alur Pengembangan Sistem

Langkah penelitian dirancang secara iteratif, sehingga setiap tahapan mencakup proses pengecekan dan validasi kualitas data maupun kinerja model seperti yang terlihat pada Gambar 33. Apabila data yang telah melewati tahap *preprocessing* belum memenuhi kelayakan, atau model yang dihasilkan belum mencapai performa optimal, maka proses akan kembali ke tahap sebelumnya, misalnya dengan melakukan penyesuaian *Hyperparameter* atau pemrosesan ulang data.

3.3 Metode Penelitian

Pada penelitian ini, metode penelitian yang digunakan ada dua, yaitu:

1. Observasi

Proses observasi dalam penelitian ini dilakukan dengan tinjauan langsung pada ruang lingkup Universitas Malikussaleh. Lokasi uji coba juga akan

dilakukan di Universitas Malikussaleh untuk menganalisis dan mengevaluasi efektivitas jangkauan dan keberhasilan Sistem Deteksi Posisi Angkat Beban yang telah dirancang dan diimplementasikan.

2. Studi Literatur

Studi literatur adalah metode yang digunakan untuk memperoleh, menganalisis, dan menyintesis informasi dari berbagai sumber, termasuk jurnal, *e-book*, artikel, dan situs *web*, yang relevan dengan topik penelitian. Studi literatur juga digunakan untuk mengidentifikasi studi-studi sebelumnya yang relevan dan memperluas kerangka teoritis serta dasar teoritis untuk penelitian yang akan dilakukan.

3.4 Analisis Kebutuhan

Analisis kebutuhan dilakukan untuk mengidentifikasi semua komponen yang diperlukan dalam desain dan implementasi Sistem Deteksi Posisi Angkat Beban berbasis *Internet of Things* (IoT). Kebutuhan ini mencakup perangkat keras dan perangkat lunak yang mendukung semua tahap penelitian, mulai dari pengumpulan data sensor, pemrosesan data, pengembangan model klasifikasi, hingga integrasi sistem secara keseluruhan. Analisis kebutuhan ini sangat penting untuk memastikan desain sistem yang optimal dan efisien, sehingga sistem dapat berfungsi sesuai dengan tujuan penelitian, khususnya deteksi posisi angkat beban secara *real-time*.

3.4.1 Kebutuhan Perangkat Keras

Perangkat keras yang digunakan dalam studi ini mencakup komponen utama untuk pengambilan data, pemrosesan awal, sumber daya listrik, dan perangkat pendukung tambahan. Persyaratan perangkat keras adalah sebagai berikut:

1. *Node MCU ESP8266*, yang berfungsi sebagai mikrokontroler dan modul komunikasi nirkabel, memfasilitasi pengiriman data sensor ke *server* atau komputer.
2. Sensor *MPU6050*, yang digunakan untuk mengumpulkan data tentang percepatan dan kecepatan sudut dari daerah punggung atas dan bawah pengguna.

3. *Piezo buzzer*, yang berfungsi sebagai perangkat yang menghasilkan sinyal suara untuk memberi peringatan kepada pengguna ketika sistem mendeteksi posisi salah.
4. Laptop Asus Expertbook L1400CDA, yang digunakan sebagai perangkat pemrosesan utama untuk pelatihan model dan integrasi sistem.
5. Memori RAM 8 GB, yang sebagai kapasitas minimum yang diperlukan untuk mendukung proses pengolahan data dan model *machine learning*.
6. Penyimpanan SSD 256 GB, yang digunakan untuk menyimpan *dataset*, skrip pemrograman, serta model *Random Forest*.
7. Baterai *Lithium-ion* 18650 (3,7 V, 3200 mAh), yang digunakan sebagai sumber daya listrik untuk perangkat IoT selama proses pengujian sistem.

3.4.2 Kebutuhan Perangkat Lunak


Selain perangkat keras, penelitian ini memerlukan perangkat lunak untuk memfasilitasi aktivitas seperti pemrograman, analisis data, pembuatan model, dan visualisasi sistem. Perangkat lunak yang digunakan adalah sebagai berikut:

1. Microsoft Windows 11 sebagai sistem operasi utama pada laptop yang digunakan dalam proses pengembangan dan analisis.
2. Python digunakan untuk pemrosesan data, *preprocessing*, dan pembangunan model klasifikasi menggunakan metode *Random Forest*.
3. Arduino IDE digunakan untuk memprogram *Node MCU ESP8266* guna mengumpulkan data sensor dan mengirimkannya melalui koneksi Wi-Fi.
4. Visual Studio Code digunakan sebagai *editor* kode alternatif untuk mengembangkan aplikasi dan skrip dukungan sistem.
5. Fritzing digunakan untuk merancang skema sirkuit *hardware* dan dokumentasi diagram kabel secara visual.


3.5 Skema Sistem Deteksi Posisi Angkat Beban

Skema Sistem Deteksi Posisi Angkat Beban menggambarkan bagaimana data mengalir dari sensor hingga menghasilkan respons berupa aktivasi *buzzer*. Skema ini divisualisasikan melalui Gambar 3.3 dan Gambar 3.4. Kedua diagram ini memberikan pemahaman menyeluruh tentang hubungan antar komponen,

proses komunikasi data, serta cara kerja sistem secara *real-time*.



Gambar 3.3 Alur Sistem Deteksi Posisi Angkat Beban



Gambar 3.3 Alur Sistem Deteksi Posisi Angkat Beban (Lanjutan)

Gambar ini menunjukkan rangkaian proses utama dari Sistem Deteksi Posisi Angkat Beban mulai dari akuisisi data hingga pemberian umpan balik. Alur kerjanya dijelaskan sebagai berikut:


1. Sensor menghasilkan data dengan cara membaca parameter gerakan tubuh melalui dua modul MPU6050 yang merekam nilai akselerasi dan kecepatan sudut secara *real-time*. Data mentah ini menjadi *input* awal yang merepresentasikan kondisi posisi pengguna dan menjadi dasar analisis pada

tahapan berikutnya.

2. Data mentah yang dihasilkan sensor kemudian masuk ke mikrokontroler *Node MCU ESP8266* melalui protokol komunikasi I2C. Pada tahap ini, *Node MCU* berfungsi sebagai penerima awal data untuk memastikan bahwa seluruh informasi sensor dapat diproses secara berurutan dan tanpa kehilangan paket data.
3. Setelah menerima data, mikrokontroler mengubah format data mentah menjadi struktur *JSON* melalui proses *parsing*. Pengubahan format ini dilakukan agar data dapat dibaca oleh *server* web dengan mudah dan dapat dikirimkan melalui jaringan secara lebih efisien serta terstandarisasi.
4. *Node MCU* kemudian mengirimkan data *JSON* tersebut ke *website* atau *server* Flask melalui *endpoint* HTTP yang telah ditentukan. Pengiriman ini dilakukan secara berkala untuk memastikan bahwa data yang diterima *server* selalu merupakan data terbaru dari sensor.
5. Ketika *server* Flask menerima data dari mikrokontroler, *server* melakukan penyesuaian format untuk memastikan bahwa data sesuai dengan kebutuhan *preprocessing* dan dapat digunakan sebagai *input* model. Proses penyesuaian ini mencakup pemeriksaan struktur *JSON* dan penyiapan data pada format yang diperlukan oleh *pipeline* pemrosesan.
6. Setelah data siap, model *Random Forest* menerima *input* yang telah diproses untuk melakukan klasifikasi posisi. Model kemudian menentukan apakah gerakan yang dilakukan pengguna berada dalam kategori benar atau salah berdasarkan pola gerakan yang terekam oleh sensor.
7. Hasil klasifikasi dari model dikirim kembali ke *backend* Flask, yang kemudian memproses informasi tersebut dan menyusunnya menjadi *output* yang dapat diteruskan ke perangkat. Tahap ini memastikan bahwa hasil prediksi dapat diakses baik oleh perangkat maupun *dashboard* web.
8. *Server* Flask selanjutnya memberikan masukan dalam bentuk nilai biner kepada mikrokontroler. Nilai berupa angka 1 untuk menunjukkan bahwa posisi pengguna salah, dan angka 0 untuk menunjukkan bahwa posisi pengguna berada dalam kondisi aman, sehingga mudah dibaca dan

ditindaklanjuti oleh *Node MCU*.

9. Mikrokontroler menerima hasil klasifikasi dalam format biner dari *server* dan membacanya untuk menentukan tindakan yang harus dilakukan. Nilai yang diterima ini menjadi penentu apakah sistem perlu memberikan peringatan atau tetap dalam keadaan normal.
10. Berdasarkan hasil klasifikasi, mikrokontroler mengaktifkan *buzzer* apabila posisi terdeteksi sebagai berisiko atau salah sebagai bentuk peringatan langsung kepada pengguna. Sebaliknya, jika hasil menunjukkan bahwa posisi aman, maka *buzzer* akan tetap dalam kondisi nonaktif sehingga tidak mengganggu aktivitas pengguna.



Gambar 3.4 *Sequence Diagram* Sistem Deteksi Posisi Angkat Beban

Sequence diagram pada gambar ini memberikan penjelasan lebih detail mengenai interaksi antar komponen, termasuk urutan waktu komunikasi antara sensor, mikrokontroler, *server* Flask, modul *preprocessing*, model klasifikasi, *dashboard*, dan *buzzer*. Penjelasanannya adalah sebagai berikut:

1. Sensor menghasilkan data mentah berupa nilai akselerasi dan kecepatan sudut (*gyro*) yang direkam oleh modul MPU6050 secara *real-time*. Data ini merupakan representasi langsung dari gerakan tubuh pengguna, sehingga menjadi dasar bagi sistem untuk menganalisis apakah posisi yang dilakukan berada dalam kondisi aman atau berisiko.
2. Mikrokontroler menerima data mentah dari sensor kemudian melakukan *parsing* untuk menata ulang struktur datanya agar lebih mudah diproses. Setelah itu, mikrokontroler membentuk data tersebut menjadi format *JSON* sehingga kompatibel dengan *server* Flask dan dapat dikirim melalui jaringan secara konsisten.
3. *Node* MCU kemudian mengirimkan data *JSON* tersebut ke *server* Flask menggunakan metode HTTP POST. Proses pengiriman ini memastikan bahwa data sensor diterima oleh *backend* secara terus-menerus dan dapat diproses tanpa jeda, sehingga mendukung Sistem Deteksi Posisi Angkat Beban *real-time*.
4. Setelah *server* Flask menerima data, *server* meneruskan informasi tersebut ke modul *preprocessing* untuk dilakukan normalisasi dan ekstraksi fitur. Tahap ini diperlukan untuk memastikan bahwa data berada dalam skala yang tepat dan fitur-fitur penting dari sinyal gerakan dapat dikenali secara optimal oleh model klasifikasi.
5. Pada proses *preprocessing*, data mentah diproses melalui beberapa langkah seperti normalisasi nilai dan penghitungan fitur statistik sehingga menghasilkan kumpulan fitur yang lebih stabil dan representatif. Hasil *preprocessing* ini kemudian digunakan sebagai *input* yang siap diprediksi oleh model *machine learning*.
6. Data fitur yang telah diproses diberikan kepada model *Random Forest* untuk dianalisis lebih lanjut. Model kemudian menggunakan pola-pola dari data pelatihan sebelumnya untuk menentukan apakah posisi yang dilakukan termasuk kategori benar atau salah.
7. Model *Random Forest* melakukan klasifikasi terhadap posisi pengguna berdasarkan *input* fitur yang diterimanya. Hasil klasifikasi ini merupakan

keluaran utama sistem, yang menunjukkan tingkat keamanan posisi pengguna saat mengangkat beban.


8. *Server Flask* menerima hasil prediksi dari model dan mengemasnya kembali dalam format *JSON*, kemudian mengirimkannya kembali ke mikrokontroler. Tahap ini memastikan bahwa perangkat fisik dapat memahami hasil prediksi dan mengambil tindakan yang sesuai.
9. *Node MCU* membaca hasil prediksi yang diterima dari *server*, kemudian memeriksa apakah status posisi termasuk kategori baik atau jelek. Informasi ini menjadi dasar pengambilan keputusan untuk memberikan atau tidak memberikan peringatan kepada pengguna.
10. Jika status yang diterima menunjukkan bahwa posisi pengguna berbahaya atau salah, *Node MCU* mengaktifkan *buzzer* sebagai sinyal peringatan audio. Sebaliknya, jika posisi aman, maka *buzzer* tetap dalam kondisi nonaktif sehingga tidak mengganggu aktivitas pengguna.
11. *Dashboard* menampilkan data secara *real-time*, termasuk nilai sensor, hasil klasifikasi model, serta riwayat pengukuran dalam bentuk grafik atau tabel. Penyajian ini memudahkan pengguna atau peneliti untuk memantau perkembangan posisi dari waktu ke waktu.
12. Pengguna dapat melihat *dashboard* melalui peramban *web*, sehingga memungkinkan pemantauan jarak jauh dan akses yang fleksibel. Dengan demikian, seluruh proses mulai dari pengambilan data hingga visualisasi dapat dilakukan secara terpadu dan nyaman bagi pengguna.

Secara keseluruhan, skema Sistem Deteksi Posisi Angkat Beban menunjukkan bahwa seluruh komponen bekerja secara terintegrasi dalam alur komunikasi yang saling berkaitan. Sistem dirancang untuk memproses data secara *real-time* dan mengonversinya menjadi informasi yang dapat ditindaklanjuti, sehingga memungkinkan pendeteksian posisi yang akurat serta pemberian peringatan yang responsif. Alur ini menegaskan bahwa keseluruhan proses berjalan secara konsisten dan berkesinambungan, memastikan bahwa sistem mampu memantau posisi pengguna secara efektif serta menyediakan dukungan yang relevan untuk tujuan pencegahan cedera dan peningkatan keselamatan kerja.

3.6 Rancangan Sistem Deteksi Posisi Angkat Beban

3.6.1 Rancangan Alat Deteksi Posisi Angkat Beban

Pada tahap ini, sistem dirancang dengan memanfaatkan *Node MCU* ESP8266 sebagai mikrokontroler utama yang berfungsi untuk memproses data sensor serta mengirimkan informasi melalui koneksi Wi-Fi.



Gambar 3.5 Diagram Sirkuit Sistem Deteksi Posisi Angkat Beban


Dua modul MPU6050, yang masing-masing merupakan kombinasi akselerometer dan giroskop, digunakan untuk merekam dinamika gerakan tubuh secara *real-time*. Konfigurasi perangkat keras sebagaimana ditampilkan pada Gambar 3.5 menunjukkan susunan komponen yang meliputi:

1. *Node MCU* ESP8266 sebagai pusat pemrosesan sekaligus modul komunikasi nirkabel.
2. Dua sensor MPU6050 yang akan ditempatkan pada area punggung bawah (*lumbar*) dan punggung atas (*thoracic*) yang berfungsi untuk menangkap sudut kemiringan dan orientasi tubuh secara akurat.
3. Satu BMP280 yang akan ditempatkan pada beban yang berfungsi untuk menangkap tekanan dan ketinggian dari beban.
4. Baterai *lithium-ion* yang dihubungkan melalui *port* USB sebagai sumber daya sehingga perangkat dapat beroperasi tanpa ketergantungan pada kabel.
5. *Buzzer* sebagai aktuator peringatan yang memberikan umpan balik langsung ketika sistem mendeteksi posisi yang salah.

Rangkaian ini dirancang untuk menghasilkan akuisisi data yang stabil dengan konsumsi daya yang efisien, sehingga memungkinkan penggunaan dalam skenario lapangan yang membutuhkan mobilitas dan pengukuran berkelanjutan.

3.6.2 Rancangan *Website* Deteksi Posisi Angkat Beban

Website yang dikembangkan dalam sistem ini memiliki tiga tujuan utama. Pertama, *website* berfungsi sebagai penerima data sensor yang dikirimkan oleh *Node* MCU ESP8266 melalui protokol HTTP POST. Data tersebut kemudian diproses lebih lanjut untuk menjalankan model *Random Forest* yang telah dilatih sebelumnya. Kedua, *website* bertugas untuk menampilkan hasil klasifikasi posisi Angkat Beban secara *real-time* dalam bentuk *dashboard* yang informatif. Ketiga, *website* juga mengirimkan kembali hasil prediksi model ke perangkat ESP, sehingga mikrokontroler dapat mengaktifkan *buzzer* apabila postur pengguna terdeteksi salah. Dengan demikian, *website* tidak hanya berperan sebagai antarmuka pengguna tetapi juga sebagai jembatan komunikasi dua arah antara sistem klasifikasi dan perangkat keras.



Gambar 3.6 Use Case Diagram Sistem Deteksi Posisi Angkat Beban

Arsitektur sistem pada *website* ini mengikuti pola client-server yang sederhana namun efisien. Di sisi server, digunakan framework Flask yang berjalan

pada lingkungan Python. Server ini bertanggung jawab untuk menerima data *JSON* dari ESP8266, melakukan *preprocessing* terhadap data mentah sensor, kemudian memasukkannya ke dalam model *Random Forest* yang sudah disimpan dalam format file (misalnya *pickle* atau *joblib*). Setelah model menghasilkan prediksi, server mengemas hasil tersebut ke dalam format *JSON* dan mengirimkannya kembali ke *Node MCU*. Di sisi lain, server juga menyediakan halaman web dinamis yang dapat diakses oleh pengguna melalui peramban. Halaman ini secara periodik mengambil data terbaru dari server menggunakan teknik *AJAX* atau *WebSocket*, sehingga tampilan *dashboard* dapat diperbarui tanpa perlu me-refresh seluruh halaman. Komunikasi antara ESP8266 dan server Flask dilakukan melalui jaringan Wi-Fi lokal, yang memungkinkan respons cepat dan latensi rendah.

Alur kerja *website* dimulai saat *Node MCU* mengirimkan data sensor mentah (akselerasi dan gyroscope dari dua sensor MPU6050) ke *endpoint /predict* pada server Flask. Data diterima dalam format *JSON* dan langsung diteruskan ke modul *preprocessing*. Pada modul *preprocessing*, data mentah dinormalisasi menggunakan teknik *min-max Scaling* atau standarisasi *Z-score*, kemudian dilakukan ekstraksi fitur seperti mean, standar deviasi, nilai maksimum, dan minimum dari setiap window waktu (misalnya window 1 detik dengan overlap 50%). Selanjutnya, fitur-fitur yang telah diekstrak disusun menjadi sebuah array multidimensi yang sesuai dengan input model *Random Forest*. Model yang telah dilatih kemudian melakukan prediksi terhadap array fitur tersebut, menghasilkan output berupa label kelas (benar atau salah) beserta probabilitasnya. Setelah prediksi selesai, server menyimpan hasil ke dalam database sementara (misalnya *SQLite* atau *Redis*) untuk keperluan histori, lalu mengirimkan respons *JSON* yang berisi status prediksi kembali ke *Node MCU*. Secara paralel, *dashboard* web yang diakses pengguna secara berkala memanggil *endpoint /get_data* untuk menampilkan data terbaru, termasuk grafik pergerakan sensor, hasil prediksi terkini, dan riwayat deteksi.

3.6.3 Rancangan *Random Forest*

Model *Random Forest* digunakan dalam sistem ini untuk mengklasifikasikan postur tubuh pengguna saat mengangkat beban ke dalam dua kategori: postur yang benar dan postur yang salah. Klasifikasi ini didasarkan pada pola sinyal yang dihasilkan oleh dua sensor MPU6050 yang dipasang di daerah punggung bawah (lumbal) dan punggung atas (torakal). *Random Forest* adalah metode ensemble yang menggabungkan beberapa pohon keputusan untuk menghasilkan keputusan yang lebih stabil dan akurat dibandingkan dengan satu pohon keputusan saja. Dalam konteks deteksi posisi mengangkat beban, *Random Forest* telah terbukti memiliki kemampuan untuk menangkap hubungan non-linear antara nilai percepatan, kecepatan sudut, dan pola gerakan tubuh, sehingga menjadikan metode ini cocok untuk sistem deteksi *real-time*.

Data sumber untuk penelitian ini dikumpulkan langsung dari sensor MPU6050 melalui perekaman gerakan mengangkat yang disimulasikan. Sebanyak 20 peserta diminta untuk melakukan gerakan mengangkat dalam dua posisi berbeda: posisi “benar” dan posisi “salah”. Setiap peserta diminta untuk melakukan 10 pengulangan setiap gerakan di setiap posisi. Fitur yang digunakan dalam pemodelan mencakup nilai percepatan (a_x , a_y , a_z) dan kecepatan sudut (ω_x , ω_y , ω_z) dari kedua sensor MPU6050, bersama dengan data tekanan dan ketinggian dari sensor BMP280. Label yang diberikan adalah “Benar” untuk posisi ergonomis dan “Salah” untuk posisi non-ergonomis.

1. Teknik Validasi Silang *Leave-One-Subject-Out* (LOSO)

Metode validasi silang yang digunakan dalam penelitian ini dikenal sebagai *Leave-One-Subject-Out* (LOSO) atau *Leave-One-Person-Out* (LOPO). Dalam metode ini, setiap peserta secara bergantian digunakan sebagai data uji, sedangkan data dari peserta lainnya digunakan untuk pelatihan. Proses pelatihan dan pengujian dilakukan sebanyak 20 kali, dengan setiap peserta menyelesaikan total 20 iterasi hingga semua peserta telah berpartisipasi dalam proses pengujian. Tujuan dari metode LOSO adalah untuk menilai kemampuan model dalam melakukan generalisasi terhadap pengguna baru yang belum pernah terpapar oleh model sebelumnya. Akibatnya, hasil

evaluasi model menjadi lebih realistis untuk diterapkan dalam kondisi penggunaan di dunia nyata.

2. *Hyperparameter Model Random Forest*

Konfigurasi *Hyperparameter* yang digunakan dapat dilihat pada Tabel 3.1.

Tabel 3.1 Konfigurasi *Hyperparameter Model*

<i>Hyperparameter</i>	Nilai yang diuji	Keterangan
<i>n_estimators</i>	200, 250, 300	Jumlah pohon keputusan dalam model <i>Random Forest</i>
<i>max_depth</i>	2, 3, 4, 5	Kedalaman maksimum pohon keputusan
<i>min_samples_split</i>	2, 5, 10	Jumlah minimum sampel untuk melakukan pemisahan <i>Node</i>
<i>min_samples_leaf</i>	1, 2, 3	Jumlah minimum sampel pada <i>Node</i> daun
<i>max_features</i>	0.8, 1.0, sqrt, log2	Jumlah fitur yang dipertimbangkan pada setiap pemisahan
<i>bootstrap</i>	<i>True</i>	Penggunaan <i>bootstrap</i> sampling pada proses pelatihan
<i>class_weight</i>	<i>balanced</i>	Penyesuaian bobot kelas untuk mengatasi ketidakseimbangan data
<i>criterion</i>	gini, entropy	Metode pengukuran kualitas pemisahan data

Parameter-parameter yang digunakan dalam pembangunan model *Random Forest* telah ditentukan melalui serangkaian uji coba dan prosedur optimasi, agar kinerja semakin optimal.

3. Evaluasi Model

Model dievaluasi untuk mengetahui kemampuan *Random Forest* dalam mengklasifikasikan posisi angkat benda secara akurat. Proses evaluasi tersebut menggunakan berbagai metrik evaluasi untuk menilai akurasi

prediksi, kemampuan model dalam mendeteksi posisi yang salah, serta distribusi kesalahan klasifikasi yang dihasilkan oleh model.

Tabel 3.2 Metrik Evaluasi Model *Random Forest*

Metrik yang Digunakan	Definisi
Akurasi	Mengukur tingkat ketepatan model secara keseluruhan berdasarkan jumlah prediksi yang benar dibandingkan dengan seluruh data pengujian.
<i>Recall</i>	Mengukur kemampuan model dalam mendeteksi seluruh data yang termasuk ke dalam kategori posisi salah.
<i>F1-score</i>	Mengukur keseimbangan antara <i>precision</i> dan <i>recall</i> sehingga memberikan evaluasi model yang lebih menyeluruh.
<i>Classification Report</i>	Menampilkan ringkasan nilai <i>precision</i> , <i>recall</i> , <i>F1-score</i> , dan support untuk masing-masing kelas klasifikasi.
<i>Confusion matrix</i>	Menunjukkan distribusi hasil prediksi benar dan salah untuk melihat pola kesalahan klasifikasi model.
Metrik yang Digunakan	Definisi
Akurasi	Mengukur tingkat ketepatan model secara keseluruhan berdasarkan jumlah prediksi yang benar dibandingkan dengan seluruh data pengujian.


BAB IV HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Tahap pengumpulan data merupakan langkah awal yang penting dalam penelitian ini karena kualitas data yang diperoleh akan memengaruhi proses pengolahan, pembentukan model, dan evaluasi sistem pada tahap selanjutnya. Pada tahap ini dijelaskan instrumen penelitian yang digunakan, skenario pengambilan data, karakteristik responden, serta hasil pengumpulan data yang menjadi dasar dalam proses analisis dan pengembangan model klasifikasi.

4.1.1 Instrumen Penelitian

Instrumen penelitian yang digunakan dalam pengambilan data terdiri atas perangkat keras dan perangkat lunak yang telah dirancang sesuai dengan kebutuhan penelitian. Perangkat keras utama yang digunakan adalah sensor MPU6050 dan BMP280, mikrokontroler ESP8266, serta sumber daya berupa baterai.



Gambar 4.1 Tampilan Alat Baca Sensor MPU6050 dan BMP280

Perangkat lunak yang digunakan berupa *website* berbasis Flask yang berfungsi sebagai antarmuka pengumpulan data secara *real-time* sekaligus


penyimpanan data ke dalam berkas .csv pada penyimpanan lokal. Dengan adanya kombinasi perangkat tersebut, proses akuisisi data dapat dilakukan secara terintegrasi, akurat, dan mudah dipantau selama pengambilan data berlangsung.

Peletakan sensor pada tubuh dilakukan menggunakan baju khusus yang telah dirancang agar perangkat dapat dipasang dengan mudah dan tetap nyaman saat digunakan. Tampilan alat pada baju ditunjukkan pada Gambar 4.2.



Gambar 4.2 Tampilan Alat pada Baju

Dua sensor MPU6050 ditempatkan pada bagian torakal dan lumbal untuk merekam data gerakan tubuh pada titik pengukuran yang telah ditentukan. Kedua sensor tersebut dihubungkan dengan ESP8266 yang mendapatkan catu daya dari baterai, sehingga sistem dapat digunakan secara mandiri tanpa ketergantungan pada sumber listrik eksternal.




Gambar 4.3 Tampilan Alat pada Beban

Selain pada tubuh, sensor juga dipasang pada beban yang digunakan dalam penelitian. Beban yang digunakan berupa galon air berkapasitas 15 liter dengan berat sekitar 15 kg, yang dipilih untuk merepresentasikan aktivitas pengangkatan beban yang umum dilakukan dalam kehidupan sehari-hari. Sensor BMP280 ditempatkan pada bagian bawah beban. Penempatan tersebut dilakukan untuk memperoleh data tekanan dan ketinggian yang diperlukan dalam proses pengambilan data. Tampilan alat yang terpasang pada beban ditunjukkan pada Gambar 4.3. Secara keseluruhan, rancangan instrumen penelitian ini disusun untuk mendukung proses pengambilan data yang sistematis, terukur, dan sesuai dengan tujuan penelitian.

4.1.2 Skenario Pengambilan Data

Tahap pengumpulan data dilakukan untuk memperoleh data pengukuran yang diperlukan dalam penelitian. Proses pengumpulan data disusun secara sistematis guna memastikan bahwa setiap partisipan memperoleh perlakuan yang seragam sehingga data yang dihasilkan memiliki tingkat konsistensi yang baik. Pelaksanaan pengambilan data dilakukan melalui beberapa tahapan, yang meliputi persiapan alat dan bahan, pemberian informasi kepada partisipan, pemasangan sensor, pelaksanaan tugas pengangkatan beban, hingga penyimpanan data hasil pengukuran. Dengan prosedur yang terstruktur, diharapkan data yang diperoleh

dapat merepresentasikan kondisi pengukuran secara akurat dan mendukung proses analisis pada tahap selanjutnya.



Gambar 4.4 Diagram Alur Proses Pengambilan Data.

Skenario pengambilan data pada penelitian ini disusun berdasarkan prosedur yang telah ditetapkan sebelumnya. Tahapan pengambilan data dilakukan secara sistematis untuk memastikan keseragaman perlakuan pada setiap partisipan sehingga data yang diperoleh memiliki tingkat konsistensi yang baik. Adapun tahapan pengambilan data yang dilakukan adalah sebagai berikut.

1. Persiapan alat dan bahan

Seluruh peralatan yang digunakan dalam penelitian dipersiapkan sebelum proses pengambilan data dimulai. Peralatan tersebut meliputi sensor, media pemasangan sensor, perangkat perekam data, serta beban berupa galon air berkapasitas 15 liter. Selain itu, pemeriksaan terhadap kondisi dan fungsi setiap perangkat dilakukan untuk memastikan seluruh sistem dapat beroperasi dengan baik selama proses pengambilan data berlangsung.

2. Pemberian informasi kepada partisipan

Partisipan yang memenuhi kriteria inklusi diberikan penjelasan mengenai tujuan penelitian, prosedur pelaksanaan, manfaat penelitian, serta potensi risiko yang mungkin timbul selama kegiatan pengambilan data. Pemberian informasi ini dilakukan agar partisipan memahami seluruh rangkaian

kegiatan yang akan dilaksanakan.

3. Persetujuan partisipasi

Setelah memperoleh penjelasan mengenai penelitian, partisipan diminta untuk membaca lembar informasi penelitian dan mengisi formulir persetujuan (*informed consent*) melalui *Google Form*. Pengisian formulir tersebut dilakukan sebagai bentuk persetujuan dan kesediaan partisipan untuk mengikuti seluruh rangkaian penelitian.

4. Pemberian instruksi pelaksanaan

Instruksi mengenai prosedur pengambilan data diberikan kepada partisipan sebelum pelaksanaan pengukuran. Instruksi yang diberikan meliputi tata cara pemasangan alat, prosedur pelaksanaan gerakan pengangkatan beban, serta penjelasan mengenai perbedaan teknik pengangkatan beban yang benar dan teknik pengangkatan beban yang salah. Partisipan juga diberikan kesempatan untuk mengajukan pertanyaan apabila terdapat prosedur yang belum dipahami dengan jelas.

5. Pemasangan sensor

Sensor dipasang pada dua lokasi anatomi, yaitu punggung atas (*thoracic*) dan punggung bawah (*lumbar*). Pemasangan dilakukan pada titik anatomi yang telah ditentukan untuk menjaga konsistensi posisi sensor pada setiap partisipan. Selain itu, sensor tambahan dipasang pada beban berupa galon air berkapasitas 15 liter yang digunakan selama proses pengambilan data.

6. Pemeriksaan sistem

Setelah seluruh sensor terpasang, pemeriksaan konektivitas dan kualitas sinyal dilakukan untuk memastikan bahwa setiap sensor berfungsi dengan baik. Tahap ini bertujuan untuk menjamin bahwa data yang dihasilkan dapat direkam secara optimal dan meminimalkan kemungkinan terjadinya kehilangan data selama proses pengukuran.

7. Pelaksanaan pengambilan data

Partisipan diminta untuk melakukan gerakan pengangkatan beban pada dua kondisi pengujian, yaitu teknik pengangkatan beban yang benar dan teknik pengangkatan beban yang salah. Pada masing-masing kondisi, gerakan

pengangkatan beban dilakukan sebanyak lima kali pengulangan. Selama proses pengambilan data berlangsung, observasi dilakukan untuk memastikan bahwa setiap gerakan dilakukan sesuai dengan skenario yang telah ditetapkan.

8. Pemberian waktu istirahat

Waktu istirahat yang cukup diberikan kepada partisipan di antara setiap kondisi pengujian. Pemberian waktu istirahat bertujuan untuk mengurangi pengaruh kelelahan yang dapat memengaruhi hasil pengukuran dan kualitas data yang diperoleh.



Gambar 4.2 Foto Proses Pengambilan Data.

Setelah seluruh rangkaian pengambilan data selesai dilaksanakan, sensor dilepaskan dari tubuh partisipan dan dari beban yang digunakan. Data hasil pengukuran kemudian disimpan pada media penyimpanan yang telah disiapkan sebelumnya dan diberi kode identitas partisipan untuk menjaga kerahasiaan data. Selanjutnya, pemeriksaan kelengkapan data dilakukan sebelum data digunakan pada tahap analisis

4.1.3 Responden Penelitian

Penelitian ini melibatkan 20 responden yang telah memenuhi kriteria inklusi dan eksklusi yang ditetapkan. Setiap responden diminta melakukan aktivitas

pengangkatan beban menggunakan galon air berkapasitas 15 liter dengan dua variasi teknik pengangkatan, yaitu teknik pengangkatan yang benar dan teknik pengangkatan yang salah. Keterlibatan responden dengan karakteristik yang beragam bertujuan untuk memperoleh data gerakan yang merepresentasikan variasi kondisi individu selama melakukan aktivitas pengangkatan beban. Karakteristik demografi responden yang terlibat dalam penelitian ini disajikan pada Tabel 4.1.

Tabel 4.1 Karakteristik Demografi Responden

ID	Usia (Tahun)	Jenis Kelamin	Tinggi Badan (cm)	Berat Badan (kg)
01	21	Perempuan	156	48
02	23	Perempuan	162	54
04	21	Laki-laki	165	70
05	21	Perempuan	150	56
06	21	Laki-laki	167	70
07	19	Laki-laki	176	69
08	21	Laki-laki	169	70
11	22	Laki-laki	162	68
12	22	Perempuan	160	52
13	22	Perempuan	149	54
14	20	Laki-laki	173	60
16	20	Laki-laki	169	71
17	23	Laki-laki	165	62
18	21	Laki-laki	158	54
19	19	Perempuan	150	39
20	22	Laki-laki	164	51
21	21	Perempuan	168	56
22	22	Perempuan	159	65
23	19	Laki-laki	172	75
24	21	Perempuan	168	60

Berdasarkan Tabel 4.1, responden yang terlibat terdiri atas 11 responden laki-laki dan 9 responden perempuan. Usia responden berada pada rentang 19 hingga 23 tahun dengan rata-rata usia sebesar 21 tahun. Tinggi badan responden berkisar antara 149 cm hingga 176 cm, sedangkan berat badan berada pada rentang 39 kg hingga 75 kg. Variasi karakteristik fisik tersebut menunjukkan bahwa data penelitian diperoleh dari responden dengan kondisi yang beragam sehingga diharapkan mampu menghasilkan pola gerakan yang lebih representatif.

Selain karakteristik demografi, informasi mengenai riwayat nyeri punggung, kebiasaan mengangkat beban, dan riwayat cedera punggung juga dikumpulkan sebagai data pendukung penelitian. Informasi tersebut digunakan untuk memberikan gambaran mengenai kondisi fisik responden yang berpotensi memengaruhi pola gerakan selama aktivitas pengangkatan beban. Data riwayat dan kebiasaan responden disajikan pada Tabel 4.2.

Tabel 4.2 Riwayat dan Kebiasaan Responden

ID	Riwayat Nyeri Punggung	Kebiasaan Mengangkat Beban	Riwayat Cedera Punggung
01	Ya	Jarang (beberapa kali sebulan)	Tidak Pernah
02	Ya	Ya, beberapa kali seminggu	Tidak Pernah
04	Tidak	Jarang (beberapa kali sebulan)	Tidak Pernah
05	Tidak	Tidak pernah	Pernah
06	Ya	Tidak pernah	Tidak Pernah
07	Ya	Ya, beberapa kali seminggu	Tidak Pernah
08	Ya	Jarang (beberapa kali sebulan)	Tidak Pernah
11	Tidak	Ya, beberapa kali seminggu	Tidak Pernah
12	Tidak	Ya, beberapa kali seminggu	Tidak Pernah
13	Ya	Jarang (beberapa kali sebulan)	Pernah
14	Tidak	Jarang (beberapa kali sebulan)	Pernah
16	Ya	Ya, beberapa kali seminggu	Pernah

Tabel 4.2 Riwayat dan Kebiasaan Responden (Lanjutan)

ID	Riwayat Nyeri Punggung	Kebiasaan Mengangkat Beban	Riwayat Cedera Punggung
17	Tidak	Jarang (beberapa kali sebulan)	Tidak Pernah
18	Tidak	Ya, beberapa kali seminggu	Tidak Pernah
19	Ya	Jarang (beberapa kali sebulan)	Tidak Pernah
20	Tidak	Jarang (beberapa kali sebulan)	Tidak Pernah
21	Ya	Jarang (beberapa kali sebulan)	Tidak Pernah
22	Tidak	Ya, beberapa kali seminggu	Pernah
23	Ya	Jarang (beberapa kali sebulan)	Pernah
24	Ya	Ya, beberapa kali seminggu	Tidak Pernah

Berdasarkan Tabel 4.2, sebanyak 11 responden memiliki riwayat nyeri punggung, sedangkan 8 responden tidak memiliki riwayat nyeri punggung. Sebagian besar responden memiliki pengalaman mengangkat beban dengan frekuensi yang bervariasi, mulai dari beberapa kali dalam seminggu hingga beberapa kali dalam sebulan. Selain itu, terdapat 6 responden yang pernah mengalami nyeri punggung dan 13 responden yang tidak memiliki riwayat nyeri punggung. Variasi kondisi tersebut berpotensi memengaruhi pola pergerakan tubuh saat melakukan aktivitas pengangkatan beban. Oleh karena itu, informasi mengenai riwayat dan kebiasaan responden digunakan sebagai data pendukung dalam proses analisis hasil penelitian.

Kuisisioner Pengambilan Data

* Indicates required question

F. Masukan terhadap Alat yang Akan Dirancang dan Kebersediaan Menjadi Subjek

Dengan mengisi mencentang "Bersedia" pada formulir ini, Anda menyatakan bahwa:

- Telah membaca dan memahami informasi penelitian;
- Bersedia menjadi responden/subjek penelitian secara sukarela;
- Mengizinkan data yang diperoleh digunakan untuk keperluan penelitian akademik.

Fitur apa yang Anda harapkan dari alat deteksi postur yang sedang kami kembangkan? (bisa pilih lebih dari satu) *

- ☐ Peringatan suara saat postur bungkuk
- ☐ Pengingat waktu untuk berdiri setiap 30 menit
- ☒ Deteksi posisi mengangkat beban yang salah
- ☐ Laporan harian postur dan durasi duduk
- ☐ Ukuran kecil dan mudah dipakai
- ☐ Dashboard aktivitas
- ☐ Other: _____

Saya Bersedia menjadi responden dalam penelitian ini. *

☒ Ya, Saya Bersedia

[Back](#) [Submit](#) [Clear form](#)

Gambar 4.3 Pernyataan Persetujuan Responden (*Informed consent*).

Sebelum proses pengambilan data dilaksanakan, seluruh responden diberikan penjelasan mengenai tujuan, prosedur, manfaat, serta potensi risiko penelitian. Setelah memperoleh penjelasan tersebut, responden yang bersedia berpartisipasi diminta untuk membaca dan menyetujui formulir persetujuan (*informed consent*) yang disediakan melalui *Google Form*. Persetujuan tersebut diberikan secara sukarela tanpa adanya unsur paksaan dari pihak mana pun. Setiap responden diberikan hak untuk menghentikan partisipasi dalam penelitian pada tahap apa pun tanpa dikenakan konsekuensi. Seluruh data yang diperoleh dijaga kerahasiaannya dan hanya digunakan untuk keperluan penelitian sesuai dengan prinsip etika penelitian yang berlaku.

4.1.4 Hasil Pengumpulan Data

Proses pengambilan data dilakukan terhadap 20 responden yang melaksanakan aktivitas pengangkatan beban sesuai dengan skenario yang telah ditetapkan. Selama proses berlangsung, data dari setiap sensor direkam secara kontinu dan disimpan untuk keperluan analisis lebih lanjut. Rekaman data tersebut mencakup sinyal dari sensor MPU6050 yang digunakan untuk memperoleh informasi percepatan dan kecepatan sudut, serta sensor BMP280 yang digunakan untuk memperoleh data tekanan dan ketinggian. Sampel hasil pencatatan data sensor MPU6050 disajikan pada Tabel 4.3, sedangkan sampel hasil pencatatan data sensor BMP280 disajikan pada Tabel 4.4.

Tabel 4.3 Sampel Hasil Data Sensor MPU6050

Baris	timestamp	mpu_id	ax	ay	az	gx	gy	gz
1	2026-06-10 16:07:23.681	1	0.52	0.90	0.08	0.60	2.32	0.59
2	2026-06-10 16:07:23.681	2	0.21	0.79	0.66	0.84	1.49	-0.56
3	2026-06-10 16:07:24.424	1	0.52	0.90	0.08	0.37	2.25	0.39
.	.	.	.	.	.	.	.	.
58.253	2026-06-10 16:07:24.208	1	0.91	-0.07	0.55	45.27	9.67	8.70
58.254	2026-06-02 16:48:01.177	2	1.00	-0.05	0.20	-9.73	1.86	-9.67
58.255	2026-06-02 16:48:01.377	1	1.03	0.17	0.33	- 25.43	- 58.28	-6.91
58.256	2026-06-02 16:48:01.377	2	1.04	-0.09	0.19	6.22	4.99	20.39

Berdasarkan hasil pengumpulan data, sensor MPU6050 berhasil merekam sebanyak 58.256 baris data. Data tersebut memuat informasi waktu pengukuran, identitas sensor, nilai percepatan pada sumbu X, Y, dan Z, serta nilai kecepatan

sudut pada sumbu X, Y, dan Z. Variasi nilai yang terekam menunjukkan adanya perubahan gerakan tubuh selama aktivitas pengangkatan beban berlangsung. Data ini selanjutnya digunakan sebagai masukan pada tahap *preprocessing*, ekstraksi fitur, serta proses analisis dan klasifikasi dalam penelitian ini.

Tabel 4.4 Sampel Hasil Data Sensor BMP280

Baris	timestamp	pressure_hpa	altitude_m
1	2026-06-10 16:08:31.519	1007.04	51.835
2	2026-06-10 16:08:32.912	1007.04	51.835
3	2026-06-10 16:08:32.795	1007.06	51.681
4	2026-06-10 16:08:33.037	1007.06	51.681
5	2026-06-10 16:08:34.596	1007.05	51.724
.	.	.	.
38.619	2026-06-02 16:47:47.491	1005.08	68.27
38.620	2026-06-02 16:47:47.691	1005.08	68.23
38.621	2026-06-02 16:47:48.920	1005.08	68.23
38.622	2026-06-02 16:47:48.120	1005.08	68.23
38.623	2026-06-02 16:47:47.491	1005.08	68.27

Sensor BMP280 berhasil merekam sebanyak 38.623 baris data selama proses pengambilan data. Data yang dihasilkan meliputi waktu pengukuran, jenis sensor, tekanan, dan ketinggian. Informasi tersebut digunakan untuk mendukung analisis kondisi lingkungan dan perubahan posisi yang terjadi selama aktivitas pengangkatan beban. Seluruh data yang diperoleh kemudian diolah lebih lanjut melalui tahapan *preprocessing*, ekstraksi fitur, dan analisis klasifikasi

4.2 *Preprocessing Data*

Data hasil pengambilan dari sensor MPU6050 dan BMP280 masih berupa data mentah yang belum siap digunakan secara langsung pada proses pemodelan. Oleh karena itu, dilakukan tahap *preprocessing* untuk meningkatkan kualitas data serta memastikan data yang digunakan telah sesuai dengan kebutuhan analisis. Tahap ini meliputi pembersihan data, pelabelan data, ekstraksi fitur, dan normalisasi data. Melalui serangkaian proses tersebut, data yang awalnya berupa

sinyal sensor mentah diubah menjadi *dataset* yang lebih terstruktur, informatif, dan siap digunakan dalam proses pelatihan serta pengujian model klasifikasi.

4.2.1 Pembersihan Data

Pemeriksaan missing value dilakukan untuk mengetahui keberadaan data kosong pada setiap kolom. Apabila data kosong ditemukan dalam jumlah yang kecil dan masih memungkinkan untuk dipertahankan, maka dilakukan imputasi sesuai dengan karakteristik data yang bersangkutan. Namun, apabila data kosong ditemukan dalam jumlah yang terlalu banyak atau terjadi pada salah satu sensor sehingga mengganggu kelengkapan data, maka data tersebut dihapus dari *dataset*. Selain itu, data yang berada di luar rentang waktu pengambilan data, seperti data sebelum aktivitas dimulai atau setelah proses pengambilan data selesai, juga dihapus karena tidak merepresentasikan kondisi pengukuran yang sesungguhnya.

Tabel 4.5 Deskripsi Fitur *Dataset*

Nama Fitur	Keterangan
<i>subject_id</i>	Identitas unik responden untuk membedakan data setiap subjek.
<i>date</i>	Tanggal pengambilan data.
<i>time</i>	Waktu pengambilan data pada setiap rekaman sensor.
<i>epoch_ms</i>	Waktu pencatatan data dalam format <i>epoch timestamp</i> dengan satuan milidetik.
<i>ts_millis</i>	Penanda waktu dalam milidetik.
<i>ax1</i>	Nilai percepatan (<i>acceleration</i>) pada sumbu X yang diperoleh dari sensor MPU6050 pertama (<i>thoracic</i>), dalam satuan g.
<i>ay1</i>	Nilai percepatan pada sumbu Y yang diperoleh dari sensor MPU6050 pertama (<i>thoracic</i>), dalam satuan g.
<i>az1</i>	Nilai percepatan pada sumbu Z yang diperoleh dari sensor MPU6050 pertama (<i>thoracic</i>), dalam satuan g.
<i>gx1</i>	Nilai kecepatan sudut pada sumbu X yang diperoleh dari sensor MPU6050 pertama (<i>thoracic</i>), dalam satuan derajat per detik (°/s).
<i>gy1</i>	Nilai kecepatan sudut pada sumbu Y yang diperoleh dari sensor MPU6050 pertama (<i>thoracic</i>), dalam satuan derajat per detik (°/s).

Tabel 4.5 Deskripsi Fitur *Dataset* (Lanjutan)

Nama Fitur	Keterangan
gz1	Nilai kecepatan sudut pada sumbu Z yang diperoleh dari sensor MPU6050 pertama (<i>thoracic</i>), dalam satuan derajat per detik ($^{\circ}/s$).
ax2	Nilai percepatan pada sumbu X yang diperoleh dari sensor MPU6050 kedua (<i>lumbar</i>), dalam satuan g.
ay2	Nilai percepatan pada sumbu Y yang diperoleh dari sensor MPU6050 kedua (<i>lumbar</i>), dalam satuan g.
az2	Nilai percepatan pada sumbu Z yang diperoleh dari sensor MPU6050 kedua (<i>lumbar</i>), dalam satuan g.
gx2	Nilai kecepatan sudut pada sumbu X yang diperoleh dari sensor MPU6050 kedua (<i>lumbar</i>), dalam satuan derajat per detik ($^{\circ}/s$).
gy2	Nilai kecepatan sudut pada sumbu Y yang diperoleh dari sensor MPU6050 kedua (<i>lumbar</i>), dalam satuan derajat per detik ($^{\circ}/s$).
gz2	Nilai kecepatan sudut pada sumbu Z yang diperoleh dari sensor MPU6050 kedua (<i>lumbar</i>), dalam satuan derajat per detik ($^{\circ}/s$).
pressure_hpa	Nilai tekanan yang diukur oleh sensor BMP280 dalam satuan hektopascal (hPa).
altitude_m	Nilai estimasi ketinggian yang dihitung oleh sensor BMP280 dalam satuan meter (m).
label	Kelas target yang menunjukkan teknik pengangkatan beban yang dilakukan oleh responden. Nilai label terdiri atas 1 untuk teknik pengangkatan yang benar dan 0 untuk teknik pengangkatan yang salah.

Data yang tidak valid turut dihapus untuk menjaga konsistensi *dataset*. Data tidak valid dapat berupa data yang tercatat ketika responden belum melakukan aktivitas, data setelah sensor dilepaskan, atau data yang hanya memuat sebagian informasi dari salah satu sensor. Setelah proses pembersihan selesai, format data diseragamkan agar sesuai untuk proses pengolahan selanjutnya. Penyeragaman format meliputi keseragaman penulisan tanggal, waktu, jenis data, dan struktur

kolom agar *dataset* dapat dibaca dan diproses secara konsisten oleh perangkat lunak analisis sesuai dengan ditunjukkan pada Tabel 4.5. Hasil data setelah dibersihkan ditunjukkan pada Tabel 4.6.

Tabel 4.6 Data *Subject* 01 Setelah Dibersihkan

<i>subject_id</i>	<i>date</i>	<i>time</i>	.	<i>gz2</i>	<i>pressure_hpa</i>	<i>altitude_m</i>
1	5/20/2026	5:32:37 PM	.	-0.672	1002.87	86.778
1	5/20/2026	5:32:37 PM	.	3.511	1002.88	86.687
1	5/20/2026	5:32:37 PM	.	3.313	1002.87	86.778
.	.	.	.	.	.	.
1	5/20/2026	5:34:22 PM	.	1.275	1002.90	86.533
1	5/20/2026	5:34:22 PM	.	7.443	1002.90	86.533
1	5/20/2026	5:34:22 PM	.	6.435	1002.90	86.533

Berdasarkan Tabel 4.7, data yang telah dibersihkan hanya memuat baris-baris yang sesuai dengan rentang pengambilan data dan memiliki informasi sensor yang lengkap. Data yang tidak relevan telah dihapus sehingga *dataset* menjadi lebih terstruktur dan siap digunakan pada tahap prapemrosesan berikutnya. Dengan demikian, proses pembersihan data berperan penting dalam memastikan bahwa hasil analisis dan klasifikasi didasarkan pada data yang valid, konsisten, dan representatif.

4.2.2 Pelabelan Data


Proses pelabelan data dilakukan secara manual dengan mencocokkan waktu perekaman sensor dengan rekaman video yang telah diambil selama proses pengambilan data. Pelabelan tersebut dilakukan untuk memastikan bahwa setiap baris data sensor memiliki kelas yang sesuai dengan kondisi postur responden saat melakukan aktivitas pengangkatan beban. Label kemudian dimasukkan ke dalam tabel data sesuai dengan hasil pengamatan terhadap perubahan postur yang terekam pada video. Dengan metode tersebut, setiap segmen data dapat diidentifikasi berdasarkan jenis teknik pengangkatan yang dilakukan oleh responden.

Jenis label yang digunakan dalam penelitian ini terdiri atas dua kelas, yaitu ‘benar’ untuk teknik pengangkatan yang benar dan ‘salah’ untuk teknik pengangkatan yang salah. Pemberian label didasarkan pada momen ketika responden mulai bergerak dari posisi awal menuju posisi pengangkatan, baik pada teknik yang benar maupun teknik yang salah. Sementara itu, proses pelabelan untuk satu segmen data dianggap selesai ketika responden kembali berdiri setelah meletakkan beban. Acuan tersebut digunakan agar label yang diberikan sesuai dengan kondisi gerakan yang sebenarnya terjadi selama aktivitas berlangsung.

Tabel 4.7 Sampel Hasil Pelabelan Data *Subject 01*

subject_id	date	time	.	pressure_hpa	altitude_m	label
1	5/20/2026	5:32:37 PM	.	1002.87	86.778	benar
1	5/20/2026	5:32:37 PM	.	1002.88	86.687	benar
1	5/20/2026	5:32:37 PM	.	1002.87	86.778	benar
.	.	.	.	.	.	.
1	5/20/2026	5:34:22 PM	.	1002.90	86.533	salah
1	5/20/2026	5:34:22 PM	.	1002.90	86.533	salah
1	5/20/2026	5:34:22 PM	.	1002.90	86.533	salah

Berdasarkan Tabel 4.8, setiap baris data telah diberi label sesuai dengan hasil observasi terhadap rekaman video. Data pada awal segmen menunjukkan label benar, sedangkan pada bagian akhir segmen menunjukkan label salah sesuai dengan jenis postur yang dilakukan oleh subjek. Hasil pelabelan ini menjadi dasar dalam proses analisis selanjutnya, terutama pada tahap ekstraksi fitur dan klasifikasi. Dengan adanya pelabelan yang terstruktur, data penelitian dapat digunakan secara lebih sistematis untuk membedakan pola gerakan pada teknik pengangkatan yang benar dan teknik pengangkatan yang salah.



Gambar 4.4 Perbandingan Distribusi Data

Distribusi jumlah data pada masing-masing kelas disajikan pada Gambar 4.4. Berdasarkan hasil pengelompokan, jumlah data pada kelas benar sebanyak 4.852 data, sedangkan jumlah data pada kelas salah sebanyak 4.028 data. Perbedaan jumlah data antar kelas menunjukkan bahwa distribusi data masih relatif berimbang, meskipun kelas benar memiliki jumlah yang lebih besar dibandingkan kelas salah. Informasi distribusi ini penting untuk mengetahui komposisi data yang digunakan dalam proses pelatihan dan pengujian model.

4.2.3 Ekstraksi Fitur

Pada tahap ini dilakukan ekstraksi fitur terhadap data sensor mentah yang berasal dari accelerometer dan gyroscope pada dua sensor, serta data pendukung berupa tekanan dan ketinggian. Ekstraksi fitur dilakukan untuk memperkaya informasi agar model lebih mudah melakukan prediksi. Data mentah umumnya masih bersifat kompleks, memiliki noise, dan kurang representatif apabila langsung digunakan oleh model pembelajaran mesin. Oleh karena itu, data sensor diubah menjadi fitur-fitur turunan yang lebih informatif, sehingga pola gerakan, rotasi, orientasi tubuh, serta perubahan sinyal dari waktu ke waktu dapat dikenali dengan lebih baik.

Contoh data:

$$\begin{aligned} ax1 &= 0.60522, ay1 = 0.052, az1 = 0.40283 \\ gx1 &= -11.153, gy1 = 87.863, gz1 = -5.656 \\ ax2 &= 0.73706, ay2 = 0.42188, az2 = 0.36377 \\ gx2 &= -89.718, gy2 = 91.237, gz2 = 45.221 \end{aligned}$$

Ekstraksi fitur yang digunakan pada kode tersebut terdiri atas beberapa jenis, yaitu:

1. Fitur magnitudo

Fitur ini menghitung besar vektor dari tiga sumbu sensor untuk merepresentasikan intensitas gerakan atau rotasi secara keseluruhan.

Sensor 1:

$$\begin{aligned} acc_mag1 &= \sqrt{0.60522^2 + 0.052^2 + 0.40283^2} \\ &= \sqrt{0.366291 + 0.002704 + 0.162274} = \sqrt{0.531269} \\ &= 0.728881 \\ acc_mag2 &= \sqrt{0.73706^2 + 0.42188^2 + 0.36377^2} \\ &= \sqrt{0.543259 + 0.178394 + 0.132163} = \sqrt{0.853816} \\ &= 0.923888 \end{aligned}$$

Sensor 2:

$$\begin{aligned} gyro_mag1 &= \sqrt{(-11.153)^2 + 87.863^2 + (-5.656)^2} \\ &= \sqrt{124.389 + 7719.827 + 31.990} = \sqrt{7876.206} \\ &= 88.748445 \\ gyro_mag2 &= \sqrt{(-89.718)^2 + 91.237^2 + 45.221^2} \\ &= \sqrt{8049.422 + 8324.227 + 2044.006} = \sqrt{18417.655} \\ &= 135.714585 \end{aligned}$$

2. Fitur selisih antar sensor (*differential feature*)

Fitur ini menghitung perbedaan nilai sensor pada titik pengukuran yang

berbeda, sehingga dapat menggambarkan ketidaksamaan gerakan antar sensor.

Sensor Accelerometer:

$$diff_ax = 0.60522 - 0.73706 = -0.13184$$

$$diff_ay = 0.052 - 0.42188 = -0.36988$$

$$diff_az = 0.40283 - 0.36377 = 0.03906$$

Sensor Gyroscope:

$$diff_gx = -11.153 - (-89.718) = 78.565$$

$$diff_gy = 87.863 - 91.237 = -3.374$$

$$diff_gz = -5.656 - 45.221 = -50.877$$

3. Fitur orientasi tubuh (*roll dan pitch*)

Fitur ini mengubah data akselerometer menjadi informasi sudut kemiringan yang lebih mudah diinterpretasikan secara postural.

Sensor1:

$$roll1 = \arctan 2 \left(0.052, \sqrt{0.60522^2 + 0.40283^2} \right)$$

$$= \arctan 2 (0.052, 0.727 \dots) = 0.071403$$

$$pitch1 = \arctan 2 \left(-0.60522, \sqrt{0.052^2 + 0.40283^2} \right)$$

$$= \arctan 2 (-0.60522, 0.406 \dots) = -0.979720$$

Sensor 2:

$$roll2 = \arctan 2 \left(0.42188, \sqrt{0.73706^2 + 0.36377^2} \right)$$

$$= \arctan 2 (0.42188, 0.82181) = 0.474210$$

$$pitch2 = \arctan 2 \left(-0.73706, \sqrt{0.42188^2 + 0.36377^2} \right)$$

$$= \arctan 2 (-0.73706, 0.5567) = -0.923606$$

4. Fitur selisih sudut antar sensor

Fitur ini menunjukkan perbedaan orientasi antar sensor dan berguna untuk mendeteksi ketidaksejajaran postur.

Selisih Sudut Antar sensor:

$$diff_roll = roll1 - roll2 = 0.071403 - 0.474210 = -0.402807$$

$$diff_pitch = pitch1 - pitch2 = -0.979720 - (-0.923606) = -0.056115$$

5. Fitur *rolling* window

Fitur ini menghitung ringkasan statistik lokal berupa rata-rata bergerak dan standar deviasi bergerak untuk menangkap tren dan variasi sinyal dalam jendela waktu pendek. *Rolling mean* dan *rolling standard deviation* dihitung dari 3 data terakhir pada urutan waktu.

Rolling mean:

Nilai *pitch1* tiga baris pertama:

$$-0.979720, -0.978987, -1.144401$$

Maka *rolling mean* baris ketiga :

$$\begin{aligned} pitch1_{rm3} &= \frac{-0.979720 + (-0.978987) + (-1.144401)}{3} \\ &= \frac{-3.103108}{3} = -1.034369 \end{aligned}$$

Dan *rolling* standar *deviation* nya adalah:

$$\begin{aligned} s^2 &= \frac{0.018161}{3 - 1} = 0.009081 \\ pitch1_{rs3} &= \sqrt{0.009081} = 0.095291 \end{aligned}$$

Tabel 4.8 Ekstraksi Fitur Data

No	Nama Fitur	Jenis Ekstraksi Fitur	Penjelasan Singkat
1	<i>acc_mag1</i>	Magnitudo	Intensitas gerakan total sensor 1
2	<i>acc_mag2</i>	Magnitudo	Intensitas gerakan total sensor 2
3	<i>gyro_mag1</i>	Magnitudo	Intensitas rotasi total sensor 1
4	<i>gyro_mag2</i>	Magnitudo	Intensitas rotasi total sensor 2
5	<i>diff_ax</i>	Diferensial	Selisih accelerometer sumbu x
6	<i>diff_ay</i>	Diferensial	Selisih accelerometer sumbu y
7	<i>diff_az</i>	Diferensial	Selisih accelerometer sumbu z
8	<i>diff_gx</i>	Diferensial	Selisih gyroscope sumbu x
9	<i>diff_gy</i>	Diferensial	Selisih gyroscope sumbu y
10	<i>diff_gz</i>	Diferensial	Selisih gyroscope sumbu z

Tabel 4.8 Ekstraksi Fitur Data (Lanjutan)

No	Nama Fitur	Jenis Ekstraksi Fitur	Penjelasan Singkat
11	<i>roll1</i>	Orientasi tubuh	Sudut <i>roll</i> sensor 1
12	<i>pitch1</i>	Orientasi tubuh	Sudut <i>pitch</i> sensor 1
13	<i>roll2</i>	Orientasi tubuh	Sudut <i>roll</i> sensor 2
14	<i>pitch2</i>	Orientasi tubuh	Sudut <i>pitch</i> sensor 2
15	<i>diff_roll</i>	Selisih sudut	Perbedaan <i>roll</i> antar sensor
16	<i>diff_pitch</i>	Selisih sudut	Perbedaan <i>pitch</i> antar sensor
17	<i>*_rm3</i>	<i>Rolling</i> mean	Rata-rata bergerak 3 sampel
18	<i>*_rs3</i>	<i>Rolling</i> std	Variasi lokal 3 sampel

Hasil ekstraksi fitur menghasilkan data baru yang lebih informatif dibandingkan data sensor mentah. Pada kode ini, data awal yang berjumlah 21 kolom bertambah menjadi 53 kolom setelah proses ekstraksi fitur. Fitur baru tersebut terdiri dari 16 fitur turunan dan 16 fitur *rolling*. Dengan demikian, total informasi yang tersedia bagi model menjadi lebih kaya, sehingga model memiliki dasar yang lebih kuat untuk melakukan klasifikasi atau prediksi.

4.2.4 Normalisasi Data

Pada penelitian ini, metode penskalaan yang digunakan adalah Robust Scaler. Metode tersebut dipilih karena lebih tahan terhadap nilai ekstrem atau pencilan dibandingkan metode penskalaan lain. Dengan demikian, distribusi data dapat disesuaikan tanpa terlalu dipengaruhi oleh nilai yang berada jauh dari kecenderungan umum data. Hasil normalisasi digunakan sebagai masukan pada tahap ekstraksi fitur dan klasifikasi.

Perbandingan data sebelum dan sesudah penskalaan ditunjukkan pada Tabel 4.10 dan Tabel 4.9. Sebelum dilakukan normalisasi, setiap fitur masih memiliki rentang nilai yang berbeda-beda, misalnya nilai percepatan, kecepatan sudut, sudut orientasi, serta fitur turunan lainnya. Perbedaan skala tersebut dapat menyebabkan fitur dengan nilai yang lebih besar mendominasi proses pembelajaran model. Oleh karena itu, seluruh fitur numerik dinormalisasi agar

berada pada skala yang lebih seragam. Sampel data sebelum *Scaling* ditampilkan pada Tabel 4.9.

Tabel 4.9 Sampel Data Sebelum *Scaling*

Baris	ax1	ay1	az1	gx1	.	diff_pitch_rs3
1	0.92993	-0.11963	0.45093	-31.580	.	0.000000
2	-0.39795	0.15088	1.07080	25.802	.	0.419596
3	-0.33545	0.07568	1.18555	-6.802	.	0.305120
4	0.39551	0.01929	0.94922	-19.603	.	0.136803
5	0.17651	0.07275	1.03760	-2.046	.	0.050139
.	.	.	.	.	.	.
8510	0.55884	-0.02222	0.94312	-1.794	.	0.137272
8511	0.50342	-0.05640	1.01636	-12.168	.	0.060264
8512	0.56030	-0.04004	0.92871	-0.603	.	0.063627
8513	0.52515	-0.02295	0.94775	1.435	.	0.057655
8514	0.46509	-0.00879	0.65088	-3.840	.	0.051952

Perhitungan Robust Scaler dilakukan dengan menggunakan median dan rentang antarkuartil (IQR) pada masing-masing fitur. Sebagai contoh, pada sampel data baris ke-1 untuk fitur ax1, nilai asli sebesar 0.92993 diubah menggunakan median 0.656490 dan IQR 0.723025, sehingga diperoleh hasil sebagai berikut:

$$X_{scaled} = \frac{0.92993 - 0.656490}{0.723025}$$

$$X_{scaled} = 0.378189$$

Setelah dilakukan penskalaan menggunakan *Robust Scaler*, nilai setiap fitur berubah menjadi bentuk yang lebih seimbang dan umumnya berada di sekitar nol. Hasil transformasi ini menunjukkan bahwa data tidak lagi bergantung pada skala asli masing-masing fitur, melainkan telah disesuaikan berdasarkan median dan rentang antarkuartil. Pada data hasil normalisasi, beberapa nilai menjadi positif dan sebagian lainnya menjadi negatif, yang menunjukkan posisi data terhadap pusat distribusi. Sampel data setelah *Scaling* ditampilkan pada Tabel 4.10.

Tabel 4.10 Sampel Data Setelah *Scaling*

Indeks	ax1	ay1	az1	gx1	.	diff_pitch_rs3
1	0.378189	-0.778572	-0.567601	-2.001997	.	-0.651987
2	-1.458373	0.846015	0.763106	1.693749	.	1.841957
3	-1.371930	0.394391	1.009446	-0.406144	.	1.161551
4	-0.360956	0.055732	0.502104	-1.230606	.	0.161128
5	-0.663850	0.376794	0.691834	-0.099829	.	-0.353979
.	.	.	.	.	.	.
8510	-0.135058	-0.193562	0.489009	-0.083599	.	0.163912
8511	-0.211708	-0.398835	0.646237	-0.751747	.	-0.293799
8512	-0.133038	-0.300583	0.458074	-0.006891	.	-0.273807
8513	-0.181653	-0.197946	0.498948	0.124368	.	-0.309305
8514	-0.264721	-0.112906	-0.138358	-0.215374	.	-0.343198

Berdasarkan perbandingan pada kedua tabel tersebut, terlihat bahwa proses normalisasi telah berhasil mengubah skala data tanpa menghilangkan pola hubungan antar fitur. Data yang telah dinormalisasi menjadi lebih sesuai untuk digunakan dalam proses pembelajaran model karena setiap fitur memiliki kontribusi yang lebih seimbang. Selain itu, penggunaan *Robust Scaler* membantu mengurangi pengaruh *outlier* sehingga hasil pelatihan model diharapkan menjadi lebih stabil. Dengan demikian, tahap normalisasi ini menjadi bagian penting dalam menjaga kualitas data sebelum masuk ke tahap analisis berikutnya.

4.3 Pemodelan *Random Forest*

Setelah melalui tahap *preprocessing*, *dataset* yang telah dibersihkan dan ditransformasikan selanjutnya digunakan untuk membangun model klasifikasi. Pada penelitian ini, algoritma *Random Forest* dipilih karena mampu menangani data berdimensi tinggi, memiliki kemampuan generalisasi yang baik, serta relatif tahan terhadap *overfitting*. Tahap pemodelan mencakup proses pembagian data menggunakan metode *Leave One Subject Out* (LOSO) dan pembentukan model *Random Forest* yang digunakan untuk mengklasifikasikan teknik pengangkatan beban ke dalam kategori benar atau salah.

4.3.1 Pembagian Data

Pembagian data pada penelitian ini dilakukan menggunakan metode *Leave One Subject Out* (LOSO). Metode tersebut merupakan salah satu teknik validasi silang yang dirancang untuk mengevaluasi kemampuan model dalam melakukan generalisasi terhadap data dari subjek yang belum pernah dilihat sebelumnya. Pada setiap iterasi pengujian, data dari satu subjek digunakan sebagai data uji, sedangkan data dari seluruh subjek lainnya digunakan sebagai data latih. Proses ini dilakukan secara berulang hingga seluruh subjek memperoleh giliran sebagai data uji sebanyak satu kali.

Dataset penelitian terdiri atas data dari 20 subjek yang telah melalui tahap pembersihan data, pelabelan, ekstraksi fitur, dan normalisasi. Pada setiap fold LOSO, data latih dibentuk dari gabungan data milik 19 subjek, sedangkan data milik satu subjek sisanya digunakan sebagai data uji. Skema pembagian data tersebut memastikan bahwa tidak terdapat data dari subjek yang sama pada proses pelatihan dan pengujian model. Dengan demikian, hasil evaluasi yang diperoleh dapat menggambarkan kemampuan model dalam mengenali pola gerakan dari individu yang belum pernah digunakan selama proses pelatihan.

Proses pembagian data diawali dengan pemisahan data berdasarkan identitas subjek. Selanjutnya, data dengan label berdiri tidak dilibatkan dalam proses klasifikasi sehingga hanya tersisa dua kelas, yaitu teknik pengangkatan yang benar dan teknik pengangkatan yang salah. Setelah proses penyaringan selesai, dilakukan pembentukan fitur turunan dan fitur berbasis *rolling window* untuk setiap subjek. Tahap berikutnya adalah normalisasi data menggunakan metode *Robust Scaler*. Parameter normalisasi diperoleh dari data latih dan kemudian diterapkan pada data uji untuk menghindari terjadinya kebocoran data (*data leakage*) selama proses evaluasi.

Pemilihan metode LOSO didasarkan pada karakteristik data yang berasal dari banyak subjek dengan pola gerakan yang berbeda-beda. Pada penelitian klasifikasi aktivitas manusia, data dari subjek yang sama cenderung memiliki karakteristik yang mirip sehingga penggunaan metode pembagian data secara acak berpotensi menghasilkan nilai evaluasi yang terlalu optimistis. Kondisi tersebut

terjadi karena sebagian pola gerakan yang digunakan saat pengujian telah dipelajari sebelumnya selama proses pelatihan. Oleh karena itu, metode LOSO dipilih karena mampu memberikan evaluasi yang lebih realistis terhadap kemampuan model dalam mengenali pola gerakan dari subjek baru.

Selain memberikan evaluasi yang lebih objektif, metode LOSO juga sesuai dengan skenario implementasi sistem pada kondisi nyata. Sistem yang dikembangkan diharapkan mampu mendeteksi teknik pengangkatan beban pada pengguna yang belum pernah terlibat dalam proses pelatihan model. Dengan menggunakan LOSO, setiap subjek diuji secara independen sehingga tingkat generalisasi model dapat dievaluasi secara menyeluruh. Pada penelitian ini, proses LOSO menghasilkan 20 fold pengujian yang sesuai dengan jumlah subjek yang digunakan dalam penelitian.

4.3.2 Model *Random Forest*

Model klasifikasi pada penelitian ini dibangun menggunakan algoritma *Random Forest*. Algoritma tersebut dipilih karena mampu menggabungkan sejumlah *decision tree* untuk menghasilkan model yang lebih stabil dan memiliki kemampuan generalisasi yang baik. Parameter yang digunakan dalam pembentukan model ditunjukkan pada Tabel 4.11.

Tabel 4.11 Parameter Model *Random Forest*

Parameter	Nilai
<i>n_estimators</i>	200
<i>max_depth</i>	None
<i>min_samples_split</i>	5
<i>min_samples_leaf</i>	1
<i>max_features</i>	'sqrt'
<i>bootstrap</i>	True
<i>class_weight</i>	'balanced'
<i>criterion</i>	'gini'
<i>random_state</i>	42

Parameter *n_estimators* sebesar 200 menunjukkan bahwa model

membangun 200 *decision tree*. Parameter *criterion* menggunakan indeks *Gini* untuk menentukan pemisahan terbaik pada setiap *node*, sedangkan *class_weight* diatur menjadi *balanced* untuk mengatasi perbedaan jumlah data antar kelas. Selain itu, parameter *bootstrap* digunakan untuk menghasilkan variasi data latih pada setiap pohon sehingga meningkatkan keragaman model dan mengurangi risiko *overfitting*.

Jumlah fitur yang digunakan sebagai masukan model adalah sebanyak 46 fitur. Oleh karena itu, jumlah fitur yang dievaluasi pada setiap proses pemisahan *node* dihitung menggunakan persamaan berikut:

$$\begin{aligned} \max_features &= \sqrt{46} \\ \max_features &= 6.78 \approx 7 \end{aligned}$$

Berdasarkan hasil perhitungan tersebut, setiap *node* akan mempertimbangkan sekitar tujuh fitur yang dipilih secara acak untuk menentukan pemisahan terbaik. Mekanisme ini membantu meningkatkan variasi antar pohon dan menghasilkan model yang lebih *robust* terhadap data baru. Setelah seluruh pohon terbentuk, hasil prediksi digabungkan menggunakan metode *majority voting* untuk menghasilkan keputusan klasifikasi akhir.

Sebagai ilustrasi proses pembentukan *decision tree*, digunakan delapan data sampel yang berasal dari hasil ekstraksi fitur. Data sampel yang digunakan ditunjukkan pada Tabel 4.12.

Tabel 4.12 Data Sampel untuk Pembentukan *Node*

No	<i>pitch1</i>	Label
1	-0.979720	salah
2	-0.978987	salah
3	-1.144401	salah
4	-1.228491	benar
5	-1.161389	benar
6	-0.293815	benar
7	-0.144915	benar
8	0.055447	benar

Berdasarkan delapan data sampel tersebut, terdapat lima data dengan label benar dan tiga data dengan label salah. Probabilitas masing-masing kelas dihitung sebagai berikut.

$$P(benar) = \frac{5}{8} = 0.625$$

$$P(salah) = \frac{3}{8} = 0.375$$

Sebelum dilakukan pemisahan *Node*, tingkat ketidakmurnian (*impurity*) pada seluruh data dihitung menggunakan indeks *Gini*.

$$Gini(D) = 1 - \left(\frac{5}{8}\right)^2 - \left(\frac{3}{8}\right)^2 = 1 - \frac{25}{64} - \frac{9}{64} = 1 - \frac{34}{64} = 0.46875$$

Nilai 0,46875 menunjukkan bahwa *Node* awal masih mengandung campuran dua kelas sehingga diperlukan proses pemisahan untuk meningkatkan homogenitas data.

Misalkan algoritma memilih salah satu kandidat threshold pada fitur *pitch1*, yaitu:

$$t = -0.646451$$

Aturan pemisahan yang digunakan adalah sebagai berikut.

$$D_{left} = x \mid pitch1 \leq -0.646451$$

$$D_{right} = x \mid pitch1 > -0.646451$$

Data yang masuk ke *Node* kiri ditunjukkan pada Tabel 4.13.

Tabel 4.13 Hasil Pemisalah *Node* Kiri

No	<i>pitch1</i>	Label
1	-0.979720	salah
2	-0.978987	salah
3	-1.144401	salah
4	-1.228491	benar
5	-1.161389	benar

Jumlah data pada *Node* kiri adalah:

$$N_{left} = 5$$

Sementara itu, data yang masuk ke *Node* kanan ditunjukkan pada Tabel 4.14.

Tabel 4.14 Hasil Pemisalah *Node* Kanan

No	<i>pitch1</i>	Label
6	-0.293815	benar
7	-0.144915	benar
8	0.055447	benar

Jumlah data pada *Node* kanan adalah:

$$N_{right} = 3$$

Selanjutnya, nilai Gini pada masing-masing *Node* dihitung. Untuk *Node* kiri diperoleh:

$$Gini(D_{left}) = -\left(\frac{3}{5}\right)^2 \left(\frac{2}{5}\right)^2 = 1 - \frac{9}{25} - \frac{4}{25} = 1 - \frac{13}{25} = 0.48$$

Pada *Node* kanan, seluruh data berasal dari kelas yang sama sehingga nilai Gini menjadi:

$$Gini(D_{right}) = 1 - \left(\frac{3}{3}\right)^2 \left(\frac{0}{3}\right)^2 = 1 - 1 - 0 = 0$$

Nilai impurity setelah proses split dihitung menggunakan rata-rata tertimbang berdasarkan jumlah data pada masing-masing *Node*.

$$Gini_{split} = \frac{5}{8}(0.48) + \frac{3}{8}(0) = 0.30$$

Besarnya penurunan impurity akibat proses pemisahan dihitung sebagai berikut.

$$\Delta Gini = Gini(D) - Gini_{split} = 0.46875 - 0.30 = 0.16875$$

Nilai penurunan impurity sebesar 0,16875 menunjukkan bahwa pemisahan menggunakan fitur *pitch1* pada threshold $-0,646451$ mampu meningkatkan

homogenitas data. Oleh karena itu, kandidat pemisahan tersebut berpeluang dipilih sebagai *Node* pada decision tree.

Untuk mengurangi bias terhadap kelas mayoritas, digunakan parameter `'class_weight'='balanced'`. Bobot masing-masing kelas dihitung sebagai berikut.

$$w_{benar} = \frac{8}{2 \times 5} = 0.8$$

$$w_{salah} = \frac{8}{2 \times 3} = 1.333$$

Nilai bobot yang lebih besar pada kelas salah menyebabkan kesalahan klasifikasi pada kelas tersebut memperoleh penalti yang lebih tinggi selama proses pelatihan model. Dengan demikian, model didorong untuk memberikan perhatian yang lebih seimbang terhadap kedua kelas.

Selain menggunakan pembobotan kelas, *Random Forest* juga menerapkan teknik *bootstrap* sampling. Karena parameter `'bootstrap=True'`, setiap decision tree dibangun menggunakan sampel acak yang diambil dengan pengembalian (*sampling with replacement*). Sebagai ilustrasi, dari delapan data awal:

$$D = 1,2,3,4,5,6,7,8$$

dapat diperoleh sampel *bootstrap* untuk pohon pertama:

$$D_1 = 1,3,3,5,6,6,7,8$$

dan untuk pohon kedua:

$$D_2 = 2,2,4,4,5,7,8,8$$

Karena pengambilan dilakukan dengan pengembalian, suatu data dapat muncul lebih dari satu kali pada satu pohon dan tidak muncul sama sekali pada pohon lainnya. Mekanisme ini menghasilkan keragaman data latih yang berkontribusi terhadap peningkatan performa model secara keseluruhan.

Proses klasifikasi akhir dilakukan menggunakan mekanisme *majority voting*. Misalkan tiga pohon pertama menghasilkan prediksi sebagai berikut.

$$T_1 = benar$$

$$T_2 = salah$$

$$T_3 = benar$$

Jumlah suara yang diperoleh adalah:

$$benar = 2$$

$$salah = 1$$

Karena kelas benar memperoleh jumlah suara terbanyak, maka prediksi akhir ditentukan sebagai berikut.

$$\hat{y} = benar$$

Pada model yang digunakan dalam penelitian ini, proses voting dilakukan terhadap 200 decision tree. Dengan jumlah pohon yang besar, keputusan klasifikasi yang dihasilkan menjadi lebih stabil dan memiliki kemampuan generalisasi yang lebih baik terhadap data baru.

4.4 Evaluasi Sistem Deteksi Posisi Angkat Beban

Setelah model *Random Forest* berhasil dibangun, tahap selanjutnya adalah melakukan evaluasi untuk mengetahui sistem yang dikembangkan. Evaluasi dilakukan terhadap performa sistem secara keseluruhan ketika diimplementasikan pada prototipe deteksi posisi angkat beban berbasis *Internet of Things* (IoT). Pada tahap ini dilakukan analisis terhadap hasil prediksi model, pengujian sistem secara *real-time*, serta pembahasan mengenai kelebihan, keterbatasan, dan potensi pengembangan sistem pada penelitian selanjutnya.

4.4.1 Hasil Evaluasi Model

Evaluasi model dilakukan untuk mengukur kemampuan sistem dalam membedakan teknik pengangkatan beban yang benar dan teknik pengangkatan beban yang salah. Berdasarkan hasil pengujian keseluruhan, model memperoleh nilai akurasi sebesar 83,32%.

Tabel 4.15 Nilai Akurasi Per-Subject

Fold	ID Subject	Akurasi (%)
1	01	85.9
2	02	85.7
3	04	77.7
4	05	80.0
5	06	82.4
6	07	82.3
7	08	84.6
8	11	76.0
9	12	68.6

Tabel 4.15 Nilai Akurasi Per-Subject (Lanjutan)


Fold	ID Subject	Akurasi (%)
10	13	70.4
11	14	94.8
12	16	96.2
13	17	95.5
14	18	95.2
15	19	72.3
16	20	94.0
17	21	77.7
18	22	94.4
19	23	86.6
20	24	95.3

Apabila dilihat berdasarkan subjek, akurasi model berada pada rentang 68,62% hingga 96,20% dengan rata-rata akurasi sebesar 84,80%. Sebanyak tujuh subjek memperoleh akurasi di atas 90 persen, tujuh subjek berada pada rentang 80 hingga 90 persen, dan enam subjek lainnya berada di bawah 80 persen. Hasil ini menunjukkan bahwa performa model masih dipengaruhi oleh variasi pola gerakan antarresponden.

Tabel 4.16 *Classification Report*


Label	Precision	Recall	F1-score	Jumlah Label
Salah	0.83	0.79	0.81	4028
Benar	0.83	0.87	0.85	4852
Total Label				8880

Berdasarkan hasil klasifikasi yang ditampilkan pada Tabel 4.18, kelas benar memperoleh nilai *precision* sebesar 0,83, *recall* sebesar 0,87, dan *F1-score* sebesar 0,85. Sementara itu, kelas salah memperoleh nilai *precision* sebesar 0,83, *recall* sebesar 0,79, dan *F1-score* sebesar 0,81. Hasil tersebut menunjukkan bahwa model lebih baik dalam mengenali kelas benar dibandingkan kelas salah.



Gambar 4.5 *Confusion matrix*

Hal ini juga terlihat pada *confusion matrix* pada Gambar 4.5, di mana sebanyak 4.212 data kelas benar berhasil diprediksi dengan tepat, sedangkan sebanyak 3.187 data kelas salah juga berhasil diklasifikasikan dengan benar. Namun, masih terdapat 841 data kelas salah yang diprediksi sebagai kelas benar dan 640 data kelas benar yang diprediksi sebagai kelas salah. Kondisi tersebut menunjukkan bahwa kesalahan klasifikasi masih terjadi pada kedua kelas, meskipun proporsinya relatif tidak jauh berbeda.



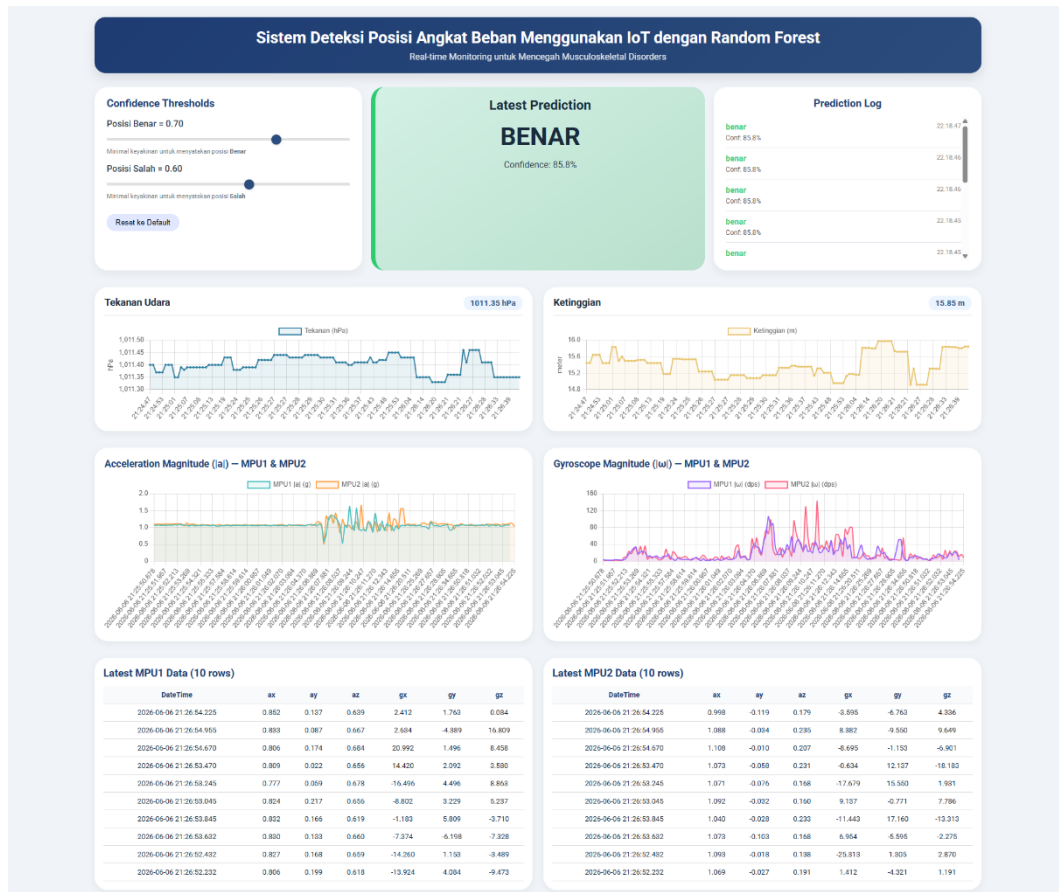
Gambar 4.6 *Features Importance*

Hasil analisis *feature importance* pada Gambar 4.6 menunjukkan bahwa fitur yang paling berpengaruh dalam proses klasifikasi adalah *pitch1*, *pitch1_rs3*, *ax1*, *pitch2*, dan *pitch1_rm3*. Dominasi fitur tersebut menunjukkan bahwa orientasi tubuh dan percepatan pada sensor yang ditempatkan di bagian torakal dan lumbal memiliki kontribusi yang besar terhadap proses pengenalan pola pengangkatan beban. Selain itu, beberapa fitur turunan yang menggunakan pengolahan jendela bergerak juga memberikan pengaruh yang signifikan, sehingga informasi temporal dari gerakan responden turut membantu model dalam membedakan pola gerakan. Di sisi lain, fitur tekanan dan ketinggian memiliki nilai importance yang lebih rendah, tetapi tetap memberikan kontribusi terhadap performa model secara keseluruhan. Dengan demikian, hasil evaluasi menunjukkan bahwa sistem telah mampu melakukan deteksi posisi angkat beban dengan performa yang cukup baik, meskipun penyempurnaan masih diperlukan untuk meningkatkan kestabilan hasil pada tiap subjek.

4.4.2 Pengujian Sistem Deteksi Posisi Angkat Beban


Pengujian sistem dilakukan untuk mengevaluasi kemampuan model dalam mendeteksi teknik pengangkatan beban secara *real-time* melalui *website* yang

telah dirancang. Pada tahap ini, hasil prediksi model dibandingkan dengan label aktual untuk menilai ketepatan klasifikasi yang dihasilkan oleh algoritma *Random Forest*. Selain itu, respons *buzzer* juga diamati untuk memastikan bahwa sistem memberikan umpan balik yang sesuai terhadap kondisi teknik pengangkatan yang terdeteksi, baik pada gerakan yang benar maupun gerakan yang salah.



Gambar 4.7 Tampilan *Website* Ketika Memprediksi Benar

Tampilan *website* ketika sistem memprediksi kelas benar ditunjukkan pada Gambar 4.7, sedangkan tampilan *website* ketika sistem memprediksi kelas salah ditunjukkan pada Gambar 4.8.



Gambar 4.8 Tampilan Website Ketika Memprediksi Salah

Pengujian dilakukan terhadap lima subjek dengan empat skenario pengujian pada masing-masing subjek. Setiap skenario terdiri atas gerakan mengangkat dan menurunkan beban dengan teknik yang benar maupun salah. Hasil pengujian sistem secara lengkap disajikan pada Tabel 4.17.

Tabel 4.17 Tabel Pengujian Data.

ID	Uji	Label Aktual	Prediksi Model	Confidence (%)	Respons Buzzer	Status Prediksi
T01	1	Angkat Benar	Benar	92.5	OFF	Sesuai
		Turun Benar	Benar	98.3	OFF	Sesuai
	2	Angkat Salah	Salah	94.6	ON	Sesuai
		Turun Salah	Salah	88.6	ON	Sesuai
	3	Angkat Benar	Benar	97.2	OFF	Sesuai

Tabel 4.17 Tabel Pengujian Data.

ID	Uji	Label Aktual	Prediksi Model	Confidence (%)	Respons Buzzer	Status Prediksi
	4	Turun Salah	Salah	90.7	ON	Sesuai
		Angkat Salah	Salah	97.3	ON	Sesuai
		Turun Benar	Benar	84.2	OFF	Sesuai
T02	1	Angkat Benar	Benar	84.5	OFF	Sesuai
		Turun Benar	Benar	87	OFF	Sesuai
	2	Angkat Salah	Salah	78.6	ON	Sesuai
		Turun Salah	Salah	89	ON	Sesuai
	3	Angkat Benar	Benar	82.1	OFF	Sesuai
		Turun Salah	Salah	84.4	ON	Sesuai
	4	Angkat Salah	Salah	81.2	ON	Sesuai
		Turun Benar	Benar	90	OFF	Sesuai
T03	1	Angkat Benar	Benar	80.6	OFF	Sesuai
		Turun Benar	Benar	79.9	OFF	Sesuai
	2	Angkat Salah	Salah	78.5	ON	Sesuai
		Turun Salah	Salah	86.4	ON	Sesuai
	3	Angkat Benar	Benar	71.9	OFF	Sesuai
		Turun Salah	Salah	85.5	OFF	Tidak Sesuai
	4	Angkat Salah	Salah	73.8	ON	Sesuai
		Turun Benar	Benar	78.2	OFF	Sesuai
T04	1	Angkat Benar	Benar	73.9	OFF	Sesuai
		Turun Benar	Benar	71.2	OFF	Sesuai

Tabel 4.17 Tabel Pengujian Data.

ID	Uji	Label Aktual	Prediksi Model	Confidence (%)	Respons Buzzer	Status Prediksi
	2	Angkat Salah	Salah	78.5	ON	Sesuai
		Turun Salah	Salah	83.7	ON	Sesuai
	3	Angkat Benar	Benar	82.6	OFF	Sesuai
		Turun Salah	Salah	80.8	ON	Sesuai
	4	Angkat Salah	Salah	76.3	ON	Sesuai
		Turun Benar	Tidak Pasti	63.0	OFF	Tidak Sesuai
T05	1	Angkat Benar	Benar	98.2	OFF	Sesuai
		Turun Benar	Benar	99.7	OFF	Sesuai
	2	Angkat Salah	Salah	94.4	ON	Sesuai
		Turun Salah	Salah	99	ON	Sesuai
	3	Angkat Benar	Benar	96.1	OFF	Sesuai
		Turun Salah	Salah	96.6	ON	Sesuai
	4	Angkat Salah	Salah	95.4	ON	Sesuai
		Turun Benar	Benar	97.7	OFF	Sesuai

Berdasarkan hasil pengujian pada 40 aktivitas yang diamati, sistem mampu memberikan prediksi yang sesuai dengan label aktual pada 38 aktivitas (95%), sedangkan 2 aktivitas (5%) menghasilkan keluaran yang tidak sesuai. Ketidaksesuaian pertama terjadi pada subjek T03 saat aktivitas Turun Salah, di mana model berhasil mengklasifikasikan gerakan sebagai salah, namun *buzzer* tidak aktif sehingga keluaran sistem tidak sesuai dengan rancangan. Ketidaksesuaian kedua terjadi pada subjek T04 saat aktivitas Turun Benar, di mana sistem menghasilkan status Tidak Pasti sehingga prediksi tidak sesuai dengan label aktual.

Nilai *confidence* hasil prediksi berkisar antara 63,0% hingga 99,7%, dengan rata-rata *confidence* sebesar 86,8%. Nilai tersebut menunjukkan bahwa sebagian besar prediksi yang dihasilkan model memiliki tingkat keyakinan yang cukup tinggi. Tingginya nilai *confidence* juga menunjukkan bahwa fitur-fitur yang digunakan mampu merepresentasikan pola gerakan pengangkatan beban dengan baik.

Status Tidak Pasti muncul karena nilai probabilitas prediksi tidak memenuhi batas threshold yang telah ditentukan pada sistem. Pada penelitian ini, kelas Benar dinyatakan valid apabila memiliki probabilitas minimal 65%, sedangkan kelas Salah dinyatakan valid apabila memiliki probabilitas minimal 60%. Jika nilai probabilitas yang dihasilkan model berada di bawah ambang batas tersebut, sistem tidak memberikan keputusan klasifikasi dan menampilkan status Tidak Pasti. Mekanisme ini diterapkan untuk mengurangi risiko pemberian umpan balik yang keliru kepada pengguna ketika tingkat keyakinan model rendah.

Respons sistem terhadap gerakan yang benar dan salah juga menunjukkan bahwa *buzzer* berfungsi sesuai dengan rancangan. Ketika sistem mengenali teknik pengangkatan yang benar, *buzzer* berada pada kondisi OFF. Sebaliknya, ketika sistem mengenali teknik pengangkatan yang salah, *buzzer* aktif sebagai bentuk peringatan kepada pengguna. Hasil ini menunjukkan bahwa sistem tidak hanya mampu melakukan klasifikasi, tetapi juga mampu memberikan umpan balik secara langsung sehingga pengguna dapat segera memperbaiki teknik pengangkatan yang dilakukan.

Secara keseluruhan, hasil pengujian menunjukkan bahwa sistem mampu mendeteksi teknik pengangkatan beban dengan tingkat kesesuaian yang tinggi. Integrasi antara sensor, model *Random Forest*, *website* monitoring, dan *buzzer* dapat bekerja sesuai dengan fungsi yang dirancang. Oleh karena itu, sistem yang dikembangkan telah menunjukkan kemampuan yang memadai sebagai prototipe deteksi teknik pengangkatan beban berbasis sensor dan *machine learning*.



Gambar 4.9 Pengujian Sistem Terhadap *Subject*

Waktu respons sistem selama pengujian menunjukkan adanya sedikit keterlambatan pada beberapa kondisi. Keterlambatan tersebut terutama dipengaruhi oleh kestabilan jaringan saat proses pengiriman data dari perangkat ke server *website*. Meskipun demikian, waktu respons yang dihasilkan masih berada dalam batas yang dapat diterima untuk kebutuhan pengujian prototipe. Dengan demikian, sistem tetap mampu menampilkan hasil deteksi dan memberikan peringatan kepada pengguna secara fungsional dan mendekati kondisi *real-time*.

4.4.3 Analisis Hasil Penelitian

Berdasarkan hasil perancangan dan pengembangan, sistem deteksi posisi angkat beban berbasis *Internet of Things* (IoT) berhasil dibuat untuk melakukan pengukuran dan pemantauan posisi tubuh secara *real-time* menggunakan sensor inersia. Penggunaan sensor MPU6050 dan BMP280 yang terintegrasi dengan mikrokontroler ESP8266 serta antarmuka *website* berbasis Flask memberikan kemudahan dalam proses akuisisi, pemantauan, dan penyimpanan data pengujian. Sistem ini mampu merekam data gerakan tubuh selama aktivitas mengangkat beban dengan baik, sehingga dapat digunakan sebagai dasar dalam proses klasifikasi teknik angkat beban. Hasil ini menunjukkan bahwa rancangan perangkat keras dan perangkat lunak yang dibuat telah berfungsi sesuai dengan

tujuan penelitian, yaitu menyediakan sistem pemantauan posisi tubuh yang praktis, responsif, dan dapat digunakan secara langsung untuk mendeteksi gerakan secara *real-time*. Analisis Hasil penerapan metode *Random Forest* sebagai algoritma klasifikasi untuk mengolah dan mengklasifikasikan data sensor inersia dalam mendeteksi posisi tubuh saat mengangkat beban.

Pada penerapan metode *Random Forest* sebagai algoritma klasifikasi, penelitian ini menunjukkan bahwa data sensor inersia dapat diolah untuk membedakan posisi tubuh saat mengangkat beban dengan hasil yang cukup baik. Berdasarkan hasil evaluasi model, akurasi keseluruhan yang diperoleh sebesar 83,32%, dengan rata-rata akurasi per subjek sebesar 84,80%. Hasil *classification report* menunjukkan bahwa kelas Benar memperoleh nilai *precision* 0,83, *recall* 0,87, dan *F1-score* 0,85, sedangkan kelas Salah memperoleh *precision* 0,83, *recall* 0,79, dan *F1-score* 0,81. Nilai tersebut menandakan bahwa model *Random Forest* lebih baik dalam mengenali gerakan yang benar, namun masih memiliki beberapa kesalahan dalam mendeteksi gerakan salah. Hal ini mengindikasikan bahwa variasi pola gerakan antarresponden masih memengaruhi performa model, sehingga diperlukan kestabilan fitur yang lebih baik agar hasil klasifikasi menjadi lebih konsisten pada seluruh subjek.

Dari sisi kemampuan sistem dalam mengidentifikasi dan membedakan posisi tubuh yang benar dan salah saat mengangkat beban, hasil pengujian sistem menunjukkan performa yang cukup baik. Pada 40 aktivitas pengujian, sistem mampu memberikan prediksi yang sesuai dengan label aktual sebanyak 38 aktivitas (95%), sedangkan 2 aktivitas (5%) dinyatakan tidak sesuai. Nilai *confidence* prediksi berada pada rentang 63,0% hingga 99,7% dengan rata-rata *confidence* sebesar 86,8%, yang menunjukkan bahwa mayoritas prediksi memiliki tingkat keyakinan yang tinggi. Respons *buzzer* juga bekerja sesuai dengan rancangan, yaitu berada pada kondisi OFF ketika gerakan terdeteksi benar dan ON ketika gerakan terdeteksi salah. Namun, terdapat dua ketidaksesuaian, yaitu saat sistem menghasilkan respons *buzzer* yang tidak sesuai pada satu aktivitas dan saat sistem menampilkan status Tidak Pasti pada aktivitas lainnya karena nilai probabilitas tidak memenuhi ambang batas yang telah ditentukan. Meskipun

demikian, hasil ini menunjukkan bahwa sistem telah mampu mengidentifikasi teknik angkat beban dengan baik sekaligus memberikan umpan balik secara otomatis kepada pengguna. Dengan demikian, penerapan *Random Forest* pada sistem deteksi posisi angkat beban berbasis IoT dapat dinilai berhasil dalam membantu membedakan gerakan yang benar dan salah secara *real-time*.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, sistem deteksi posisi angkat beban berbasis *Internet of Things* (IoT) berhasil dirancang dan diimplementasikan untuk memantau posisi tubuh secara *real-time* menggunakan sensor inersia. Sistem ini memanfaatkan dua sensor MPU6050, satu sensor BMP280, mikrokontroler ESP8266, *website* berbasis Flask, serta *buzzer* sebagai umpan balik ketika postur terdeteksi salah. Hasil pengujian menunjukkan bahwa seluruh komponen sistem dapat bekerja secara terintegrasi sesuai fungsi yang dirancang. Metode *Random Forest* terbukti dapat digunakan untuk mengklasifikasikan data sensor inersia dalam mendeteksi posisi tubuh saat mengangkat beban. Proses *preprocessing*, ekstraksi fitur, dan pelatihan model menghasilkan data yang lebih informatif sehingga model mampu mengenali pola gerakan dengan baik. Dari hasil evaluasi, model memperoleh kinerja yang cukup baik dalam membedakan posisi benar dan salah, sehingga metode ini sesuai digunakan pada sistem deteksi posisi angkat beban dalam penelitian ini. Sistem yang dikembangkan juga mampu mengidentifikasi dan membedakan posisi tubuh yang benar dan yang salah saat mengangkat beban. Pada pengujian sistem, sebagian besar hasil prediksi sesuai dengan label aktual dan respons *buzzer* bekerja sesuai rancangan, yaitu nonaktif saat gerakan benar dan aktif saat gerakan salah. Hal ini menunjukkan bahwa sistem tidak hanya mampu melakukan klasifikasi, tetapi juga mampu memberikan umpan balik secara langsung untuk membantu pengguna memperbaiki teknik pengangkatan beban.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya adalah sebagai berikut:

1. Penelitian selanjutnya disarankan untuk menambah jumlah responden dengan karakteristik yang lebih beragam agar model dapat belajar dari variasi pola gerakan yang lebih luas. Hal ini diharapkan dapat meningkatkan kemampuan sistem dalam mengenali posisi tubuh saat mengangkat beban pada kondisi pengguna yang berbeda-beda.
2. Penelitian berikutnya dapat mengembangkan sistem dengan menggunakan jenis beban, bentuk beban, atau variasi aktivitas pengangkatan yang lebih beragam. Pengembangan ini penting agar sistem tidak hanya terbatas pada satu skenario pengujian, tetapi juga mampu diterapkan pada kondisi yang lebih mendekati situasi nyata di lapangan.
3. Disarankan untuk melakukan perbandingan metode klasifikasi lain selain *Random Forest*, sehingga dapat diketahui algoritma yang memiliki kinerja paling optimal dalam mendeteksi posisi angkat beban. Dengan demikian, hasil penelitian selanjutnya dapat memberikan gambaran yang lebih komprehensif mengenai metode yang paling sesuai untuk kasus ini.
4. Penelitian selanjutnya juga dapat mengembangkan sistem dengan menambahkan fitur pemantauan yang lebih lengkap, seperti notifikasi berbasis aplikasi mobile atau penyimpanan data ke server *cloud*, agar sistem menjadi lebih fleksibel dan mudah digunakan dalam pemantauan secara berkelanjutan.
5. Untuk meningkatkan ketepatan pengenalan postur, penelitian mendatang dapat menambah variasi sensor atau melakukan pengembangan pada proses ekstraksi fitur dan *preprocessing* data. Langkah ini diharapkan dapat memperkuat informasi yang digunakan model dalam membedakan posisi tubuh yang benar dan yang salah.

DAFTAR PUSTAKA

- Ahsan, M., Mahmud, M., Saha, P., Gupta, K. D., & Siddique, Z. (2021). Effect of data *Scaling* methods on *machine learning* algorithms and model performance. *Technologies*, 9(3), 52. <https://doi.org/10.3390/technologies9030052>
- Alfarezy, K., Fathurrahman, M., Sembiring, S. S. B., Paradisa, A., Anshari, S. F., & Fikry, M. (2026). Multi-stage *feature engineering* for robust BLE-based location recognition in care facilities using the activity and location recognition *dataset*. *International Journal of Activity and Behavior Computing*, 2026(2), 1–17. <https://doi.org/10.60401/ijabc.164>
- Alfiyan, M. (2023). Analisis posisi kerja manual material *handling* terhadap keluhan *Musculoskeletal Disorders* (MSDs) menggunakan metode NIOSH pada pembangunan Gedung At-Ta'awun Universitas Muhammadiyah Surabaya (*Doctoral dissertation*, Universitas Muhammadiyah Surabaya). <https://repository.um-surabaya.ac.id/id/eprint/9584>
- Alghifari, M. G. (2024). Sistem *wearable* deteksi posisi pada pelatihan otot *biceps* dan *triceps* berbasis angkat beban dengan algoritma *Random Forest*. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 8(9), 1-8. <https://j-ptiik.ub.ac.id/index.php/j-ptiik/article/view/14112>
- Ali, S., Yusman, Y., Bakhtiar, B., & Raju, M. (2022). Perancangan *software* robot pencari dan penyusun menara Lagori pada ABU Robocon 2022. *Jurnal Teknologi*, 22(2), 92. <https://doi.org/10.30811/teknologi.v22i2.3259>
- Alita, D., & Isnain, A. R. (2020). Pendeteksian sarkasme pada proses analisis sentimen menggunakan *Random Forest classifier*. *Jurnal Komputasi*, 8(2), 50–58. <https://doi.org/10.23960/komputasi.v8i2.2615>
- Amaliah, S., Nusrang, M., & Aswi. (2022). Penerapan metode *Random Forest* untuk klasifikasi varian minuman kopi di Kedai Kopi Konijiwa Bantaeng. *VARIANSI: Journal of Statistics and Its Application on Teaching and Research*, 4(2), 121–127. <https://doi.org/10.35580/variansiunm31>
- Amorim, L. B. V., Cavalcanti, G. D. C., & Cruz, R. M. O. (2022). The choice of *Scaling* technique matters for classification performance. *Applied Soft Computing*, 133, 109924. <https://doi.org/10.1016/j.asoc.2022.109924>
- Ananda, Z., Astuty, D. A., & Indriani, F. (2025). Relationship between Work Position and Musculoskeletal Disorder (MSDs) Complaints in Palm Harvesters at PTPN IV Tanah Itam Ulu. *Jurnal Biomedika Dan Kesehatan*, 8(2), 159–169. <https://doi.org/10.18051/JBiomedKes.2025.v8.159-169>

- Arif, M., Mukheimer, A., & Asif, D. (2023). Enhancing the early detection of chronic kidney disease: A robust *machine learning* model. *Big Data and Cognitive Computing*, 7, 144. <https://doi.org/10.3390/bdcc7030144>
- Ayu Syahfitri. (2025). *Internet of Things (IoT)*, sejarah, teknologi, dan penerapannya. *Uranus: Jurnal Ilmiah Teknik Elektro, Sains dan Informatika*, 3(1), 113–120. <https://doi.org/10.61132/uranus.v3i1.667>
- Butarbutar, J., Basuki, P., Sungono, V., Riantho, A., & Fidiasrianto, K. (2024). Burden of osteoarthritis in Indonesia: A Global Burden of Disease (GBD) study 2019. *Narra Journal*, 4(2). <https://doi.org/10.52225/narra.v4i2.884>
- Dimoudis, D., Vafeiadis, T., Nizamis, A., Ioannidis, D., & Tzovaras, D. (2023). Utilizing an adaptive window *rolling median* methodology for time series anomaly detection. *Procedia Computer Science*, 584–593.
- Ekici, N. U., & Tuglular, T. (2023). *Automatic Test Sequence Generation and Functional Coverage Measurement From UML Sequence Diagrams*. *International Journal of Information System Modeling and Design*, 14(1), 1–21. <https://doi.org/10.4018/IJISMD.332865>
- Fahmi, M. N. (2023). Implementasi *machine learning* menggunakan Python *library*: Scikit-Learn (*supervised* dan *unsupervised learning*). *Sains Data: Jurnal Studi Matematika dan Teknologi*, 1(2), 87–96. <https://doi.org/10.52620/sainsdata.v1i2.31>
- Fathurrahman, M., Sayuti, M., Siregar, K. M., Arta, F. S., Jazuli, M. S., Fortilla, Z. A., & Fikry, M. (2025). *EEG-based Arabic silent speech classification using native Arabic silent speech dataset: A hybrid model combining Random Forest and SVM*. In *2025 International Conference on Activity and Behavior Computing (ABC)* (pp. 1–6). IEEE. <https://doi.org/10.1109/ABC64332.2025.11118578>
- Fikhri, A. A., & Nurdin, N. (2024). Implementasi algoritma *K-Nearest Neighbor* pada sistem pemantau suhu dan kelembapan ruang server menggunakan protokol MQTT berbasis IoT. *Jurnal Informatika Dan Teknik Elektro Terapan*, 12(3S1). <https://doi.org/10.23960/jitet.v12i3S1.5422>
- Fikry, M., Bustami, & Suzanna, E. (2025). IOT-Based Environmental Monitoring and Its Implications For Student Mental Health. *Revista De Gestão Social E Ambiental - RGSA*, 19(2), e011183. <https://doi.org/10.24857/rgsa.v19n2-022>
- Gill, T. K., Mittinty, M., March, L., Steinmetz, J. D., Culbreth, G. T., Cross, M., Brooks, P. M., & others. (2023). *Global, regional, and national burden of other Musculoskeletal Disorders, 1990–2020, and projections to 2050: A systematic analysis of the Global Burden of Disease Study 2021*. *The Lancet*

- Rheumatology*, 5(9), e670–e682. [https://doi.org/10.1016/S2665-9913\(23\)00232-1](https://doi.org/10.1016/S2665-9913(23)00232-1)
- Guo, W., Yamagishi, S., & Jing, L. (2024). *Human activity recognition via Wi-Fi and inertial sensors with machine learning*. *IEEE Access*, 12, 18821–18836. <https://doi.org/10.1109/ACCESS.2024.3360490>
- Han, J., Song, W., Gozho, A., Sung, Y., Ji, S., Song, L., Wen, L., & Zhang, Q. (2020). *LoRa-based smart IoT application for smart city: An example of human position detection*. *Wireless Communications and Mobile Computing*, 2020, Article 8822555. <https://doi.org/10.1155/2020/8822555>
- Hilal, Y. N., Muliandhi, P., & Ardina, E. N. (2023). Analisa *balancing* BMS pada pengisian baterai *lithium-ion* tipe INR 18650 dengan metode *cut off*. *Jurnal Simetris*, 14(2), 375–384. DOI:10.24176/simet.v14i2.9852
- Hsu, G., Wu, J., Huang, Y., Chiu, C., & Kang, J. (2025). *Automatic detect incorrect lifting position with the pose estimation model*. *Life*, 15(3), 358. <https://doi.org/10.3390/life15030358>
- Ibrahim, A. M., & Setiyadi, D. (2021). *Prototype pengendalian lampu dan AC jarak jauh dengan jaringan internet menggunakan aplikasi Telegram berbasis Node MCU ESP8266*. *Infotech: Journal of Technology Information*, 7(1), 27–34. <https://doi.org/10.37365/jti.v7i1.103>
- Iqbal, S., Al-Azzoni, I., Allen, G., & Ullah Khan, H. (2020). *Extending UML Use Case Diagrams to Represent Non-Interactive Functional Requirements*. *E-Informatica Software Engineering Journal*, 14(1), 97–115. <https://doi.org/10.37190/e-Inf200104>
- Irianto, S., Putri, M., Pujiningrum, A. R. S., Maulang, I., Hamisah, H., Rini, I., & Syam, A. T. I. (2025). Edukasi dan skrining terkait posisi tubuh ideal sebagai upaya pencegahan gangguan posisi dini bagi peserta didik SMP-IT Ar-Rahmah Kota Makassar. *Panrita Abdi: Jurnal Pengabdian kepada Masyarakat*, 9(1), 227–237. <http://journal.unhas.ac.id/index.php/panritaabdi>
- Jha, P., Sahu, M., & Isobe, T. (2023). *A UML Activity Flow Graph-Based Regression Testing Approach*. *Applied Sciences*, 13(9), 5379. <https://doi.org/10.3390/app13095379>
- Junaedi, A., Puspitasari, M. D. M., & Maulidina, M. (2021). Pengaruh (intensor) induktor *heater* menggunakan *thermal* sensor berbasis mikrokontroler Arduino Nano dalam mengolah logam. *Nusantara of Engineering (NOE)*, 4(2), 169–175. <https://doi.org/10.29407/noe.v4i2.16754>
- Juniawan, F. P., Mayasari, M. S., Pradana, H. A., Tommy, L., & Sylfania, D. Y. (2023). Pelatihan digital marketing guna meningkatkan kompetensi

- masyarakat Desa Kace Timur, Bangka. *Jurnal Pengabdian kepada Masyarakat*, 6(1), 17–25. <https://doi.org/10.35957/fordicate.v3i1.5057>
- Kaladewa, Y., & Santoso, K. A. (2022). Implementasi sensor kemiringan sudut untuk alat bantu (*grab*) *gantry luffing crane*. *Jurnal Kajian Teknik Elektro*, 6(2), 62–69. <http://journal.uta45jakarta.ac.id/index.php/JKTE>
- Kianoush, S., Savazzi, S., Rampa, V., Costa, L., & Tolochenko, D. (2023). A *Random Forest approach to body motion detection: Multisensory fusion and edge processing*. *IEEE Sensors Journal*, 23(4), 3801–3814. <https://doi.org/10.1109/JSEN.2022.3232085>
- Kiswantono, A., & Irwan, A. (2024). Inovasi energi hijau: Piezoelektrik untuk mengubah getaran kendaraan menjadi listrik. *Jurnal Informatika dan Teknik Elektro Terapan*, 12(3), 1-10. <https://doi.org/10.23960/jitet.v12i3.4452>
- Koç, H., Erdoğan, A. M., Barjakly, Y., & Peker, S. (2021). *UML Diagrams in Software Engineering Research: A Systematic Literature Review*. *The 7th International Management Information Systems Conference*, 13. <https://doi.org/10.3390/proceedings2021074013>
- Kusuma, H. A., Oktavia, D., Nugaraha, S., Suhendra, T., & Refly, S. (2023). *Sensor BMP280 statistical analysis for barometric pressure acquisition*. *IOP Conference Series: Earth and Environmental Science*, 1148(1), 012008. <https://doi.org/10.1088/1755-1315/1148/1/012008>
- Nekwek, A. V., Pigome, J. K. S., & Firdaus, N. (2024). *Weather station based Raspberry Pi*. *Mars: Jurnal Teknik Mesin, Industri, Elektro dan Ilmu Komputer*, 2(4), 278–287. <https://doi.org/10.61132/mars.v2i4.267>
- Maulana, F., Sembiring, S. S. B., Luqman, M. N., Putri, A., Sinambela, I. S., Paradisa, A., Fathurrahman, M., Fikry, M. (2025). Comparison of tree-based and deep learning models for tremor related to Parkinson's disease. *International Journal of Activity and Behavior Computing*, 2025(3), 1–26. <https://doi.org/10.60401/ijabc.128>
- Pecoraro, F., & Luzi, D. (2022). *Using Unified Modeling Language to Analyze Business Processes in the Delivery of Child Health Services*. *International Journal of Environmental Research and Public Health*, 19(20), 13456. <https://doi.org/10.3390/ijerph192013456>
- Prahastuti, Brian & Djaali, Nur & Usman, Syarif. (2021). Faktor Risiko Gejala Muskuloskeletal Disorder (MSDs) pada Pekerja Buruh Pasar. *Jurnal Ilmiah Kesehatan*. 13. 47-54. [10.37012/jik.v13i1.516](https://doi.org/10.37012/jik.v13i1.516)
- Putri, C. H., & Mahmudin. (2025). Mengenal *Internet of Things* (IoT) dan perannya dalam jaringan komputer. *Cendekia Pendidikan*, 17(9), 61–70.

<https://doi.org/10.8734/Sindoro.v1i2.365>

- Rafiq, M., Almujaally, N., Algarni, A., Alshehri, M., Alqahtani, Y., Jalal, A., & Liu, H. (2025). Intelligent biosensors for human movement rehabilitation and intention recognition. *Frontiers in Bioengineering and Biotechnology*, 13. <https://doi.org/10.3389/fbioe.2025.1558529>
- Rahman, M. F., Nantan, Y., & Alfira, W. S. (2022). Pemodelan kotak 3D menggunakan sensor MPU6050. Dalam *Prosiding Seminar Nasional Teknik Elektro dan Informatika (SNTETI 2022)* (hlm. 1-8). Universitas Islam Makassar. <https://jurnal.poliupg.ac.id/index.php/sntei/article/view/3569>
- Rane, M., Mohole, S., Pahade, Y., Kurandale, G., & Munjale, A. (2025). *SmartPosisie: Real-time posisie detection and feedback system integrating IoT and machine learning*. Dalam *2025 1st International Conference on AIML-Applications for Engineering & Technology (ICAET)* (hlm. 1–6). IEEE. <https://doi.org/10.1109/ICAET63337.2025.10457905>
- Salcha, M. A., & Arni Juliani. (2021). Relationship between Work Posture and Symptoms of Musculoskeletal Disorders in Rice Farmers . *Miracle Journal of Public Health* , 4(2), 195-201. <https://doi.org/10.36566/mjph/Vol4.Iss2/260>
- Saputra, R., & Yulianti, B. (2021). Alat Pendeteksi Originalitas Baterai Tipe 18650 Berbasis Arduino Nano. *Jurnal Teknologi Industri*, 10(1). <https://doi.org/10.35968/jti.v10i1.776>
- Sinuhaji, N. (2023). Sistem monitoring jumlah pengunjung, tingkat kebisingan, dan kendali intensitas cahaya perpustakaan terintegrasi *Internet of Things*. *Resolusi: Rekayasa Teknik Informatika dan Informasi*, 4(1), 100–105. <https://doi.org/10.30865/resolusi.v4i1.1248>
- Song, S. Y., Pei, Y., & Hsiao-Wecksler, E. (2022). Estimating relative angles using two inertial measurement units without magnetometers. *IEEE Sensors Journal*, 22(23), 19688–19699. <https://doi.org/10.1109/JSEN.2022.3203346>
- Suryana, T. (2021). Implementasi komunikasi *web server Node MCU ESP8266* dan *web server Apache MySQL* untuk otomatisasi dan kontrol peralatan elektronik jarak jauh via Internet. *Jurnal Sistem Informasi dan Teknologi*, 3(2), 78-85. <http://repository.unikom.ac.id/id/eprint/68717>
- Suwanda, R., Anshari, S. F., & Ningsih, W. (2024). Information system for operational goods management at the Career Guidance and Entrepreneurship Center Malikussaleh University. *Jurnal Inotera*, 9(1), 164–169. <https://doi.org/10.31572/inotera.Vol9.Iss1.2024.ID324>
- Susanti, N., & Septi, A. N. (2021). Penyuluhan fisioterapi pada sikap ergonomis

- untuk mengurangi terjadinya gangguan *Musculoskeletal Disorders* (MSDs) di komunitas keluarga Desa Kebojongan. *Pena Abdimas: Jurnal Pengabdian Masyarakat*, 2(1), 45-52.
<https://doi.org/10.31941/abdms.v2i1.1290>
- Tam, A., Chairani, A., & Bustamam, N. (2021). Gambaran kualitas tidur, keluhan muskuloskeletal, dan hubungannya pada staf akademik tahun 2020. *Prepotif: Jurnal Kesehatan Masyarakat*, 5(1), 195–203.
<https://doi.org/10.31004/prepotif.v5i1.1453>
- Turyadi, I. U. (2021). Analisa dukungan *Internet of Things* (IoT) terhadap peran intelijen dalam pengamanan daerah maritim Indonesia wilayah timur. *Jurnal Teknologi dan Manajemen Informatika*, 7(1), 29–39.
<https://doi.org/10.26905/jtmi.v7i1.6040>
- World Health Organization. (2023). *Musculoskeletal conditions*. Diakses 20 Desember 2025. <https://www.who.int/news-room/fact-sheets/detail/Musculoskeletal-conditions>.
- Kalua, A. L., Kaplale, J. R., Mapalie, N. K. R., Iriansu, I. S., & Ketaren, E. (2024). Pengembangan alat tes kesamaptaan TNI/POLRI berbasis teknologi computer vision dan IoT dengan metode pose estimation menggunakan Python. *Jurnal TIMES*, 13(2), 294–299.
<https://doi.org/10.51351/jtm.13.2.2024791>
- Zulfa, I., Syahputra, H., & Faisal, A. (2021). Rancang bangun sistem kontrol alat-alat listrik menggunakan Bluetooth berbasis mikrokontroler. *Jurnal Ilmiah Elektronika dan Komputer*, 10(2), 112-120.
<http://journal.stekom.ac.id/index.php/elkom>